CAUSAL EPISTEMIC GEOMETRY · ACS-USP

Intervenções internas e os erros de um LLM

O que construímos, o que encontramos
e o que ainda precisamos entender

Gabriel · Entropic Session · 16 de outubro de 2026

Quais problemas o modelo erra?

Conseguimos mudar quais problemas um modelo acerta e erra, mantendo seus pesos fixos?

E antecipar essa mudança a partir da intervenção que fazemos?

A mesma acurácia pode esconder erros diferentes

Duas variantes acertam 3 de 6 problemas.

Problema	1	2	3	4	5	6
Variante A	**Acerta**	**Acerta**	**Acerta**	Erra	Erra	Erra
Variante B	**Acerta**	Erra	Erra	**Acerta**	**Acerta**	Erra

Exemplo construído para ilustrar a pergunta

> B resolve alguns erros de A, mas também perde acertos.

Como aproveitar isso sem conhecer o gabarito?

O que queremos descobrir

Mudar os erros	Uma intervenção oferece algo além de repetir o modelo?
Prever a mudança	Intervenções parecidas produzem perfis de erro parecidos?
Usar a diferença	Conseguimos escolher melhor sem consultar o gabarito?

Nos registros do projeto: Q1, Q2 e Q3, respectivamente.

A ESCOLHA EXPERIMENTAL

O que mudamos em cada abordagem

Abordagem	O que alteramos diretamente
Prompt	O texto de entrada. Os pesos ficam fixos.
Steering	O estado interno, somando um vetor: uma lista de ajustes numéricos. Texto da tarefa e pesos ficam fixos.
Ajuste de pesos	Os parâmetros do modelo, por treinamento adicional. LoRA aprende ajustes compartilhando o modelo base.

A adição interna oferece um controle explícito. A vantagem prática sobre bons prompts ainda precisa ser medida.

LoRA é uma comparação proposta, ainda não executada. Prompt e steering podem ser combinados. Como comparar benefício e custo ↗

O código e a entrada eram mostrados

CRUXEval · problema real sample_298

```
def f(text):
    new_text = list(text)
    for i in range(len(new_text)):
        character = new_text[i]
        new_character = character.swapcase()
        new_text[i] = new_character
    return ''.join(new_text)
```

Entrada

```
'dst vavf n dmv dfvm gamcu dgcvb.'
```

Saída correta

```
'DST VAVF N DMV DFVM GAMCU DGCVB.'
```

O programa troca maiúsculas e minúsculas; preserva espaços e ponto.

> A tarefa era escrever o resultado. A função estava visível; não era preciso descobri-la nem escrevê-la.

A resposta era comparada com o gabarito

Modelo

Lê código e entrada.
Gera uma resposta.

Avaliador, depois

Extrai o valor final.
Compara com o gabarito.

Valor extraído no caso real	Decisão
`'DST VAVF N DMV DFVM GAMCU DGCVB.'`	Correto
`'DST VAVF N DVM DFVM GAMCU DGCVB.'`	Errado: DMV virou DVM
Sem um valor final interpretável	Resposta inutilizável

Na avaliação de Q2, respostas erradas, inválidas e interrompidas contam como falhas. Registros ausentes bloqueiam a análise.

Em que regime o modelo respondia

Modelo	Qwen3-8B, com os pesos fixos durante a avaliação.
Ferramentas	Sem acesso a um interpretador Python.
Thinking desativado	Não usamos o modo especial de pensamento. O modelo ainda podia escrever passos intermediários.

> No teste Q1, o original acertou 43,86% das respostas. Conhecer o código não tornou a tarefa trivial nesse regime.

Esses resultados não estabelecem o desempenho com thinking habilitado nem representam a melhor configuração possível do modelo.

APROFUNDAR [O que pode mudar com os pesos fixos?]

O que somamos ao estado interno

No modelo usado, cada posição do texto tem um estado com **4.096 números**.
Somamos outro vetor, também com 4.096 componentes.

Estado

$$h = (h_1, h_2, \ldots, h_{4096})$$

$+$

Adição

$$\delta = \alpha \cdot (v_1, v_2, \ldots, v_{4096})$$

$\longrightarrow$ $h + \delta$

v: direção, com comprimento 1

α: intensidade da adição

> A direção define a orientação. A intensidade define quanto adicionamos nessa orientação.

Onde fica a adição: depois do 28º bloco

Usamos a **saída do 28º bloco** do Qwen3-8B. O código começa a contar em zero: esse é o **índice 27**.



L27 nos registros = bloco de índice 27 = 28º bloco na contagem humana

Um **token** é uma unidade de texto. Lemos ou alteramos o estado associado a uma posição, nessa saída.

Escolha de desenvolvimento: o protocolo fixou o índice 27 como candidato de camada única, sujeito aos testes da fonte. Os 57 problemas confirmatórios não escolheram o bloco.

APROFUNDAR Como chegamos ao controlador final

Como a adição acompanha a geração

Somamos δ na saída do 28º bloco. Os escores após os blocos seguintes dão as chances do próximo token.

Chamada	Entrada	Posição com +δ	Próximo token amostrado
Prompt inteiro	Prompt inteiro x_1 … xP	xP, último token da entrada	g_1
Próximo passo	g_1	Corrente, em g_1	g_2
Passo seguinte	g_2	Corrente, em g_2	g_3

$$h \leftarrow h + \delta \quad \cdot \quad \delta = \alpha v$$

Se a geração continuar, cada token sorteado entra na próxima chamada. A memória de passos anteriores não é reescrita; nova memória pode mudar.

Mesma adição nominal em cada passo. BF16 é a precisão numérica usada; o arredondamento pode mudar o incremento realizado. Adição, linhas 28–109 · Intensidade da primeira intervenção

Uma direção nasce de duas instruções

Nos mesmos **104 problemas**, processamos uma instrução cuidadosa e uma direta.

Cuidadosa · CAREFUL

Rastrear operações e valores.
Conferir o resultado.

Direta · DIRECT

Responder imediatamente.
Sem rastrear ou verificar.

estado cuidadoso – estado direto → média → normalização

Lemos 4.096 números na última posição do prompt, na saída do 28º bloco, antes de gerar livremente a resposta.

104 problemas de desenvolvimento; 32 separados para validar a fonte. Os 57 da confirmação não constroem o vetor.

APROFUNDAR [Como chegamos ao controlador final]

O que D75 significa na primeira etapa?

D75 é um tamanho de adição: 75% do tamanho histórico, calibrado no desenvolvimento.

adição = 0,75 × tamanho histórico × direção unitária

A intensidade histórica usa a dispersão das projeções dos estados na direção escolhida, além de um multiplicador já calibrado.

> O tamanho fica fixo na confirmação. D75 não significa 75% de mudança na resposta ou de acerto.

A coleção Q2 usa outra referência para intensidade. Seus valores 0,25 e 0,50 não são frações dessa mesma escala.

Por que D75 passou e D50 não?

Um critério exigia recuperar parte do aumento de comprimento produzido pelo prompt cuidadoso.

> Exemplo construído
>
> Original: 10 tokens. Cuidadoso: 110.
> Adição: 35 → recupera 25 dos 100 tokens extras = **25%**.

Calibração real · 50 problemas	Recuperação	Faixa exigida: 25%–125%
D50	2,8%	Não passou
D75	34,6%	Passou

D75 foi a menor intensidade elegível no conjunto de critérios, que também exigia respostas utilizáveis, competência e mudança acima dos controles.

APROFUNDAR [Como chegamos ao controlador final]

Duas instruções não são duas repetições

Construir a direção	Testar a direção fixa
104 problemas: instrução cuidadosa e instrução direta.	57 problemas reservados: duas respostas em **cada condição**.

No Qwen: original, steering, prompt CAREFUL e quatro direções aleatórias.

$$57 \text{ problemas} \times 7 \text{ condições} \times 2 \text{ respostas} = 798 \text{ gerações}$$

> Repetir a mesma condição pode produzir a mesma resposta. Não são uma resposta DIRECT e outra CAREFUL.

APROFUNDAR [Os quatro cruzamentos reutilizam as mesmas respostas]

Um perfil reúne chances de erro

A geração é aleatória: o mesmo problema pode ser acertado ou errado em tentativas diferentes.

Duas tentativas	Proporção observada de erros
0 erros	0%
1 erro	50%
2 erros	100%

> Essas proporções não são probabilidades conhecidas. Duas tentativas dão baixa resolução; as medidas usam repetições e vários problemas.

Como as repetições entram

APROFUNDAR Quanto valeria saber qual tentativa acertou? O que muda ao retirar a média? Como medir distância com poucas tentativas?

De duas respostas à falha conjunta

Registramos **erro = 1** e **acerto = 0**. O produto vale 1 só quando as duas tentativas falham.

Resposta 1	Resposta 2	Produto
0	0	0
0	1	0
1	0	0
1	1	**1**

Exemplo construído: chance de erro $q_0 = 0{,}60$ no original; $q_v = 0{,}40$ com steering.

Par	Ambas falham	Ao menos um acerto
Original + original	0,60 × 0,60 = 0,36	0,64
Original + steering	0,60 × 0,40 = 0,24	0,76

> $G = 0{,}76 - 0{,}64 = 0{,}12$: ganho de 12 pontos percentuais, com duas tentativas de cada lado.

Tentativas independentes dado o problema; seleção com gabarito.

APROFUNDAR [Os quatro cruzamentos reutilizam as mesmas respostas]

De G para C: separar o termo das médias

G compara original + steering com duas tentativas do original, usando o gabarito.

Melhor acurácia média já pode aumentar G.

μ_0: erro médio original; μ_v: erro médio com steering.

$$C = G - \mu_0(\mu_0 - \mu_v)$$

Retiramos esse termo das médias. Estimamos termos agregados com repetições independentes e correção entre problemas.

> C não identifica uma habilidade nem exige inverter a ordem de dificuldade.

APROFUNDAR Os quatro cruzamentos reutilizam as mesmas respostas A mesma distância garante o mesmo ganho?

Três comparadores, três perguntas

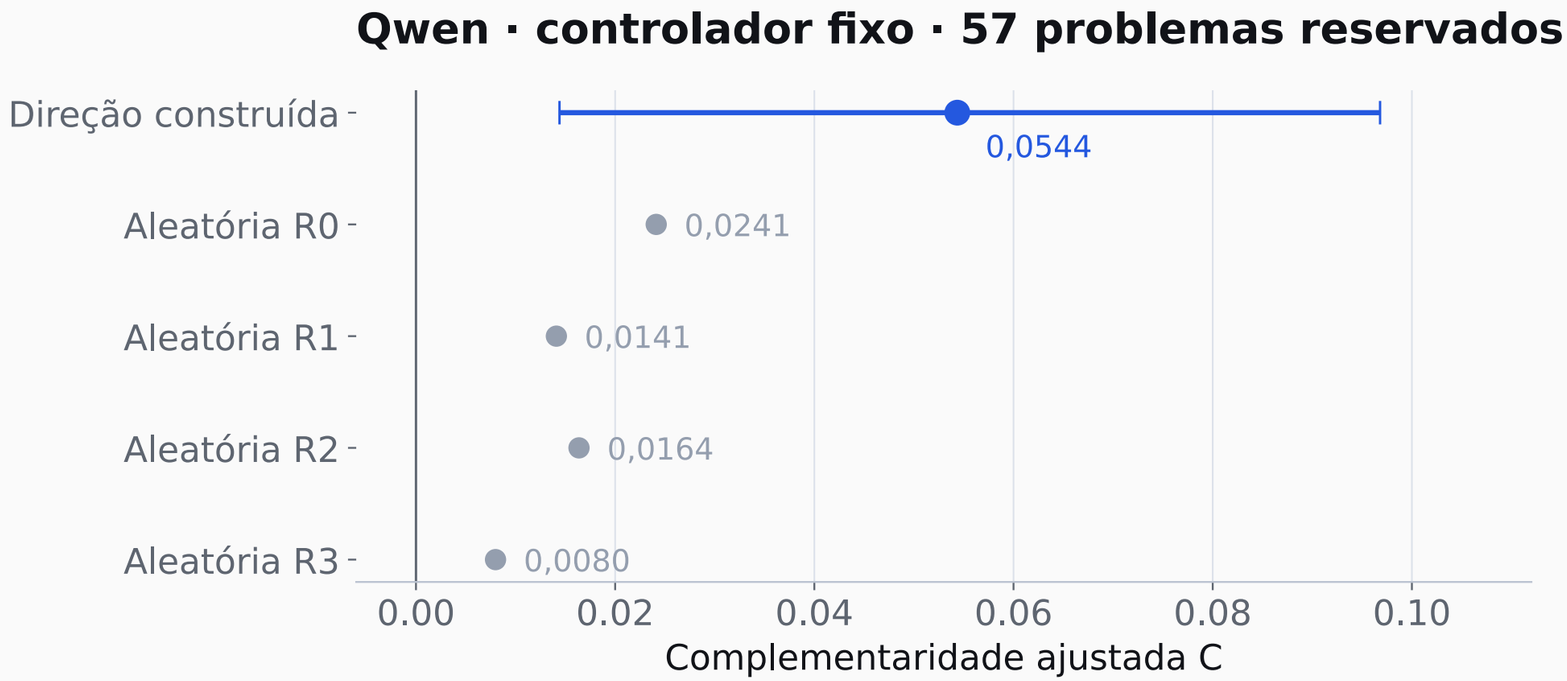
Comparador	Pergunta
Repetir o original	Quanto já ganhamos com outra amostra?
Quatro direções aleatórias	Outras direções, aplicadas do mesmo modo, também funcionam?
Prompt CAREFUL	O pedido textual já oferece benefício?

CAREFUL não integra os quatro controles aleatórios.

> Calculamos C frente ao original; depois verificamos C acima de zero e C acima da média dos quatro controles.

Complementaridade no Qwen

Controlador fixo = direção construída. R0–R3 = vetores aleatórios. Barra azul = intervalo de 95%.



57 problemas reservados; duas gerações por condição. C = 0,05435; C – média dos controles = 0,03871.

> A direção passou no Qwen. O segundo modelo, Ministral, falhou no critério de respostas utilizáveis.

APROFUNDAR Casos observados Por que estes controles?

Qual trecho será executado?

Q2 constrói outras fontes; a direção de Q1 fica fora.

```
def f(x):
    if x > 0:
        return x + 1
    else:
        return -x
```

Instrução A

Liste quais trechos podem executar; acompanhe cada um até o retorno.

Instrução B

Siga o trecho que parecer mais imediato, sem listar outros. **“Mais imediato” não foi definido.**

Entrada: `-3`.
`x > 0` é falso: seguimos o `else` e retornamos **3**.

Exemplo construído. A/B resumem instruções reais; não são respostas coletadas nem prova de habilidade isolada.

Dois nomes, uma única lista

```
def f(x):
    a = [x]
    b = a
    b.append(2)
    return a
```

Entrada: `1`. Resultado: **`[1, 2]`**.
`b = a` não copia a lista.

Instrução A

Registre que `a` e `b` apontam para a mesma lista; aplique as mudanças em ordem.

Instrução B

Faça as atualizações sem manter esse registro de objetos compartilhados. **Isso não manda criar duas listas.**

Exemplo construído. A/B resumem instruções reais; não são respostas coletadas nem prova de habilidade isolada.

Qual é a última repetição?

```
def f():
    total = 0
    for i in range(1, 4):
        total += i
    return total
```

Chamada `f()`: resultado **6**.
Somamos `1 + 2 + 3`; o `4` fica fora.

Instrução A

Confira começo, primeiro e último `i`, ordem das somas e parada.

Instrução B

Resolva o que a repetição faz, sem conferir esses limites separadamente. **O texto não define outro cálculo.**

Exemplo construído. A/B resumem instruções reais; não são respostas coletadas nem prova de habilidade isolada.

Qual saída resiste às operações?

```
def f(x):
    y = x + 2
    return y * 3
```

Entrada: `1` → `y = 3` → retorno **9**.
Entre `3` e `9`, a última operação exclui `3`.

Instrução A

Teste saídas possíveis contra as operações; descarte as incompatíveis.

Instrução B

Assuma a primeira saída plausível, sem manter ou eliminar alternativas.

> Quatro pares A/B × duas posições de leitura = oito vetores-fonte. Q1 usa outra direção.

Exemplo construído. A/B resumem instruções reais; não são respostas coletadas nem prova de habilidade isolada.

De onde lemos os estados

No mesmo problema, lemos o estado após cada instrução A/B, na saída do 28º bloco. Os prompts podem ter comprimentos diferentes.

Posição	O que lemos em A	O que lemos em B
Fim do prompt	h^A no último token da entrada	h^B no último token da entrada
Fim da frase fornecida	h^A após a frase fixa	h^B após a mesma frase

Frase fornecida · não é uma resposta livre

I will now apply the requested reasoning policy to the program before committing to one answer.

Uma passagem completa sem cache por instrução. h é o estado com 4096 números nessa posição.

Quatro receitas × duas posições = oito vetores-fonte. Aqui lemos estados; na avaliação somamos vetores. Esquema de posições, sem tokens reais. Captura, linhas 259–302

Dos oito vetores a uma base comum

Para cada receita e posição: média das diferenças em 24 problemas, depois normalização para comprimento 1.

$$d_i = h_i^{A} - h_i^{B} \quad \rightarrow \quad \bar{d} = \text{média}(d_i) \quad \rightarrow \quad u = \bar{d} / \|\bar{d}\|$$

8 vetores-fonte: colunas de U

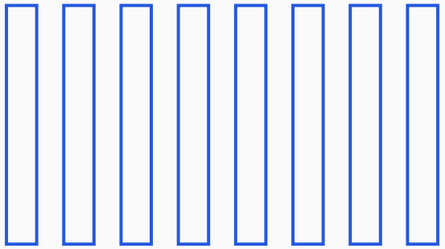


4 receitas × 2 posições

SVD

Decomposição em valores singulares

8 colunas de Q



4096 linhas; 8 colunas

> O posto observado foi 8. Q tem colunas de comprimento 1, perpendiculares entre si: uma base do mesmo espaço.

Como produzimos novas direções nesse espaço

Uma nova direção combina as oito colunas de Q, com pesos positivos ou negativos.

8 pesos: $c_1 \ldots c_8$ — Base já construída — Direção no modelo

$$c \longrightarrow Q \times c \longrightarrow v = Qc$$

c tem 8 números

v tem 4096 números

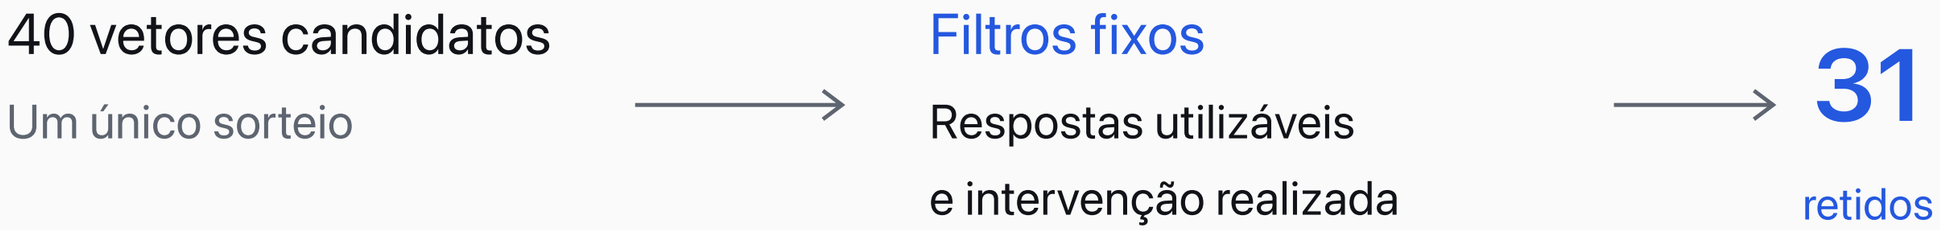
Para obter c, sorteamos oito números independentes da normal padrão e normalizamos o conjunto:

$$g \sim N(0, I_8) \rightarrow c = g / \|g\| \rightarrow v = Qc$$

Orientações distribuídas uniformemente dentro desse espaço, antes dos filtros. Coordenadas não nomeiam conceitos.

Como fechamos a coleção de direções

Chamamos de **banco** a coleção de vetores disponíveis para adicionar ao mesmo modelo.



Os filtros verificam formato, interpretação da saída, interrupção, mudança textual e tamanho, sem consultar acertos. **Uma resposta utilizável ainda pode estar errada.**

> Não substituímos os rejeitados. Estudamos as 31 direções que qualificaram, não todas as orientações possíveis.

APROFUNDAR [Usar sem gabarito ainda é usar o problema]

Mesma direção, duas intensidades

Calibramos dois tamanhos de adição contra uma referência fixa do estado sem intervenção.

Alvo Q2	Norma do vetor adicionado ÷ referência
0,25 · menor	0,25
0,50 · maior	0,50

Referência = raiz da média de $||h||^2$, congelada em 12 prompts de calibração. h é o estado sem adição.

> 31 direções × 2 intensidades + modelo original = 63 condições.

α é calibrado por direção e alvo; fica fixo na geração. D75 usa outra escala. O arredondamento numérico pode mudar o incremento efetivo.

Como comparar dois perfis de erro?

Perfil: chance de errar cada problema.

Condição	Problema 1	Problema 2	Erro médio
Referência	20%	80%	50%
Variante	40%	60%	50%

Exemplo construído

A média é igual, mas a distribuição entre problemas mudou.

> Chamamos de D^{shape} a distância de forma, que retira a diferença média.

No estudo: duas gerações por condição; estimativas com baixa resolução.

Três maneiras de comparar as intervenções

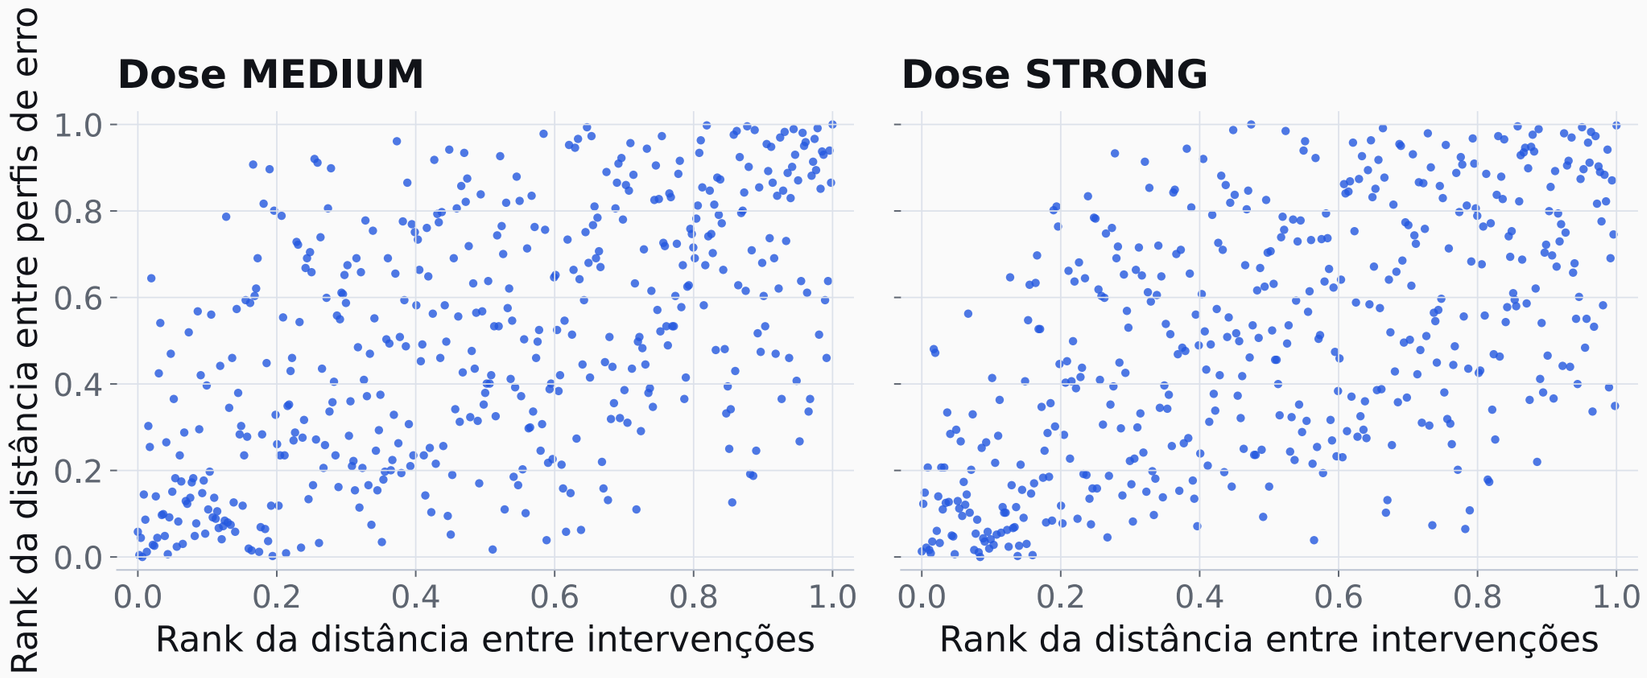
Medida	Como comparamos
A0 · vetores	Ângulo entre as direções adicionadas.
A1 · estados internos	Ângulo com coordenadas ajustadas à variação habitual dos estados internos.
A2 · respostas probabilísticas	Ângulo entre mudanças nas probabilidades do próximo token.

> Foram fixadas antes de analisar os erros do painel. A2 exige executar intervenções, mas não consulta o gabarito.

APROFUNDAR [O que A1 e A2 acrescentam ao ângulo comum?]

Ângulo dos vetores e diferenças nos erros

Cada ponto é um par. Rank = ordem. Doses MEDIUM/STRONG = adições de intensidade 0,25/0,50.



Horizontal: ângulo dos vetores, A0. Vertical: distância de forma dos erros, D^{shape}. Associação média entre ordens: 0,564.

> Os 465 pares compartilham 31 direções; não são observações independentes.

APROFUNDAR [Por que 465 pares não são casos independentes?]

O teste com direções novas

Mantemos o espaço de oito dimensões e as duas intensidades. Trocamos os vetores.

Para cada direção nova	Procedimento
Comparar com as 31 originais	31 distâncias entre vetores versus 31 distâncias entre perfis de erro.
Obter um resultado	Calcular a associação em cada intensidade e fazer a média.

> O gráfico seguinte mostra um resultado por direção nova.

34 candidatas em um único fluxo, 26 qualificadas, primeiras 16 retidas. Seleção sem consultar acertos.

O padrão se repetiu em direções novas

Uma barra por nova direção. Atlas = 31 referências. A altura, r_i, é a associação média nas duas intensidades.



16/16 associações positivas. Teste de sinais: p unilateral nominal = $1{,}53 \times 10^{-5}$.

> Unidade do teste: direção qualificada. As referências e os problemas são compartilhados; 19.200 gerações não são unidades independentes.

APROFUNDAR [Por que 465 pares não são casos independentes?] [Reamostrar problemas cria novas respostas?]

O alcance do teste com novas direções

Variou	Permaneceu igual
As direções adicionadas	Modelo, tarefa e 300 problemas
Novas identidades	Bloco de aplicação, espaço de misturas, duas intensidades e 31 referências

> O resultado generaliza para direções novas nesse laboratório. Não testa tarefas novas nem garante prever cada resposta.

Estratégia semântica específica e resposta genérica às perturbações continuam explicações a distinguir.

O texto também é um comparador forte

Acurácia observada em duas coletas distintas:

Coleta	Sem adição	Adição fixa	Instrução detalhada
CRUXEval 57 problemas	43,86%	50,00%	73,68%
LiveCodeBench 130 grupos de casos	66,92%	59,62%	72,88%

A adição fixa não passou os critérios completos na tarefa nova.

> A instrução teve maior acurácia observada. Custos não foram igualados; isso não é um teste de superioridade.

O espaço construído teve uma vantagem especial?

Um piloto manteve a estrutura das direções e comparou três orientações do espaço interno.

Orientação	Associação entre distâncias
Construída das instruções	0,418
Aleatória 1	0,018
Aleatória 2	0,248

> O critério pré-definido ficou inconclusivo. O tamanho da mudança de erros e sua repetibilidade diferiram; só duas orientações aleatórias foram comparadas.

APROFUNDAR [Por que estes controles?]

Escolher a configuração trouxe ganhos em desenvolvimento

Seletor: escolhe a configuração antes da resposta, sem gabarito. Dados já expostos.

Desenho	Ganho em pontos percentuais
Escolha por problema	+5,33
Seletor em um conjunto de 8 variantes	+4

Comparador de cada estudo: sua melhor configuração fixa, escolhida na parte de treino de cada divisão dos dados.

> No primeiro estudo, informar também a geometria ao seletor acrescentou 0,33 ponto. O mínimo exigido era 1 ponto.

APROFUNDAR [A mesma distância garante o mesmo ganho?] [Como comparar steering, prompts e ajuste de pesos?]

A confirmação em problemas novos não foi aberta

Primeiro, o instrumento precisava passar critérios obrigatórios.

Critério	Observado	Exigido
Acerto da configuração fixa	13,33%	≥25%
Oportunidade observada com gabarito	1,5 ponto percentual	≥5 pontos percentuais

São dois exemplos de quatro critérios que falharam.

> Instrumento não qualificado; confirmação não realizada. Isso não demonstra ausência de benefício.

Por que o desenho precisou mudar

Dificuldade encontrada	O que mudamos
O formato escrito confundia a correção.	Passamos a comparar o valor final interpretado.
Separar instruções não garantia um efeito útil.	Testamos também onde, quanto e por quanto tempo adicionar o vetor.
Poucas intervenções limitavam a comparação.	Construímos uma coleção e fixamos regras antes dos acertos.
A relação podia depender das direções já vistas.	Reservamos novas direções para testar a previsão.

Os apoios documentam as mudanças de desenho, os resultados que limitaram a hipótese e a sistemática de registro.

APROFUNDAR [O trabalho mudou o que precisava ser testado]

O que vale testar a seguir?

Que observação distinguiria uma estrutura especial dos erros de uma resposta genérica à perturbação?

E que ganho justificaria usar steering junto de bons prompts?