CAUSAL EPISTEMIC GEOMETRY · ACS-USP

Intervenções internas e a estrutura dos erros de um LLM

Resultados, limites e perguntas para continuar investigando

Gabriel · Entropic Session · 16 de outubro de 2026

Controle dos perfis de erro

Até que ponto conseguimos controlar e prever quais problemas um modelo congelado acerta e erra?

O objeto é um perfil de desempenho por problema, sob uma política de geração definida.

> A mesma acurácia média pode acompanhar perfis de erro diferentes.

Três perguntas do programa

Controle	Uma intervenção muda quais problemas falham, além de repetir o baseline?
Geometria	Relações entre intervenções antecipam relações entre perfis de erro?
Utilidade	Um mecanismo realizável consegue aproveitar essa complementaridade?

Cada pergunta tem uma unidade de análise e um teste próprio.

O que a evidência atual sustenta

16 / 16

direções novas com associação geométrica positiva frente ao atlas histórico

Há controle de perfil no teste confirmatório do Qwen.

Há estrutura relacional no banco e em direções novas.

> Generalidade entre tarefas, especificidade do espaço e ganho coletivo permanecem delimitados ou abertos.

Steering, prompting e adaptação dos pesos

Intervenção	O que muda diretamente	Pesos e escopo
Prompt	Instrução e contexto na sequência de entrada; também alteram ativações	Pesos fixos. Pode ser combinado com steering.
Steering	Adição nominal na saída do bloco 27; direção, dose, site e duração controlados	Pesos fixos. Vetor de contrastes de prompts; texto baseline fixo na avaliação.
LoRA	Adaptação aprendida $\Delta W = BA$, escala absorvida; efeito BAx depende da representação x	Base compartilhada e fixa; peso efetivo $W_0 + BA$. Comparador proposto, não executado aqui.

Os métodos podem ser combinados; políticas de prompts também admitem famílias contínuas. Compare baseline repetido, prompts fortes, steering e adaptações, contando construção, seleção, treinamento e inferência.

Steering permite controlar uma adição interna, mantendo o prompt de avaliação fixo. Superioridade prática exige comparação.

Comparação conceitual; LoRA não foi executado neste projeto. O benefício incremental exige comparar prompts fortes, steering e adaptações sob orçamento definido.
Apoio: experimento justo ↗

O laboratório experimental

Qwen3-8B congelado

Predição de saídas de programas Python no CRUXEval

Correção objetiva após avaliação semântica do valor final

Q2: painel fixo de 300 problemas

Mesma camada, prompt de tarefa, avaliação e política de geração entre condições

> O Q2 final usa `enable_thinking=false`.

Uma resposta precisa passar por três perguntas

Compromisso	O modelo entregou um valor final identificável?
Avaliabilidade	Esse valor pode ser interpretado pelo contrato semântico?
Correção	O valor corresponde à execução de referência?

O Q2 conta respostas erradas, inválidas e truncadas como erro; linhas ausentes bloqueiam a análise.

A direção confirmatória de Q1

$$v = \text{unit}\,[\,\text{média de } 104 \text{ contrastes CAREFUL} - \text{DIRECT}\,]$$

- Mesmos problemas nas duas condições de fonte
- Captura no último token do prompt, saída de L27
- 32 itens separados para validar a fonte
- Sem usar correção ou respostas geradas para estimar v
- D75: 75% da dose histórica, após calibração em desenvolvimento

> Esta direção é anterior e distinta das oito fontes do Q2.

Quatro contrastes de instruções

Família	Política positiva	Política negativa
Fluxo de controle	Enumerar e reconciliar caminhos	Seguir o caminho mais aparente
Mutação e aliasing	Acompanhar alterações e referências	Tratar atualizações localmente
Fronteiras de loops	Auditar iterações e término	Seguir o padrão geral
Hipóteses	Manter e eliminar candidatos	Assumir o primeiro plausível

Paráfrases para leitura. Os prompts completos e seus bytes definem o experimento.

APROFUNDAR [A direção confirmatória de Q1]

Duas posições de captura

As instruções +/− são system prompts para o mesmo problema i e família f. Cada prompt tem comprimento $P_{\pm}$ próprio; a continuação fixa tem T tokens. Capturamos a saída do bloco 27.

Condição	Sequência processada	Prompt boundary	Execution boundary
+	$x_1^+ \dots xP^+ \cdot t_1 \dots tT$	h^+ em xP^+ Índice $P_+ - 1$	h^+ em tT Índice $P_+ + T - 1$
−	$x_1^- \dots xP^- \cdot t_1 \dots tT$	h^- em xP^- Índice $P_- - 1$	h^- em tT Índice $P_- + T - 1$

```
teacher_ids = encode(text, add_special_tokens=False)
full_ids = prompt_ids + teacher_ids
```

Continuação fixa · teacher forcing

I will now apply the requested reasoning policy to the program before committing to one answer.

Índices com base zero. Uma forward completa, sem cache, por condição captura ambas as posições. Não há geração livre nem retokenização de uma string combinada.

Quatro famílias × duas posições = oito fontes. Esquema de posições, sem tokens ou comprimentos medidos. Captura não é fase nem site de aplicação. Captura Q2, linhas 259–302

Das ativações ao subespaço de intervenção

Etapa	Operação	Definição
1 · Pares	Mesmos 24 problemas, para cada família f e posição s	$d_{i,f,s} = h^{+}_{i,f,s} - h^{-}_{i,f,s}$
2 · Fonte unitária	Média das diferenças, depois normalização L2	$\bar{d}_{f,s} = (1/24)\ \Sigma_i\ d_{i,f,s}$ $u_{f,s} = \bar{d}_{f,s} / \lVert \bar{d}_{f,s} \rVert_2$
3 · Base SVD	Oito fontes em $U \in \mathbb{R}^{4096\times 8}$; posto observado 8	$U = L\Sigma R^{T}$; reter $\sigma_k/\sigma_1 \geq 10^{-6}$ $Q = L_{retido} \in \mathbb{R}^{4096\times 8}$; $Q^{T}Q = I_8$
4 · Combinação	Coeficientes unitários; isotropia apenas no subespaço	$g_j \sim N(0, I_8)$ $c_j = g_j/\lVert g_j \rVert_2$; $v_j = Qc_j$

Quatro famílias × duas posições = oito fontes. A média pareada precede a normalização; U não precisa ter colunas ortogonais. Q fornece coordenadas, não significados cognitivos. A lei isotrópica é anterior à qualificação: 40 candidatos sorteados deram 31 direções qualificadas.

31 direções não significam 31 conceitos. 40 candidatos sorteados → 31 qualificados. Esquema de matrizes; sem novo sorteio nem valores medidos. Construção Q2 e fontes imutáveis · Geometrias: A0, A1 e A2

PROTOCOLO DE APLICAÇÃO

Site, dose e duração

δ é uma adição na saída de L27. Os logits após os blocos seguintes definem a distribuição de amostragem.

Chamada	Entrada	Posição com +δ	Próximo token amostrado
Prefill	Prompt inteiro x_1 … xP	xP, último não-padding	g_1
Decode 1	g_1	Corrente, em g_1	g_2
Decode 2	g_2	Corrente, em g_2	g_3

$$h^{(27)}_p \leftarrow h^{(27)}_p + \alpha_{j,s} v_j$$

As chamadas decode ocorrem se a geração continuar. O hook não reescreve K/V já calculados em L27. Os blocos seguintes podem mudar o cache produzido adiante.

δ nominal fixo por condição. Em BF16, o incremento realizado pode variar com o estado. Q2: alvos 0,25 e 0,50 com RMS baseline congelado. Regime serial, batch 1, com cache qualificado. Hook L27, linhas 28–109 · D75: seleção da dose

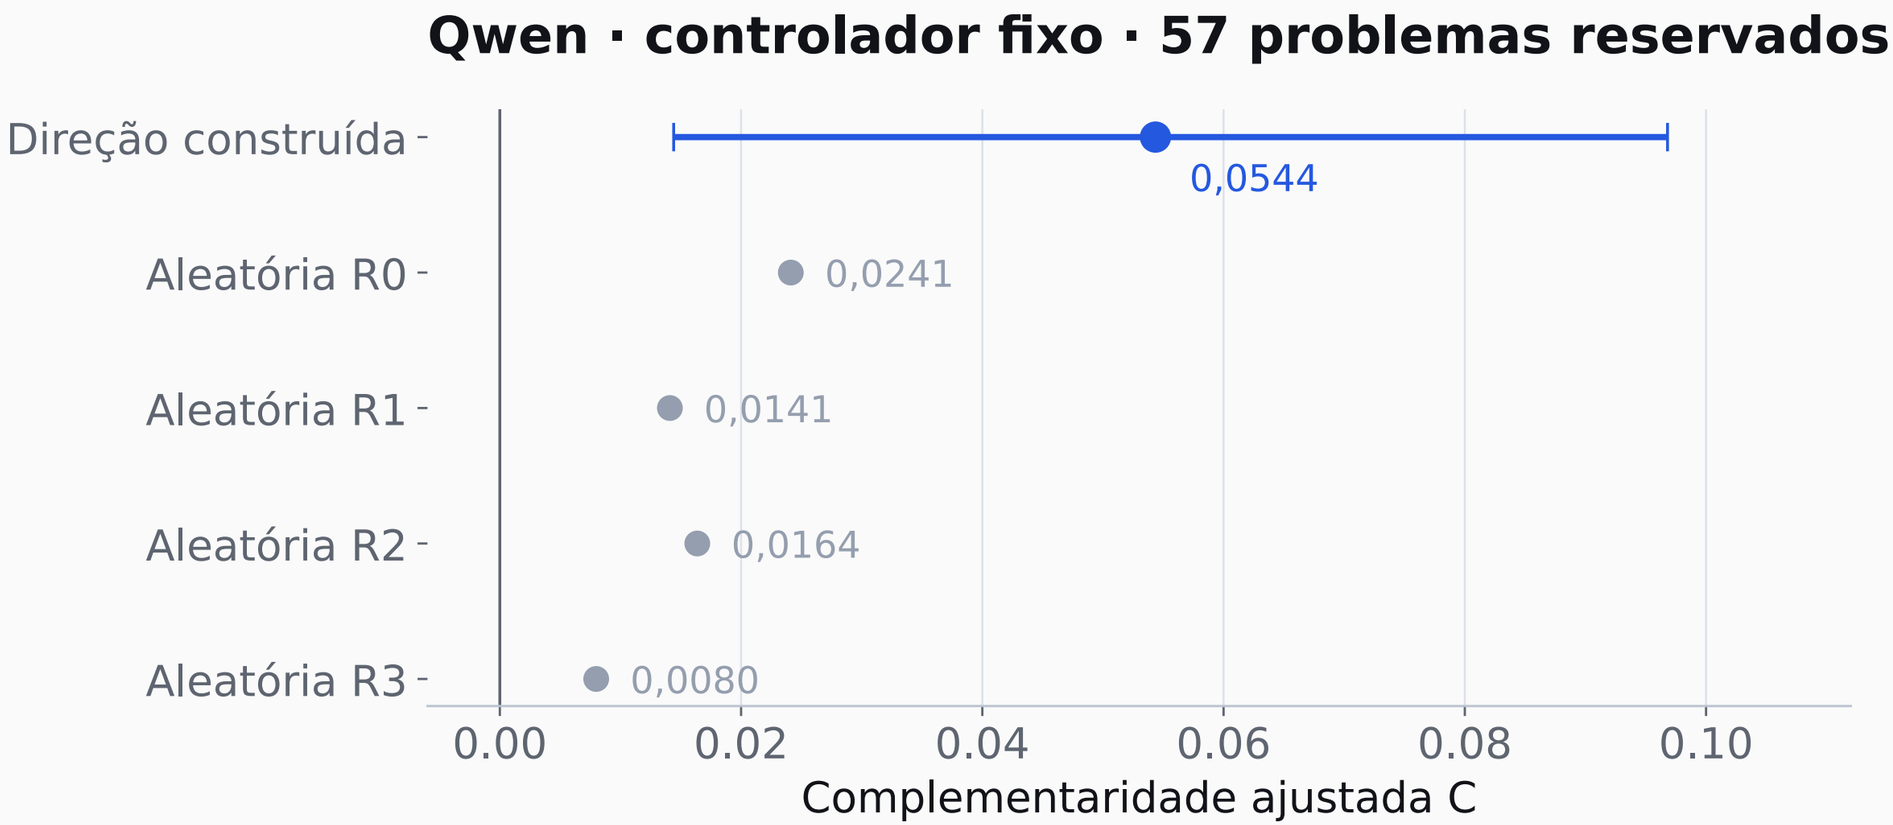
O que medimos em cada problema

$q_j(i)$: probabilidade de erro da condição j no problema i

Quantidade	Pergunta
Acurácia média	A condição acerta mais no painel?
Rescue / damage	Que acertos ganhamos e perdemos frente ao baseline?
Complementaridade C	Qual componente da mudança excede a diferença média de competência?
D^{shape}	Quanto a forma do perfil muda, removendo seu deslocamento médio?

APROFUNDAR Oracle, competência e complementaridade · Distância total e mudança de forma · Por que duas repetições entram no estimador

Q1 · complementaridade no controlador fixo



Qwen, 57 problemas reservados. Acurácia: 43,86% → 50,00%. Contraste C – média dos controles: 0,03871.

APROFUNDAR [Respostas observadas no mesmo problema] [A direção confirmatória de Q1] [D75: o que foi selecionado, e por quê] [Que pergunta cada controle responde?]

Geometrias definidas antes dos acertos

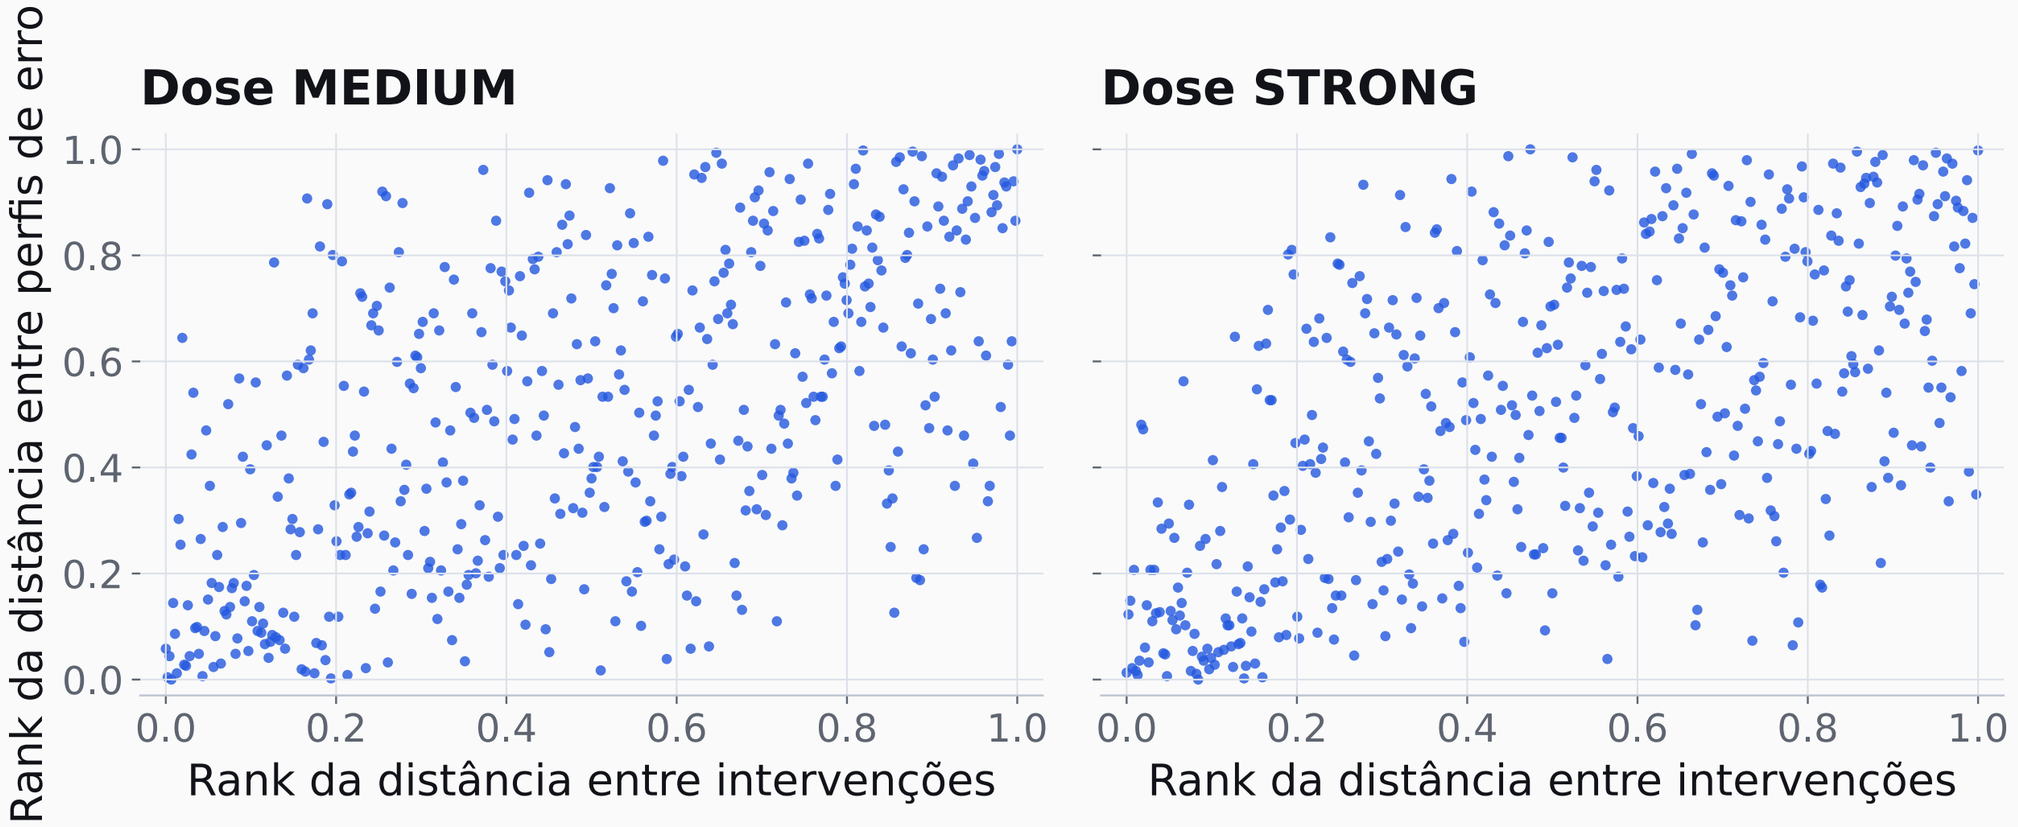
Preditor	Informação utilizada
A0 · coordenadas	Ângulo entre direções de intervenção
A1 · ativações	Geometria ponderada por estatísticas de ativação
A2 · resposta	Relações entre mudanças nas distribuições de saída

> Pré-outcome semântico não significa pré-intervenção.

A2 utiliza resposta label-free a intervenções; não é uma Fisher estimada por derivada infinitesimal.

APROFUNDAR [A1 e A2: construções operacionais]

Q2 · associação no banco histórico



31 direções, 300 problemas, duas repetições por condição. 37.800 gerações. A0 agregado: ρ ≈ 0,564.

APROFUNDAR [Pares compartilham direções]

Validação com direções novas



19.200 gerações. Teste primário por direção nova: 16/16 positivos; p binomial unilateral nominal = 1,53 × 10^{-5}.

APROFUNDAR [Pares compartilham direções] [O diagnóstico do bootstrap]

O alcance da generalização

MUDOU

A identidade da direção de intervenção

PERMANECEU FIXO

Modelo · tarefa · painel de problemas

Camada · subespaço · doses · atlas

> As relações generalizaram dentro desse laboratório. Outras dimensões exigem testes próprios.

Transferência e o comparador textual

ACURÁCIA OBSERVADA

Coleta	Baseline	Steering fixo	Prompt CAREFUL
Q1 · CRUXEval 57 problemas	43,86%	50,00%	73,68%
LiveCodeBench 130 famílias	66,92%	59,62%	72,88%

Acurácias descritivas; uso realizado de tokens não pareado. Em LiveCodeBench, o controlador fixo não passou o critério completo de transferência.

> A vantagem sobre prompting continua sendo uma pergunta experimental.

A etapa da utilidade coletiva

Como escolher ou agregar respostas sem conhecer o gabarito?

Um banco complementar pode oferecer headroom para um oracle.

Seleção realizável exige informação disponível antes da resposta final e avaliação em problemas reservados.

> Os estudos acumulados ainda não demonstram utilidade prospectiva de roteamento.

APROFUNDAR [Mesma distância, ganhos de oracle opostos] [Uma comparação de valor incremental]

Discussão

Que explicação concorrente vale enfrentar primeiro?

Que resultado mudaria nossa interpretação do mapa entre intervenção e erro?

Qual dimensão nova de generalização acrescentaria mais conhecimento?

Os apêndices permitem aprofundar métodos, estimandos e caminhos de pesquisa.