CAUSAL EPISTEMIC GEOMETRY · ACS-USP

Intervenções internas e a estrutura dos erros de um LLM

Resultados, limites e perguntas para continuar investigando

Gabriel · Entropic Session · 16 de outubro de 2026

Controle dos perfis de erro

Até que ponto conseguimos controlar e prever quais problemas um modelo congelado acerta e erra?

O objeto é um perfil de desempenho por problema, sob uma política de geração definida.

> A mesma acurácia média pode acompanhar perfis de erro diferentes.

Três perguntas do programa

Controle	Uma intervenção muda quais problemas falham, além de repetir o baseline?
Geometria	Relações entre intervenções antecipam relações entre perfis de erro?
Utilidade	Um mecanismo realizável consegue aproveitar essa complementaridade?

Cada pergunta tem uma unidade de análise e um teste próprio.

O que a evidência atual sustenta

16 / 16

direções novas com associação geométrica positiva frente ao atlas histórico

Há controle de perfil no teste confirmatório do Qwen.

Há estrutura relacional no banco e em direções novas.

> Generalidade entre tarefas, especificidade do espaço e ganho coletivo permanecem delimitados ou abertos.

Steering, prompting e adaptação dos pesos

Intervenção	O que variamos	Pergunta relevante
Prompt	Instrução e contexto	Quanto os bons prompts já conseguem?
Steering	Direção, dose, site e duração	O controle interno acrescenta algo útil?
Fine-tuning / LoRA	Uma adaptação aprendida	Como comparar benefício e custo total?

> Steering permite controlar uma adição interna, mantendo o prompt de avaliação fixo.
> Superioridade prática exige comparação.

APROFUNDAR [Uma comparação de valor incremental]

O laboratório experimental

Qwen3-8B congelado

Predição de saídas de programas Python no CRUXEval

Correção objetiva após avaliação semântica do valor final

Q2: painel fixo de 300 problemas

Mesma camada, prompt de tarefa, avaliação e política de geração entre condições

> O Q2 final usa `enable_thinking=false`.

Uma resposta precisa passar por três perguntas

Compromisso	O modelo entregou um valor final identificável?
Avaliabilidade	Esse valor pode ser interpretado pelo contrato semântico?
Correção	O valor corresponde à execução de referência?

O Q2 conta respostas erradas, inválidas e truncadas como erro; linhas ausentes bloqueiam a análise.

A direção confirmatória de Q1

$$v = \text{unit}\,[\,\text{média de } 104 \text{ contrastes CAREFUL} - \text{DIRECT}\,]$$

- Mesmos problemas nas duas condições de fonte
- Captura no último token do prompt, saída de L27
- 32 itens separados para validar a fonte
- Sem usar correção ou respostas geradas para estimar v
- D75: 75% da dose histórica, após calibração em desenvolvimento

> Esta direção é anterior e distinta das oito fontes do Q2.

Quatro contrastes de instruções

Família	Política positiva	Política negativa
Fluxo de controle	Enumerar e reconciliar caminhos	Seguir o caminho mais aparente
Mutação e aliasing	Acompanhar alterações e referências	Tratar atualizações localmente
Fronteiras de loops	Auditar iterações e término	Seguir o padrão geral
Hipóteses	Manter e eliminar candidatos	Assumir o primeiro plausível

Paráfrases para leitura. Os prompts completos e seus bytes definem o experimento.

APROFUNDAR [A direção confirmatória de Q1]

Duas posições de captura

PROMPT BOUNDARY

Último token do prompt renderizado

EXECUTION BOUNDARY

Último token de uma continuação fixa, por teacher forcing

> I will now apply the requested reasoning policy to the program before committing to one answer.

Quatro contrastes × duas posições = oito estimadores de direção.

Das ativações ao subespaço de intervenção

$$u_{f,s} = \text{unit}\left[\ \text{média}_i\ (h^{+}_{i,f,s} - h^{-}_{i,f,s})\ \right]$$

Oito vetores em $\mathbb{R}^{4096}$ formam uma matriz de posto 8.

$$U = L\Sigma R^{T} \qquad Q^{T}Q = I \qquad v_j = Qc_j$$

Amostramos c_j unitários dentro desse espaço.

> As direções novas são combinações no subespaço; 31 direções não significam 31 conceitos.

APROFUNDAR [A1 e A2: construções operacionais]

Site, dose e duração

δ é uma adição na saída de L27. Os logits após os blocos seguintes definem a distribuição de amostragem.

Chamada	Entrada	Posição com +δ	Próximo token amostrado
Prefill	Prompt inteiro x_1 … xP	xP, último não-padding	g_1
Decode 1	g_1	Corrente, em g_1	g_2
Decode 2	g_2	Corrente, em g_2	g_3

$$h^{(27)}_p \leftarrow h^{(27)}_p + \alpha_{j,s} v_j$$

As chamadas decode ocorrem se a geração continuar. O hook não reescreve K/V já calculados em L27. Os blocos seguintes podem mudar o cache produzido adiante.

δ nominal fixo por condição. Em BF16, o incremento realizado pode variar com o estado. Q2: alvos 0,25 e 0,50 com RMS baseline congelado. Regime serial, batch 1, com cache qualificado. Hook L27, linhas 28–109 · D75: seleção da dose

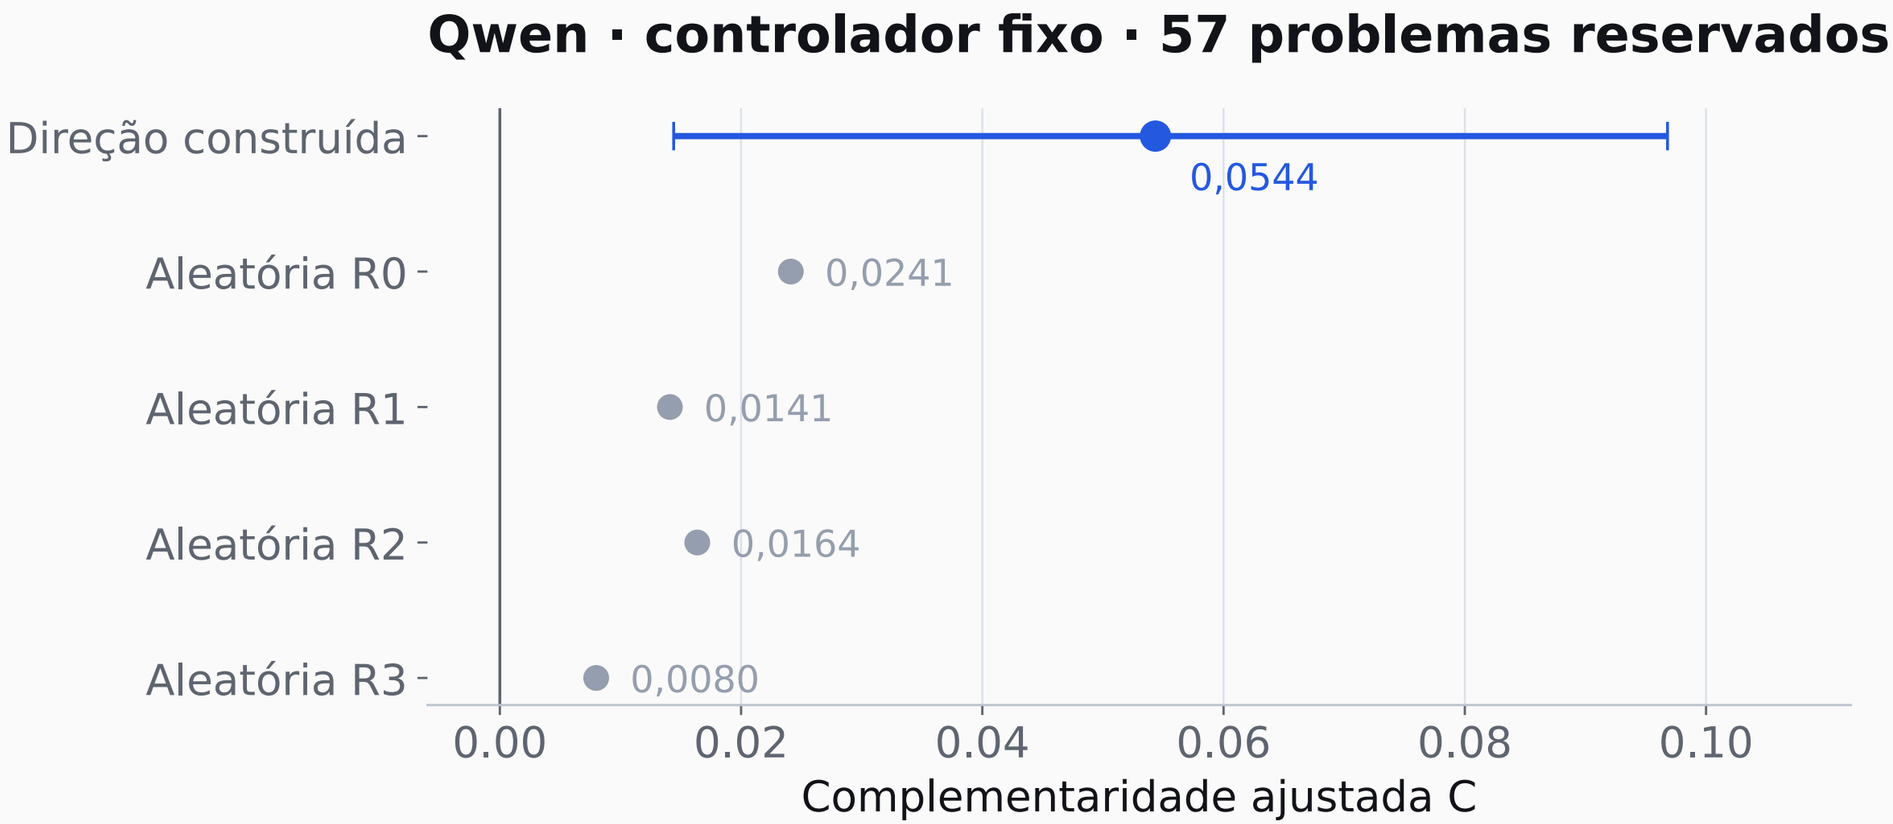
O que medimos em cada problema

$q_j(i)$: probabilidade de erro da condição j no problema i

Quantidade	Pergunta
Acurácia média	A condição acerta mais no painel?
Rescue / damage	Que acertos ganhamos e perdemos frente ao baseline?
Complementaridade C	Qual componente da mudança excede a diferença média de competência?
D^{shape}	Quanto a forma do perfil muda, removendo seu deslocamento médio?

APROFUNDAR Oracle, competência e complementaridade · Distância total e mudança de forma · Por que duas repetições entram no estimador

Q1 · complementaridade no controlador fixo



Qwen, 57 problemas reservados. Acurácia: 43,86% → 50,00%. Contraste C – média dos controles: 0,03871.

APROFUNDAR [Respostas observadas no mesmo problema] [A direção confirmatória de Q1] [D75: o que foi selecionado, e por quê] [Que pergunta cada controle responde?]

Geometrias definidas antes dos acertos

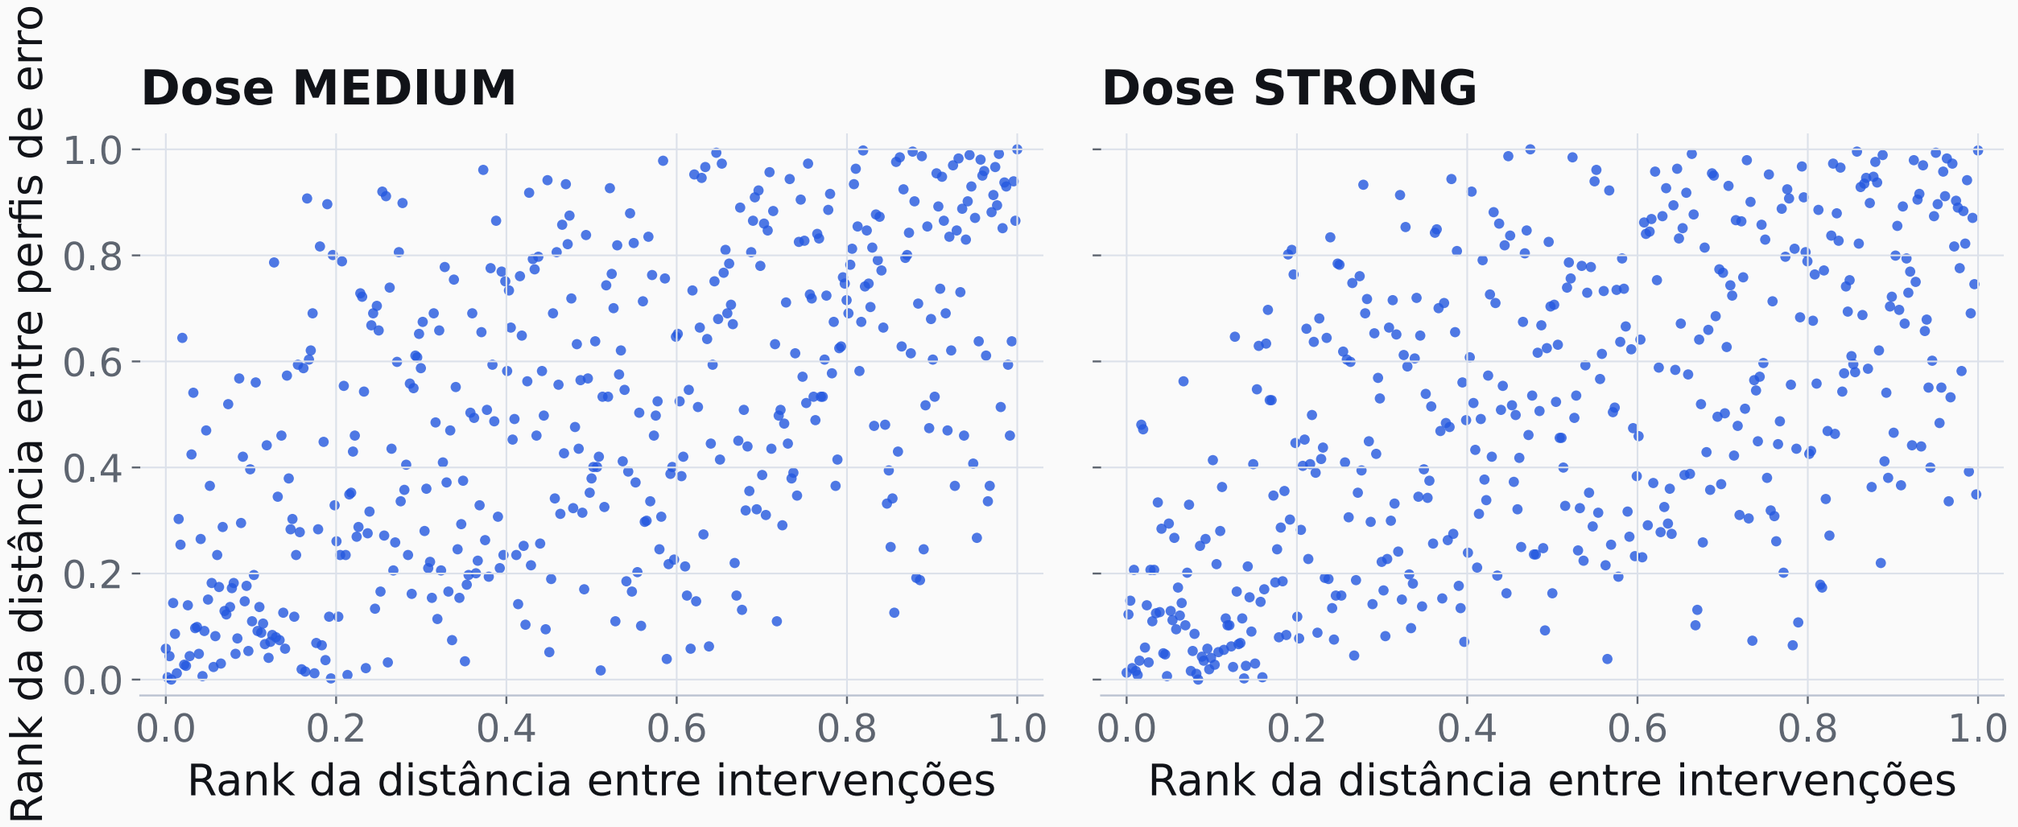
Preditor	Informação utilizada
A0 · coordenadas	Ângulo entre direções de intervenção
A1 · ativações	Geometria ponderada por estatísticas de ativação
A2 · resposta	Relações entre mudanças nas distribuições de saída

> Pré-outcome semântico não significa pré-intervenção.

A2 utiliza resposta label-free a intervenções; não é uma Fisher estimada por derivada infinitesimal.

APROFUNDAR [A1 e A2: construções operacionais]

Q2 · associação no banco histórico



31 direções, 300 problemas, duas repetições por condição. 37.800 gerações. A0 agregado: ρ ≈ 0,564.

APROFUNDAR [Pares compartilham direções]

Validação com direções novas



19.200 gerações. Teste primário por direção nova: 16/16 positivos; p binomial unilateral nominal = 1,53 × 10^{-5}.

APROFUNDAR [Pares compartilham direções] [O diagnóstico do bootstrap]

O alcance da generalização

MUDOU

A identidade da direção de intervenção

PERMANECEU FIXO

Modelo · tarefa · painel de problemas

Camada · subespaço · doses · atlas

> As relações generalizaram dentro desse laboratório. Outras dimensões exigem testes próprios.

Transferência e o comparador textual

ACURÁCIA OBSERVADA

Coleta	Baseline	Steering fixo	Prompt CAREFUL
Q1 · CRUXEval 57 problemas	43,86%	50,00%	73,68%
LiveCodeBench 130 famílias	66,92%	59,62%	72,88%

Acurácias descritivas; uso realizado de tokens não pareado. Em LiveCodeBench, o controlador fixo não passou o critério completo de transferência.

> A vantagem sobre prompting continua sendo uma pergunta experimental.

A etapa da utilidade coletiva

Como escolher ou agregar respostas sem conhecer o gabarito?

Um banco complementar pode oferecer headroom para um oracle.

Seleção realizável exige informação disponível antes da resposta final e avaliação em problemas reservados.

> Os estudos acumulados ainda não demonstram utilidade prospectiva de roteamento.

APROFUNDAR [Mesma distância, ganhos de oracle opostos] [Uma comparação de valor incremental]

Discussão

Que explicação concorrente vale enfrentar primeiro?

Que resultado mudaria nossa interpretação do mapa entre intervenção e erro?

Qual dimensão nova de generalização acrescentaria mais conhecimento?

Os apêndices permitem aprofundar métodos, estimandos e caminhos de pesquisa.