CAUSAL EPISTEMIC GEOMETRY · ACS-USP

Intervenções internas e os erros de um LLM

O que construímos, o que encontramos
e o que ainda precisamos entender

Gabriel · Entropic Session · 16 de outubro de 2026

Quais problemas o modelo erra?

Conseguimos mudar quais problemas um modelo acerta e erra, mantendo seus pesos fixos?

E antecipar essa mudança a partir da intervenção que fazemos?

A mesma acurácia pode esconder erros diferentes

Duas variantes acertam 3 de 6 problemas.

Problema	1	2	3	4	5	6
Variante A	**Acerta**	**Acerta**	**Acerta**	Erra	Erra	Erra
Variante B	**Acerta**	Erra	Erra	**Acerta**	**Acerta**	Erra

Exemplo construído para ilustrar a pergunta

> B resolve alguns erros de A, mas também perde acertos.

Como aproveitar isso sem conhecer o gabarito?

O que queremos descobrir

Mudar os erros	Uma intervenção oferece algo além de repetir o modelo?
Prever a mudança	Intervenções parecidas produzem perfis de erro parecidos?
Usar a diferença	Conseguimos escolher melhor sem consultar o gabarito?

Nos registros do projeto: Q1, Q2 e Q3, respectivamente.

A ESCOLHA EXPERIMENTAL

O que mudamos em cada abordagem

Abordagem	O que alteramos diretamente
Prompt	O texto de entrada. Os pesos ficam fixos.
Steering	O estado interno, somando um vetor: uma lista de ajustes numéricos. Texto da tarefa e pesos ficam fixos.
Ajuste de pesos	Os parâmetros do modelo, por treinamento adicional. LoRA aprende ajustes compartilhando o modelo base.

A adição interna oferece um controle explícito. A vantagem prática sobre bons prompts ainda precisa ser medida.

LoRA é uma comparação proposta, ainda não executada. Prompt e steering podem ser combinados. Como comparar benefício e custo ↗

A tarefa: prever o resultado de um programa

```
def f(a, b, c, d):
    return a and b or c and d
```

Entrada: `'CJU', 'BFS', 'WBYDZPVES', 'Y'`

Resultado de referência: `'BFS'`

Problema real: sample_82, primeira etapa do estudo.

O modelo recebe código e entrada, e escreve o valor de saída.

Usamos o Qwen3-8B, sem treinar seus pesos.

O conjunto CRUXEval reúne esses problemas curtos de Python.

Como decidimos se a resposta está certa

Extraímos o valor final e comparamos com a execução Python.

Resposta entregue	Leitura do avaliador
`FINAL: BFS`	Valor 'BFS': correto no exemplo anterior.
`FINAL: Y`	Valor 'Y': comparável, mas errado.
Sem um valor final identificável	Não há resposta utilizável para comparar.

Na coleção de intervenções, respostas erradas, inválidas e interrompidas pelo limite de geração contam como erro. Registros ausentes bloqueiam a análise.

O que somamos ao estado interno

No modelo usado, cada posição do texto tem um estado com **4.096 números**.
Somamos outro vetor, também com 4.096 componentes.

Estado

$$h = (h_1, h_2, \ldots, h_{4096})$$

$+$

Adição

$$\delta = \alpha \cdot (v_1, v_2, \ldots, v_{4096})$$

$\longrightarrow$ $h + \delta$

v: direção, com comprimento 1

α: intensidade da adição

> A direção define a orientação. A intensidade define quanto adicionamos nessa orientação.

Onde fica a adição: depois do 28º bloco

Usamos a **saída do 28º bloco** do Qwen3-8B. O código começa a contar em zero: esse é o **índice 27**.



L27 nos registros = bloco de índice 27 = 28º bloco na contagem humana

Um **token** é uma unidade de texto. Lemos ou alteramos o estado associado a uma posição, nessa saída.

Como a adição acompanha a geração

Somamos δ na saída do 28º bloco. Os escores após os blocos seguintes dão as chances do próximo token.

Chamada	Entrada	Posição com +δ	Próximo token amostrado
Prompt inteiro	Prompt inteiro x_1 … xP	xP, último token da entrada	g_1
Próximo passo	g_1	Corrente, em g_1	g_2
Passo seguinte	g_2	Corrente, em g_2	g_3

$$h \leftarrow h + \delta \quad \cdot \quad \delta = \alpha v$$

Se a geração continuar, cada token sorteado entra na próxima chamada. A memória de passos anteriores não é reescrita; nova memória pode mudar.

Mesma adição nominal em cada passo. BF16 é a precisão numérica usada; o arredondamento pode mudar o incremento realizado. Adição, linhas 28–109 · Intensidade da primeira intervenção

Primeiro construímos uma direção fixa

Nos mesmos 104 problemas, comparamos duas instruções.

Texto de construção	O que pede
Cuidadoso · CAREFUL	Rastreie operações, valores e caminhos. Confira o resultado.
Direto · DIRECT	Responda imediatamente, sem rastrear ou verificar.

$h_{cuidadoso} - h_{direto}$ → média dos 104 pares → normalização

Lemos o estado no fim do prompt, na saída do 28º bloco. A média normalizada dá o vetor v, de comprimento 1.

32 problemas separados para validação da fonte. Os 57 problemas do teste não constroem o vetor.

O que D75 significa na primeira etapa?

D75 é uma intensidade: 75% de uma escala de referência definida no desenvolvimento.

Somamos a direção multiplicada por esse tamanho, fixo na confirmação. A escala usa a dispersão das projeções de estados ordinários do modelo na direção escolhida.

> Foi a menor intensidade aprovada entre 25%, 50% e 75%, pelos critérios de resposta utilizável, acurácia, mudança de saída e comprimento.

A coleção posterior usa outra referência para a intensidade.

Um perfil reúne chances de erro

A geração é aleatória: o mesmo problema pode ser acertado ou errado em tentativas diferentes.

Duas tentativas	Proporção observada de erros
0 erros	0%
1 erro	50%
2 erros	100%

> Essas proporções não são probabilidades conhecidas. Duas tentativas dão baixa resolução; as medidas usam repetições e vários problemas.

Como as repetições entram

APROFUNDAR Quanto valeria saber qual tentativa acertou? O que muda ao retirar a média? Como medir distância com poucas tentativas?

O que chamamos de complementaridade?

Usando o gabarito, o par acerta se ao menos uma resposta estiver correta.

Referência	Comparação
Duas gerações sem adição	Uma sem adição + uma com adição

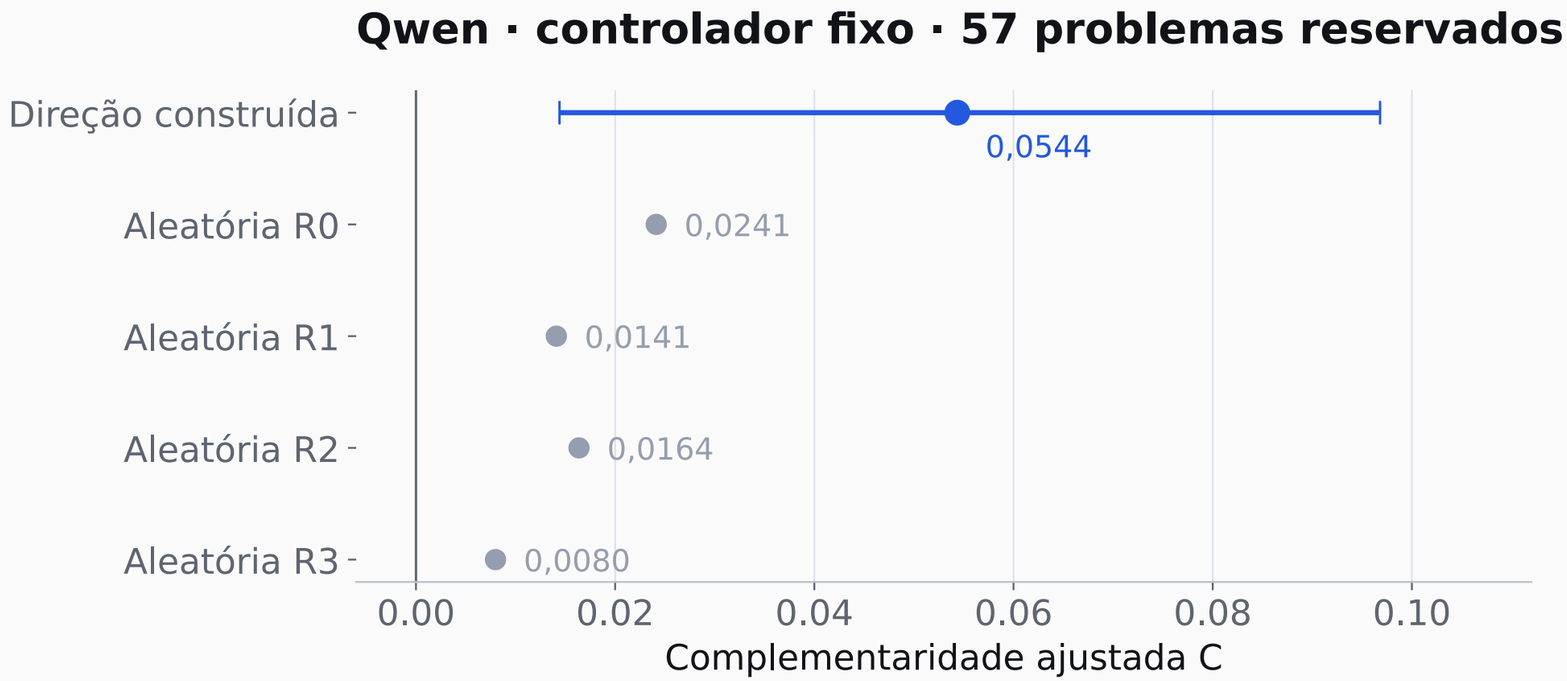
O ganho do par mistura acurácia média e redistribuição dos erros.

> C desconta a parcela da acurácia média, deixando o componente de redistribuição.

Pressuposto: gerações independentes dado o problema. Isso ainda não é uma regra para escolher uma resposta sem gabarito.

Complementaridade no Qwen

Controlador fixo = direção construída. R0–R3 = vetores aleatórios. Barra azul = intervalo de 95%.



57 problemas reservados; duas gerações por condição. C = 0,05435; C – média dos controles = 0,03871.

> A direção passou no Qwen. O segundo modelo, Ministral, falhou no critério de respostas utilizáveis.

APROFUNDAR [Casos observados] [Por que estes controles?]

Para ampliar a coleção: duas receitas

Cada linha pede duas formas de resolver o mesmo problema.

Exemplo de cuidado	Instrução A	Instrução B
Um if/else	Enumere caminhos e confira os retornos.	Siga só o caminho mais aparente.
a e b compartilham uma lista	Registre objetos compartilhados e alterações em ordem.	Trate atualizações localmente, sem registrar compartilhamento.

> São receitas textuais para obter estados diferentes, sem atribuir uma habilidade isolada a cada vetor.

Resumos das instruções reais; exemplos ilustrativos.

Mais duas receitas de construção

Variamos também como conferir laços e saídas candidatas.

Exemplo de cuidado	Instrução A	Instrução B
range(3): 0, 1, 2	Confira início, última iteração, atualizações e parada.	Use o padrão geral, sem auditar os limites.
Duas saídas plausíveis	Mantenha alternativas e elimine as contraditas pela execução.	Aceite a primeira saída plausível.

> Quatro receitas, sempre em pares A/B nos mesmos 24 problemas de construção.

Resumos das instruções reais. Há outros 24 problemas para validar as fontes.

De onde lemos os estados

No mesmo problema, lemos o estado após cada instrução A/B, na saída do 28º bloco. Os prompts podem ter comprimentos diferentes.

Posição	O que lemos em A	O que lemos em B
Fim do prompt	h^A no último token da entrada	h^B no último token da entrada
Fim da frase fornecida	h^A após a frase fixa	h^B após a mesma frase

Frase fornecida · não é uma resposta livre

I will now apply the requested reasoning policy to the program before committing to one answer.

Uma passagem completa sem cache por instrução. h é o estado com 4096 números nessa posição.

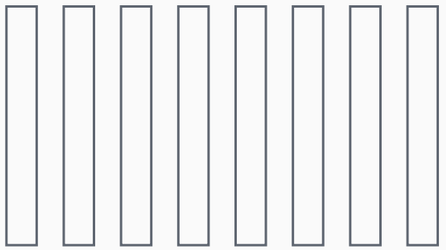
Quatro receitas × duas posições = oito vetores-fonte. Aqui lemos estados; na avaliação somamos vetores. Esquema de posições, sem tokens reais. Captura, linhas 259–302

Dos oito vetores a uma base comum

Para cada receita e posição: média das diferenças em 24 problemas, depois normalização para comprimento 1.

$$d_i = h_i^{A} - h_i^{B} \quad \rightarrow \quad \bar{d} = \text{média}(d_i) \quad \rightarrow \quad u = \bar{d} / \|\bar{d}\|$$

8 vetores-fonte: colunas de U

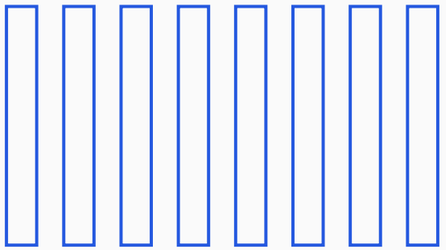


4 receitas × 2 posições

SVD

Decomposição em valores singulares

8 colunas de Q



4096 linhas; 8 colunas

> O posto observado foi 8. Q tem colunas de comprimento 1, perpendiculares entre si: uma base do mesmo espaço.

Como produzimos novas direções nesse espaço

Uma nova direção combina as oito colunas de Q, com pesos positivos ou negativos.

8 pesos: $c_1 \ldots c_8$ — Base já construída — Direção no modelo

$$c \longrightarrow Q \times c \longrightarrow v = Qc$$

c tem 8 números

v tem 4096 números

Para obter c, sorteamos oito números independentes da normal padrão e normalizamos o conjunto:

$$g \sim N(0, I_8) \rightarrow c = g / \|g\| \rightarrow v = Qc$$

Orientações distribuídas uniformemente dentro desse espaço, antes dos filtros. Coordenadas não nomeiam conceitos.

Como fechamos a coleção de direções

Chamamos de **banco** a coleção de vetores disponíveis para adicionar ao mesmo modelo.

40 vetores candidatos

Um único sorteio

→

Filtros fixos

Respostas utilizáveis

e intervenção realizada

→

31

retidos

Os filtros verificam formato, interpretação da saída, interrupção, mudança textual e amplitude, sem consultar acertos.

> Não substituímos os rejeitados. Estudamos as 31 direções que qualificaram, não todas as orientações possíveis.

Mesma direção, duas intensidades

Calibramos dois tamanhos de adição contra uma referência fixa do estado sem intervenção.

Alvo Q2	Norma do vetor adicionado ÷ referência
0,25 · menor	0,25
0,50 · maior	0,50

Referência = raiz da média de $||h||^2$, congelada em 12 prompts de calibração. h é o estado sem adição.

> 31 direções × 2 intensidades + modelo original = 63 condições.

α é calibrado por direção e alvo; fica fixo na geração. D75 usa outra escala. O arredondamento numérico pode mudar o incremento efetivo.

Como comparar dois perfis de erro?

Perfil: chance de errar cada problema.

Condição	Problema 1	Problema 2	Erro médio
Referência	20%	80%	50%
Variante	40%	60%	50%

Exemplo construído

A média é igual, mas a distribuição entre problemas mudou.

> Chamamos de D^{shape} a distância de forma, que retira a diferença média.

No estudo: duas gerações por condição; estimativas com baixa resolução.

Três maneiras de comparar as intervenções

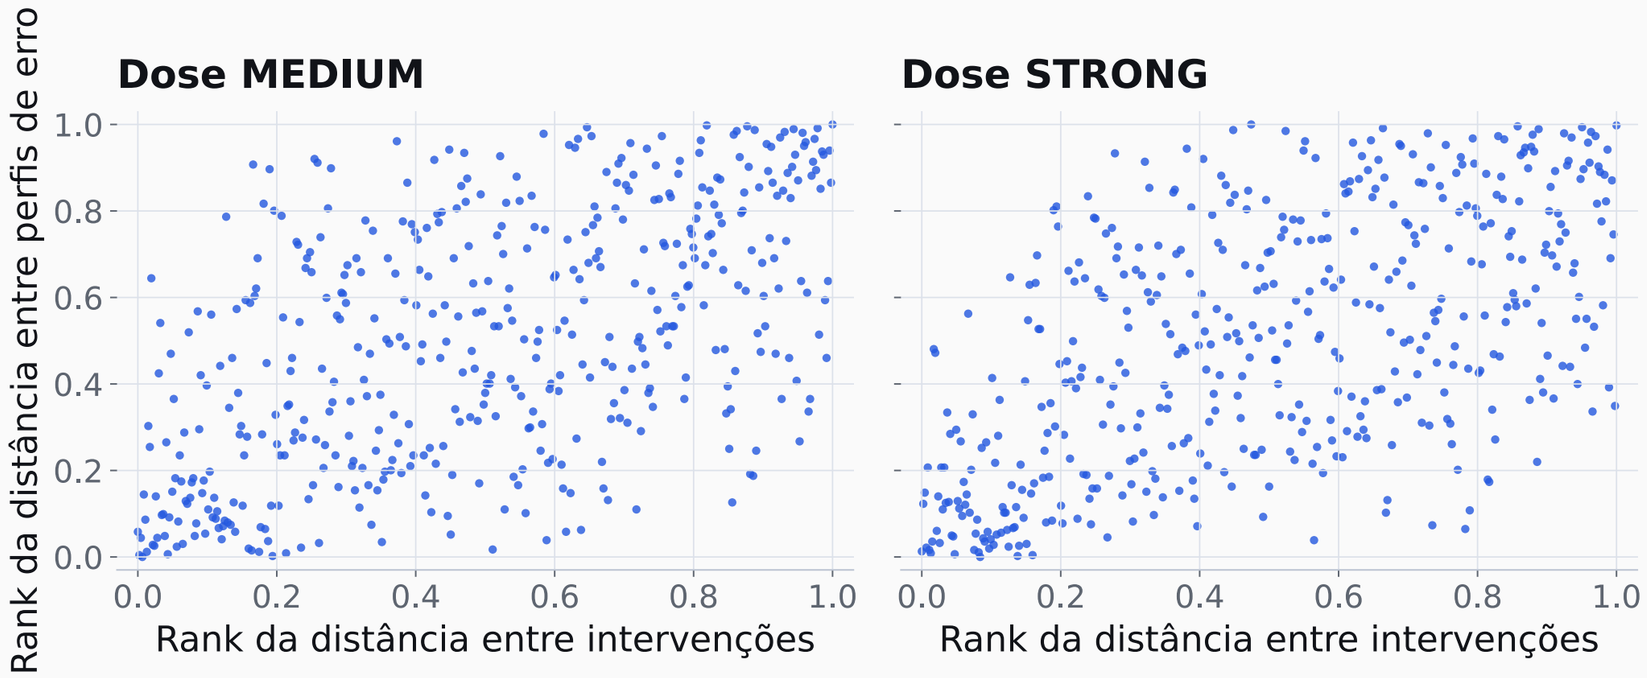
Medida	Como comparamos
A0 · vetores	Ângulo entre as direções adicionadas.
A1 · estados internos	Ângulo com coordenadas ajustadas à variação habitual dos estados internos.
A2 · respostas probabilísticas	Ângulo entre mudanças nas probabilidades do próximo token.

> Foram fixadas antes de analisar os erros do painel. A2 exige executar intervenções, mas não consulta o gabarito.

APROFUNDAR [O que A1 e A2 acrescentam ao ângulo comum?]

Ângulo dos vetores e diferenças nos erros

Cada ponto é um par. Rank = ordem. Doses MEDIUM/STRONG = adições de intensidade 0,25/0,50.



Horizontal: ângulo dos vetores, A0. Vertical: distância de forma dos erros, D^{shape}. Associação média entre ordens: 0,564.

> Os 465 pares compartilham 31 direções; não são observações independentes.

APROFUNDAR [Por que 465 pares não são casos independentes?]

O teste com direções novas

Mantemos o espaço de oito dimensões e as duas intensidades. Trocamos os vetores.

Para cada direção nova	Procedimento
Comparar com as 31 originais	31 distâncias entre vetores versus 31 distâncias entre perfis de erro.
Obter um resultado	Calcular a associação em cada intensidade e fazer a média.

> O gráfico seguinte mostra um resultado por direção nova.

34 candidatas em um único fluxo, 26 qualificadas, primeiras 16 retidas. Seleção sem consultar acertos.

O padrão se repetiu em direções novas

Uma barra por nova direção. Atlas = 31 referências. A altura, r_i, é a associação média nas duas intensidades.



16/16 associações positivas. Teste de sinais: p unilateral nominal = $1{,}53 \times 10^{-5}$.

> Unidade do teste: direção qualificada. As referências e os problemas são compartilhados; 19.200 gerações não são unidades independentes.

APROFUNDAR [Por que 465 pares não são casos independentes?] [Reamostrar problemas cria novas respostas?]

O alcance do teste com novas direções

Variou	Permaneceu igual
As direções adicionadas	Modelo, tarefa e 300 problemas
Novas identidades	Bloco de aplicação, espaço de misturas, duas intensidades e 31 referências

> O resultado generaliza para direções novas nesse laboratório. Não testa tarefas novas nem garante prever cada resposta.

Estratégia semântica específica e resposta genérica às perturbações continuam explicações a distinguir.

O texto também é um comparador forte

Acurácia observada em duas coletas distintas:

Coleta	Sem adição	Adição fixa	Instrução detalhada
CRUXEval 57 problemas	43,86%	50,00%	73,68%
LiveCodeBench 130 grupos de casos	66,92%	59,62%	72,88%

A adição fixa não passou os critérios completos na tarefa nova.

> A instrução teve maior acurácia observada. Custos não foram igualados; isso não é um teste de superioridade.

O espaço construído teve uma vantagem especial?

Um piloto manteve a estrutura das direções e comparou três orientações do espaço interno.

Orientação	Associação entre distâncias
Construída das instruções	0,418
Aleatória 1	0,018
Aleatória 2	0,248

> O critério pré-definido ficou inconclusivo. O tamanho da mudança de erros e sua repetibilidade diferiram; só duas orientações aleatórias foram comparadas.

APROFUNDAR [Por que estes controles?]

Escolher a configuração trouxe ganhos em desenvolvimento

Seletor: escolhe a configuração antes da resposta, sem gabarito. Dados já expostos.

Desenho	Ganho em pontos percentuais
Escolha por problema	+5,33
Seletor em um conjunto de 8 variantes	+4

Comparador de cada estudo: sua melhor configuração fixa, escolhida na parte de treino de cada divisão dos dados.

> No primeiro estudo, informar também a geometria ao seletor acrescentou 0,33 ponto. O mínimo exigido era 1 ponto.

APROFUNDAR [A mesma distância garante o mesmo ganho?] [Como comparar steering, prompts e ajuste de pesos?]

A confirmação em problemas novos não foi aberta

Primeiro, o instrumento precisava passar critérios obrigatórios.

Critério	Observado	Exigido
Acerto da configuração fixa	13,33%	≥25%
Oportunidade observada com gabarito	1,5 ponto percentual	≥5 pontos percentuais

São dois exemplos de quatro critérios que falharam.

> Instrumento não qualificado; confirmação não realizada. Isso não demonstra ausência de benefício.

Por que o desenho precisou mudar

Dificuldade encontrada	O que mudamos
O formato escrito confundia a correção.	Passamos a comparar o valor final interpretado.
Separar instruções não garantia um efeito útil.	Testamos também onde, quanto e por quanto tempo adicionar o vetor.
Poucas intervenções limitavam a comparação.	Construímos uma coleção e fixamos regras antes dos acertos.
A relação podia depender das direções já vistas.	Reservamos novas direções para testar a previsão.

Os apoios documentam as mudanças de desenho, os resultados que limitaram a hipótese e a sistemática de registro.

APROFUNDAR [O trabalho mudou o que precisava ser testado]

O que vale testar a seguir?

Que observação distinguiria uma estrutura especial dos erros de uma resposta genérica à perturbação?

E que ganho justificaria usar steering junto de bons prompts?

Dois casos observados: acertos ganhos e perdidos

Problema	Modelo original	Adição interna	Instrução cuidadosa
Operadores and/or sample_82	0 / 2	2 / 2	2 / 2
Troca de maiúsculas e minúsculas sample_298	2 / 2	0 / 2	1 / 2

Acertos em duas tentativas por condição

> A intervenção pode recuperar respostas e perder outras.

Casos escolhidos depois de observar os resultados. Duas tentativas não estimam com precisão a chance de acerto de cada problema.

A medida mais elaborada não superou as simples

Associação entre a ordem das distâncias internas e das distâncias de erro:

Medida	Associação média
A0 · ângulo dos vetores	0,564
A1 · ângulo ajustado	0,556
A2 · resposta probabilística	0,441

Todas passaram os critérios de associação.

> A2 não passou a exigência adicional de superioridade. Observar uma associação não basta para demonstrar vantagem incremental.

Mais mudança de perfil não significou mais acertos

Nas 31 direções, a intensidade maior produziu maior distância de forma frente à referência.

Configuração	Acurácia média
Sem adição	45,50%
Intensidade menor · 0,25	46,76%
Intensidade maior · 0,50	44,96%

> A intensidade controla o tamanho da adição; não garante melhora de acurácia. Dois níveis não estabelecem uma curva geral.

Uma resposta simples já pode criar geometria?

Imagine que pequenas mudanças na intervenção alterem quase linearmente a chance de erro de cada problema.

$$q_i(c) \approx q_i(0) + b_i^T c$$

q_i: chance de erro; **0**: sem adição; **c**: coordenadas da intervenção; **b_i**: sensibilidade daquele problema.

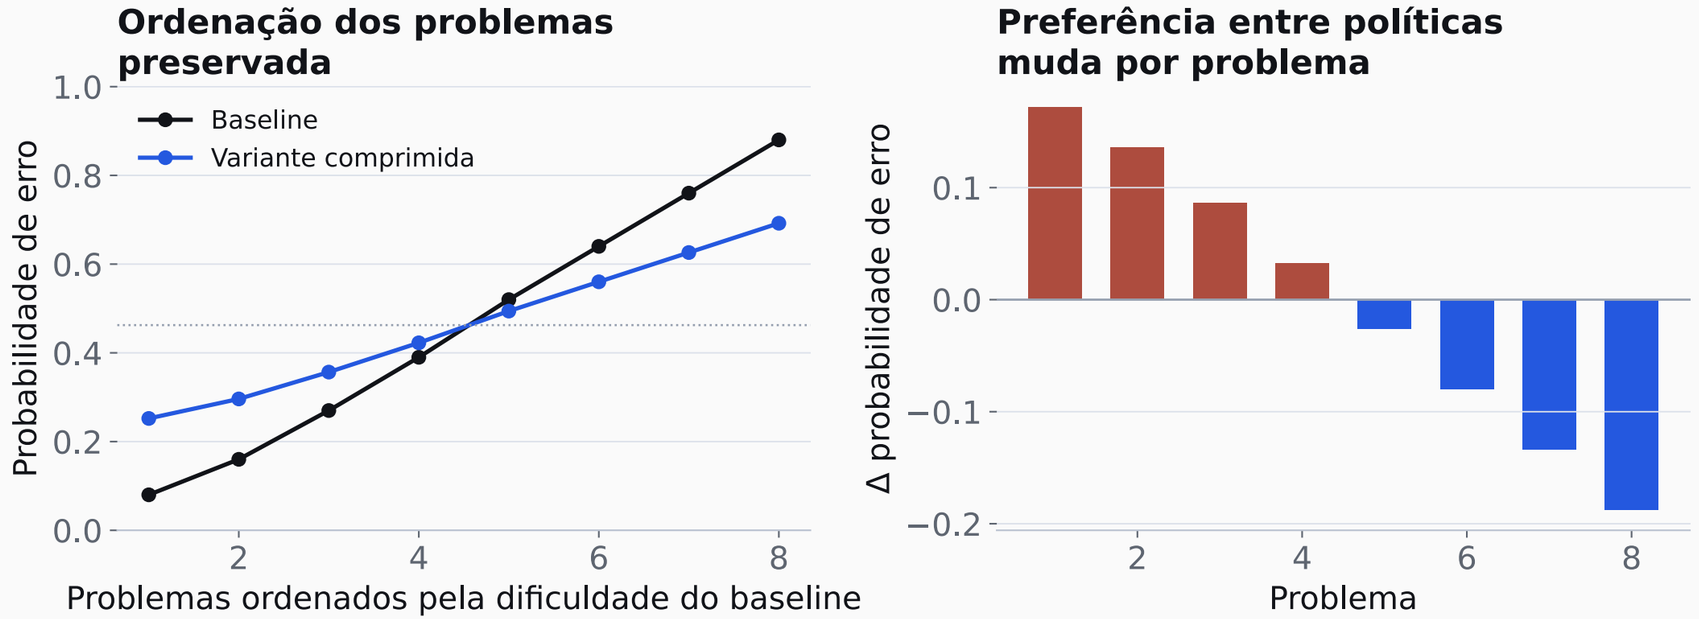
> Com sensibilidades igualmente distribuídas nas orientações, o ângulo já prevê a distância de forma.

Modelo reduzido; ainda não validado como explicação dos resultados.

APROFUNDAR [Um exemplo em que o ângulo funciona exatamente]

Complementaridade exige inverter a dificuldade?

Neste exemplo construído, a variante aproxima as chances de erro de sua média, sem mudar essa média nem a ordem de dificuldade.



q é a chance de erro. A variante piora os problemas fáceis e melhora os difíceis. Duas tentativas independentes dado o problema.

> Aqui, com médias iguais, C positivo é ganho da seleção com gabarito; não identifica habilidade específica.

APROFUNDAR [Quanto valeria saber qual tentativa acertou?] [A mesma distância garante o mesmo ganho?]

O que o trabalho já tornou mais preciso?

O que conta como resposta	Comparar o valor final, além do formato escrito.
Como intervir	Separar orientação, tamanho da adição e duração.
O que prever	Relações entre perfis de erro, além da acurácia média.
Até onde foi testado	Novas direções no mesmo modelo, tarefa e painel.

> Segue aberto por que o padrão aparece, se passa para outros contextos e como aproveitar a diferença sem gabarito.

APROFUNDAR [O trabalho mudou o que precisava ser testado] [O que as linhas posteriores ainda não resolveram]

Qual pergunta merece a próxima etapa?

Três caminhos, com requisitos diferentes:

Caminho	Pergunta
Explicar o padrão	Uma resposta simples à perturbação prevê o que observamos?
Testar o alcance	As relações persistem ao mudar problemas, tarefa ou modelo?
Usar as diferenças	Escolher uma variante antes de gerar melhora decisões sob um orçamento definido?

> São perguntas para discussão, sem prioridade ou novidade estabelecida.

APROFUNDAR [O que poderia virar uma contribuição?]

Quanto valeria saber qual tentativa acertou?

Com gabarito, aceite um acerto entre duas tentativas. Compare repetir o original com original + variante.

$$G = C + \mu_0(\mu_0 - \mu_j)$$

G: ganho de acerto; μ_0, μ_j: médias de erro; **C**: parcela do ganho além do termo das médias.

> Médias iguais: G = C. É uma oportunidade retrospectiva, sem regra de escolha utilizável.

Suposição: tentativas independentes dado o problema.

O que muda ao retirar a média?

Original: q_0. Variante: $q_j = 0{,}5 + m + a(q_0 - 0{,}5)$. m muda a média; a muda escala e sinal. Aqui, m = 0,00 e a = 0,00.

Perfis de erro

Versão	1	2	3	4
Original	0,20	0,40	0,60	0,80
Variante	0,50	0,50	0,50	0,50

Após subtrair cada média

Versão	1	2	3	4
Original – sua média	-0,30	-0,10	0,10	0,30
Variante – sua média	0,00	0,00	0,00	0,00

$$D_{total} = (1/n)\ \Sigma_i\ [q_j(i) - q_0(i)]^2$$

$D_{shape} = (1/n)\ \Sigma_i\ [(q_j(i) - \mu_j) - (q_0(i) - \mu_0)]^2$; i é o problema; n = 4

$$D_{total} = D_{shape} + (\mu_j - \mu_0)^2 = 0{,}0500 + 0{,}0000 = 0{,}0500$$

Erro médio original (μ_o): 0,50; variante (μ_j): 0,50. Dispersão original: 0,0500; variante: 0,0000. Dispersão é a média dos desvios ao quadrado; aqui, usamos divisor 4. Retirar a média preserva escala e sinal.

Quatro problemas com pesos iguais. μ é a média. D_{total} compara perfis; D_{shape} compara perfis centrados. Centrar mantém escala e sinal. Dispersão é a média dos desvios ao quadrado, com divisor 4. Definições de distância

Como medir distância com poucas tentativas?

Em cada problema, cada condição produz erro **1** ou acerto **0**. Repetimos a geração em dois blocos independentes.

$$\mathrm{E}[\delta_1\delta_2 \mid \text{problema}] = (q_j - q_k)^2$$

δ é a diferença entre os erros observados das condições em um bloco; **q** é sua chance de erro.

> O produto retira o viés do quadrado de uma só observação. Duas tentativas ainda deixam muita incerteza.

Por que 465 pares não são casos independentes?

31 direções → 465 pares

Os pares (1,2), (1,3) e (1,4) compartilham a direção 1.

Para testar a relação entre dois mapas de distâncias, trocamos as identidades das direções em um deles. Todas as relações de uma direção se movem juntas.

> Esse teste é a permutação relacional, chamada QAP. Não transforma pares em réplicas independentes nem demonstra generalização externa.

Reamostrar problemas cria novas respostas?

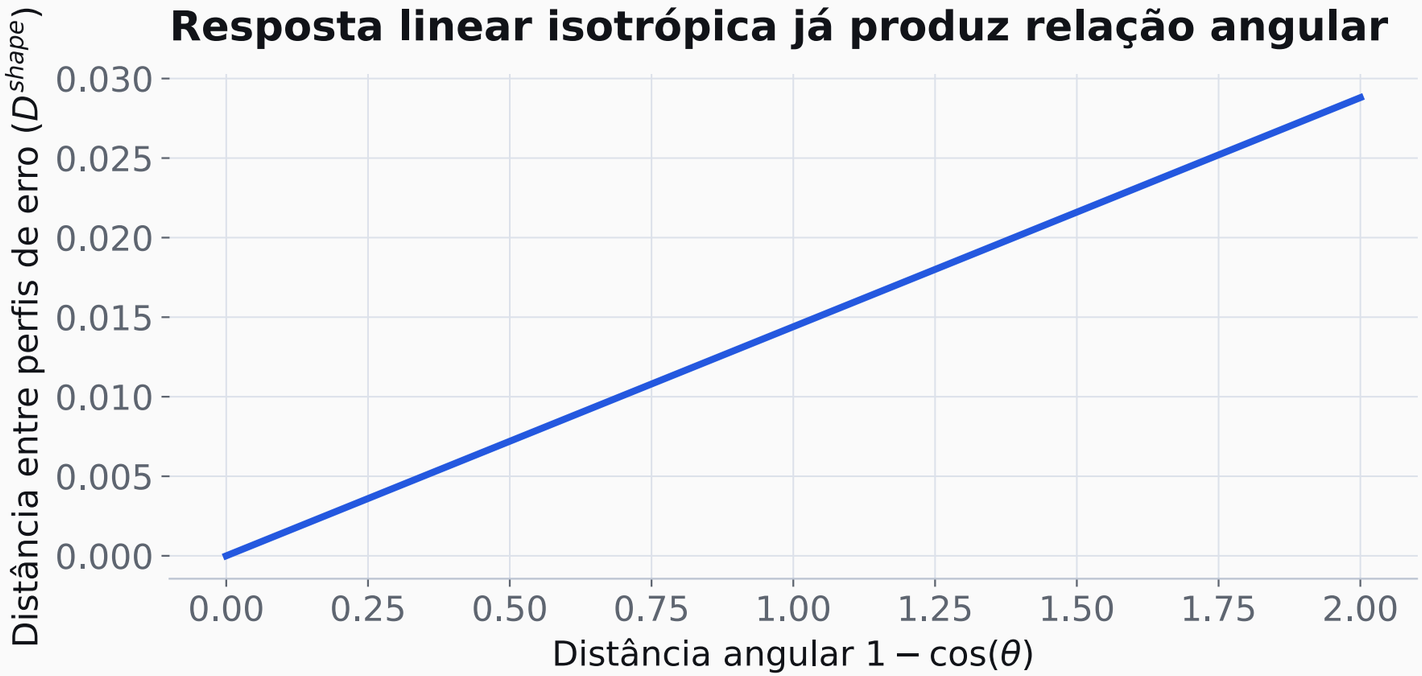
Não. Com duas tentativas por condição e problema, repetir um item na reamostragem reutiliza suas mesmas respostas.

O bootstrap muda o peso dos problemas e recalcula a relação. Nos diagnósticos deste estimador relacional, seus percentis não sustentaram a interpretação como intervalo de confiança convencional.

> Ficou como análise de sensibilidade à composição do painel. O teste principal das 16 direções novas é separado.

Um exemplo em que o ângulo funciona exatamente

Quatro problemas construídos têm chances de erro que variam linearmente em duas coordenadas de intervenção.



O eixo horizontal compara ângulos; o vertical, perfis depois de retirar suas médias.

> A relação vem da construção matemática. Não é ajuste aos dados CEG nem explicação validada do modelo real.

Como comparar steering, prompts e ajuste de pesos?

Proposta ainda não executada: original, bons prompts, steering, ambos e LoRA.

- Mesma distribuição de problemas e avaliação reservada.
- Contar desenvolvimento, seleção e geração no orçamento relevante.
- Medir uma decisão utilizável, sem consultar o gabarito.

> LoRA aprende pequenos ajustes nos pesos. Nenhuma abordagem é presumida mais barata ou superior; repetir o original também entra na comparação.

O que poderia virar uma contribuição?

São possibilidades diferentes para o mesmo programa:

Possibilidade	O que precisaria sustentar
Evidência empírica	Uma relação delimitada, testada em novas direções.
Explicação	Previsões que diferenciem mecanismos, além da forma quadrática conhecida.
Utilidade	Uma escolha realizável que acrescente ganho frente a bons comparadores.

> Precisam ser confrontadas com a literatura e os limites dos testes. Não estabelecem novidade, prioridade ou aceitação.

Três estados que não podemos misturar

Estado	Significado
Negativo sob a regra	O teste terminou e não atendeu seu critério.
Inconclusivo	A evidência não separa as explicações.
Não avaliado	A comparação pretendida não foi completada.

A mesma intervenção na tarefa nova falhou o critério. A especificidade geométrica ficou inconclusiva. Na etapa de uso, a avaliação não passou as condições mínimas e a confirmação não começou.

> Falha operacional não prova ausência do fenômeno.

Cada controle enfrenta uma dúvida diferente

Comparador	Dúvida
Repetir o original	Quanto muda só por sortear outra resposta?
Prompt cuidadoso	O texto de origem já oferece benefício?
Quatro direções controle	Outras direções, com o mesmo tamanho e local, também funcionam?
Espaços alternativos	A relação Q2 depende do espaço construído?

> Q1 compara um controlador fixo com direções aleatórias; o piloto posterior troca o espaço inteiro. São objetos e limites diferentes.

O que A1 e A2 acrescentam ao ângulo comum?

Comparamos intervenções antes de consultar os acertos.

A1: ângulo reponderado	64 estados internos sem adição dão pesos às coordenadas conforme suas variações e correlações.
A2: efeito nos próximos tokens	12 textos, cada um em 4 posições fixas, comparam as mudanças nas distribuições sobre o próximo token.

Em A2, o ângulo relaciona deslocamentos em relação ao original. As probabilidades usam o vocabulário completo, antes dos filtros de amostragem.

> Isso não mede a geometria de toda a geração nem garante acerto final.

O trabalho mudou o que precisava ser testado

Dificuldade	Mudança de desenho
Distinguir formatos	Comparar o valor final da resposta.
Encontrar um efeito	Separar posição, tamanho e duração da adição.
Comparar poucas estratégias	Criar muitas direções num espaço definido.
Explicar um conjunto já visto	Congelar previsões e avaliar novas direções.

> Foram testes e dificuldades sucessivas. Há sucessos delimitados, resultados negativos e instrumentos que não qualificaram; os registros completos ficam nas notas e no guia.

O que as linhas posteriores ainda não resolveram

Pergunta	Estado
Maior intensidade só amplia o efeito?	Uma única escala de resposta não captura tudo; inversões na ordem dos problemas não demonstradas.
Limitar a geração explica o ganho?	Estudo posterior com raciocínio habilitado: inconclusivo.
Quando aparece a resposta final?	Plano e implementação, sem resultado estabelecido.

> São regimes e perguntas diferentes. Não ampliam retroativamente o resultado entre direções nem mostram por que ele ocorre ou se o comprimento gerado explica o ganho.

A mesma distância garante o mesmo ganho?

Dois problemas com pesos iguais; s = 0,20. Todas as médias de erro são 0,50.

Versão	Chances de erro	D_{shape} ao original	C	Acerto com gabarito
Original	(0,20; 0,80)	—	—	66%
A	(0,40; 0,60)	0,0400	+0,0600	72%
B	(0,00; 1,00)	0,0400	-0,0600	60%

$$C = \tfrac{1}{2}\,[D_{shape} + \text{dispersão do original} - \text{dispersão da variante}]$$

Dispersão: média dos desvios ao quadrado, com divisor 2. Com médias iguais, C é o ganho da seleção com gabarito. Original usa duas chamadas; A/B usam original + variante.

A seleção com gabarito aceita qualquer tentativa correta. Precisamos de outra regra para escolher sem o gabarito.

D_{shape}: distância após retirar as médias. C: complementaridade relativa ao original. Seleção com gabarito após gerar. Duas chamadas independentes dado o problema. Exemplo exato e identidade