CAUSAL EPISTEMIC GEOMETRY · ACS-USP

# Intervenções internas e a estrutura dos erros de um LLM

## Resultados, limites e perguntas para continuar investigando

Gabriel · Entropic Session · 16 de outubro de 2026

# Controle dos perfis de erro

## Até que ponto conseguimos controlar e prever quais problemas um modelo congelado acerta e erra?

O objeto é um perfil de desempenho por problema, sob uma política de geração definida.

> A mesma acurácia média pode acompanhar perfis de erro diferentes.

# Três perguntas do programa

| | |
|---|---|
| **Controle** | Uma intervenção muda quais problemas falham, além de repetir o baseline? |
| **Geometria** | Relações entre intervenções antecipam relações entre perfis de erro? |
| **Utilidade** | Um mecanismo realizável consegue aproveitar essa complementaridade? |

Cada pergunta tem uma unidade de análise e um teste próprio.

# O que a evidência atual sustenta

**16 / 16**

direções novas com associação geométrica positiva frente ao atlas histórico

Há controle de perfil no teste confirmatório do Qwen.

Há estrutura relacional no banco e em direções novas.

> Generalidade entre tarefas, especificidade do espaço e ganho coletivo permanecem delimitados ou abertos.

# Steering, prompting e adaptação dos pesos

| Intervenção | O que variamos | Pergunta relevante |
|---|---|---|
| Prompt | Instrução e contexto | Quanto os bons prompts já conseguem? |
| Steering | Direção, dose, site e duração | O controle interno acrescenta algo útil? |
| Fine-tuning / LoRA | Uma adaptação aprendida | Como comparar benefício e custo total? |

> Steering permite controlar uma adição interna, mantendo o prompt de avaliação fixo.
> Superioridade prática exige comparação.

APROFUNDAR [Uma comparação de valor incremental]

# Como o desenho foi ficando mais preciso

| Problema encontrado | Resposta experimental |
| --- | --- |
| Artefatos da superfície de resposta | Revisão do instrumento e avaliação semântica |
| Origem, aplicação e persistência do vetor | Testes de source, camada, dose e duração |
| Intensidade podia explicar a associação | Doses calibradas e pergunta angular |
| Poucas unidades do lado das intervenções | Subespaço e banco de direções amostradas |
| Relação restrita às identidades conhecidas | Validação prospectiva com direções novas |

APROFUNDAR [Quatro mudanças de desenho que custaram trabalho]

# O laboratório experimental

## Qwen3-8B congelado

Predição de saídas de programas Python no CRUXEval

Correção objetiva após avaliação semântica do valor final

**Q2:** painel fixo de 300 problemas

Mesma camada, prompt de tarefa, avaliação e política de geração entre condições

> O Q2 final usa `enable_thinking=false`.

# Respostas observadas no mesmo problema

```
def f(a, b, c, d):
    return a and b or c and d
```

Input: `'CJU', 'BFS', 'WBYDZPVES', 'Y'`

Referência: `'BFS'`

| Condição | Tentativa 1 | Tentativa 2 |
|---|---|---|
| Baseline | `Y` | `CJU` |
| Steering D75 | `BFS` | `'BFS'` |
| Prompt CAREFUL | `BFS` | `'BFS'` |

> O prompt também acertou este caso. Há casos observados no sentido inverso.

Qwen, Q1 · sample_82 · seleção pós-hoc · duas gerações por condição.

# Uma resposta precisa passar por três perguntas

| | |
|---|---|
| **Compromisso** | O modelo entregou um valor final identificável? |
| **Avaliabilidade** | Esse valor pode ser interpretado pelo contrato semântico? |
| **Correção** | O valor corresponde à execução de referência? |

O Q2 conta respostas erradas, inválidas e truncadas como erro; linhas ausentes bloqueiam a análise.

# A direção confirmatória de Q1

$$v = \text{unit}\,[\,\text{média de } 104 \text{ contrastes CAREFUL} - \text{DIRECT}\,]$$

- Mesmos problemas nas duas condições de fonte
- Captura no último token do prompt, saída de L27
- 32 itens separados para validar a fonte
- Sem usar correção ou respostas geradas para estimar v
- D75: 75% da dose histórica, após calibração em desenvolvimento

> Esta direção é anterior e distinta das oito fontes do Q2.

# Quatro contrastes de instruções

| Família | Política positiva | Política negativa |
|---|---|---|
| Fluxo de controle | Enumerar e reconciliar caminhos | Seguir o caminho mais aparente |
| Mutação e aliasing | Acompanhar alterações e referências | Tratar atualizações localmente |
| Fronteiras de loops | Auditar iterações e término | Seguir o padrão geral |
| Hipóteses | Manter e eliminar candidatos | Assumir o primeiro plausível |

Paráfrases para leitura. Os prompts completos e seus bytes definem o experimento.

APROFUNDAR [A direção confirmatória de Q1]

# Duas posições de captura

**PROMPT BOUNDARY**

Último token do prompt renderizado

**EXECUTION BOUNDARY**

Último token de uma continuação fixa, por teacher forcing

> I will now apply the requested reasoning policy to the program before committing to one answer.

Quatro contrastes × duas posições = oito estimadores de direção.

# Das ativações ao subespaço de intervenção

$$u_{f,s} = \text{unit}\left[\ \text{média}_i\ (h^{+}_{i,f,s} - h^{-}_{i,f,s})\ \right]$$

Oito vetores em $\mathbb{R}^{4096}$ formam uma matriz de posto 8.

$$U = L\Sigma R^{T} \qquad Q^{T}Q = I \qquad v_j = Qc_j$$

Amostramos $c_j$ unitários dentro desse espaço.

> As direções novas são combinações no subespaço; 31 direções não significam 31 conceitos.

APROFUNDAR [A1 e A2: construções operacionais]

# Site, dose e duração

δ é uma adição na saída de L27. Os logits após os blocos seguintes definem a distribuição de amostragem.

| Chamada | Entrada | Posição com +δ | Próximo token amostrado |
|---|---|---|---|
| **Prefill** | Prompt inteiro $x_1$ … xP | xP, último não-padding | $g_1$ |
| **Decode 1** | $g_1$ | Corrente, em $g_1$ | $g_2$ |
| **Decode 2** | $g_2$ | Corrente, em $g_2$ | $g_3$ |

$$h^{(27)}_p \leftarrow h^{(27)}_p + \alpha_{j,s} v_j$$

As chamadas decode ocorrem se a geração continuar. O hook não reescreve K/V já calculados em L27. Os blocos seguintes podem mudar o cache produzido adiante.

**δ nominal fixo por condição.** Em BF16, o incremento realizado pode variar com o estado. Q2: alvos 0,25 e 0,50 com RMS baseline congelado. Regime serial, batch 1, com cache qualificado. Hook L27, linhas 28–109 · D75: seleção da dose

# A formação do banco de direções

## 40 → 31

Uma amostra de candidatos; 31 passaram os critérios de integridade nas duas doses.

O banco foi fixado antes da avaliação semântica do painel.

> A análise é condicional às direções qualificadas nesse subespaço.

31 direções × 2 doses + baseline = 63 condições

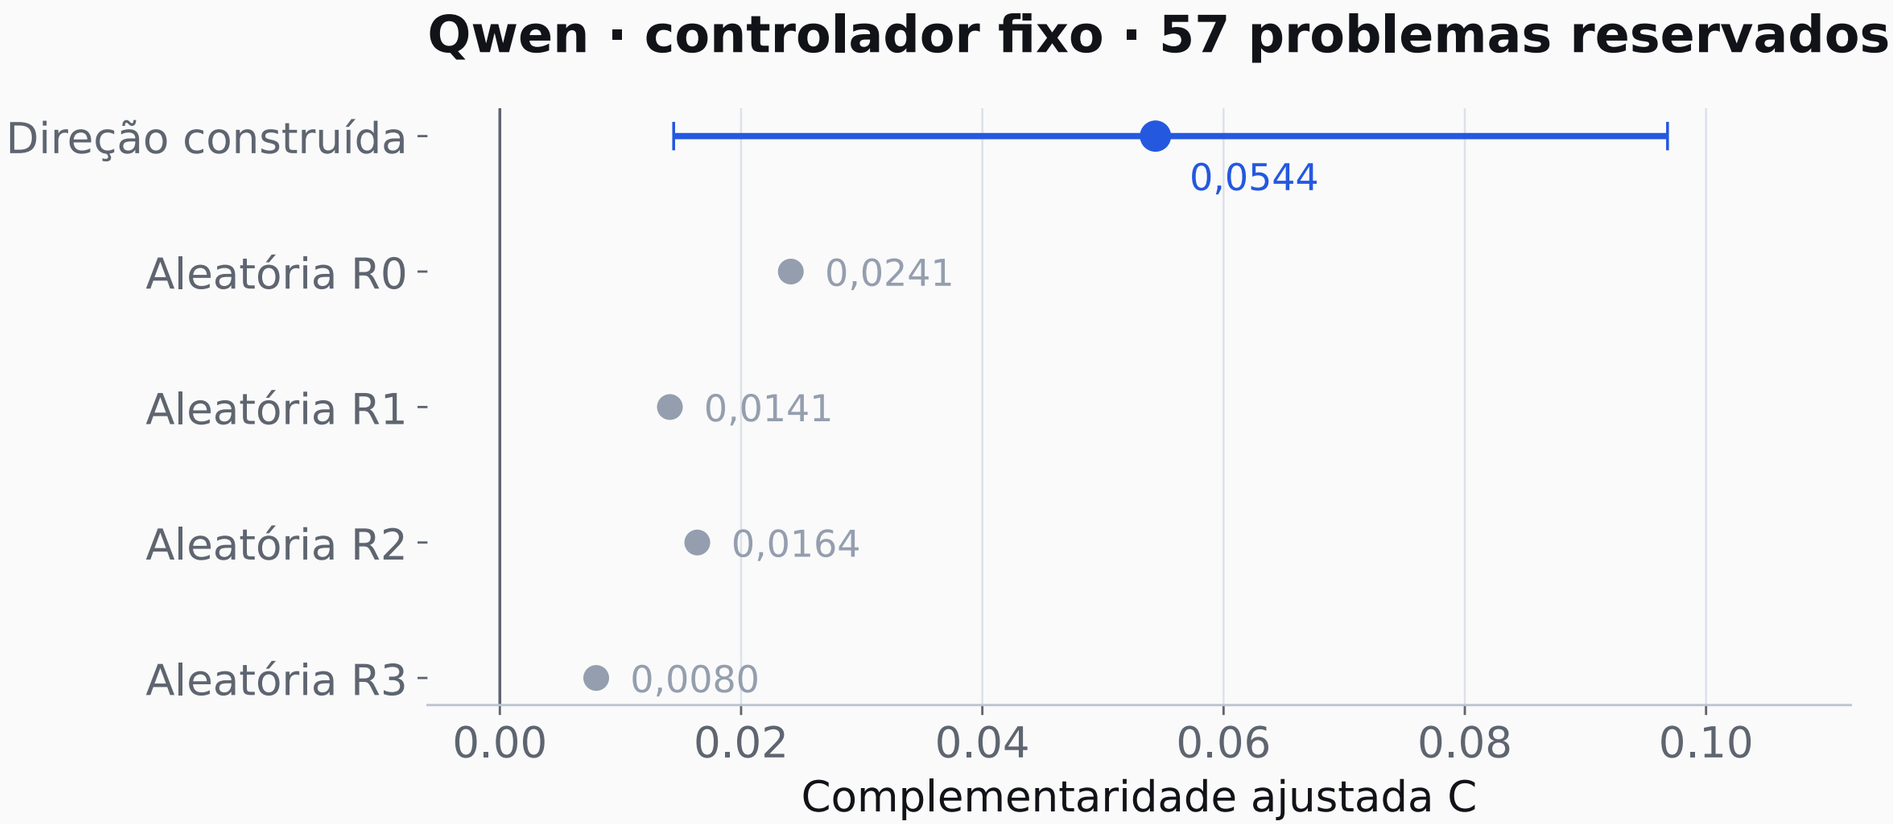
# O que medimos em cada problema

## $q_j(i)$: probabilidade de erro da condição j no problema i

| Quantidade | Pergunta |
|---|---|
| Acurácia média | A condição acerta mais no painel? |
| Rescue / damage | Que acertos ganhamos e perdemos frente ao baseline? |
| Complementaridade C | Qual componente da mudança excede a diferença média de competência? |
| $D^{shape}$ | Quanto a forma do perfil muda, removendo seu deslocamento médio? |

APROFUNDAR Oracle, competência e complementaridade · Distância total e mudança de forma · Por que duas repetições entram no estimador

# Q1 · complementaridade no controlador fixo




Qwen, 57 problemas reservados. Acurácia: 43,86% → 50,00%. Contraste C – média dos controles: 0,03871.

APROFUNDAR [Respostas observadas no mesmo problema] [A direção confirmatória de Q1] [D75: o que foi selecionado, e por quê] [Que pergunta cada controle responde?]

# Geometrias definidas antes dos acertos

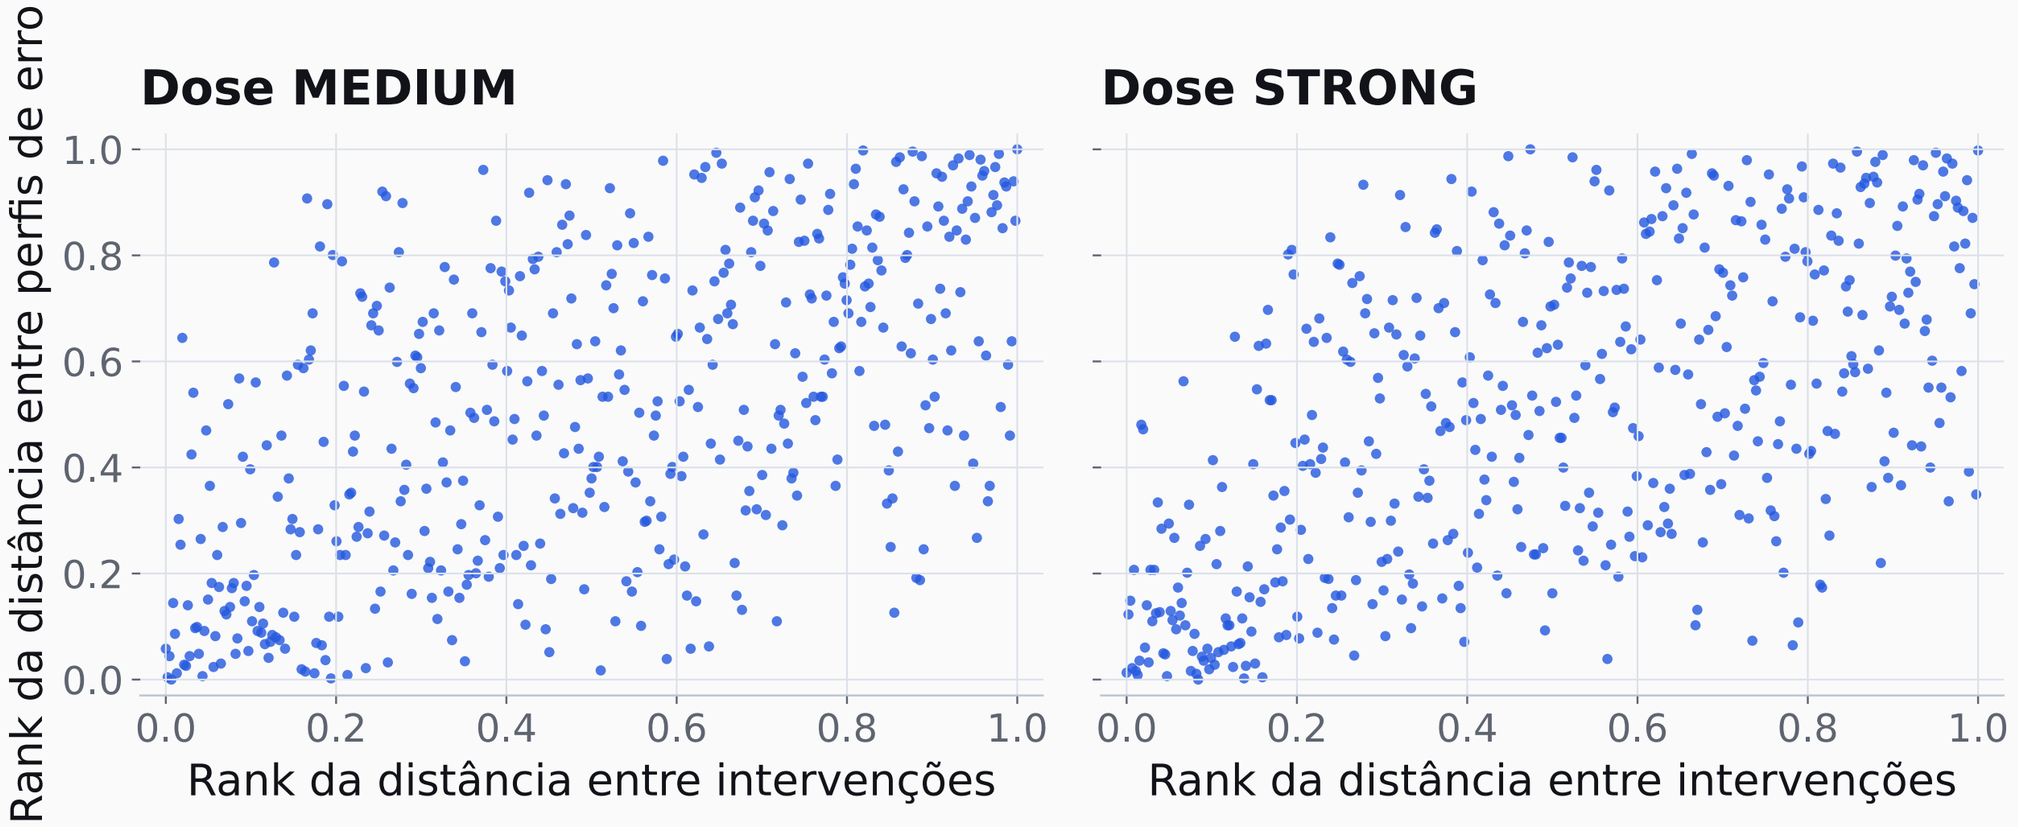
| Preditor | Informação utilizada |
| --- | --- |
| A0 · coordenadas | Ângulo entre direções de intervenção |
| A1 · ativações | Geometria ponderada por estatísticas de ativação |
| A2 · resposta | Relações entre mudanças nas distribuições de saída |

> Pré-outcome semântico não significa pré-intervenção.

A2 utiliza resposta label-free a intervenções; não é uma Fisher estimada por derivada infinitesimal.

APROFUNDAR [A1 e A2: construções operacionais]

# Q2 · associação no banco histórico




31 direções, 300 problemas, duas repetições por condição. 37.800 gerações. A0 agregado: ρ ≈ 0,564.

APROFUNDAR [Pares compartilham direções]

# A geometria mais elaborada não foi a melhor

| Geometria | ρ agregado | Resultado |
|---|---|---|
| A0 · coordenadas | 0,564 | Associação qualificada |
| A1 · ativações | 0,556 | Associação qualificada |
| A2 · resposta | 0,441 | Associação qualificada; sem superioridade |

> Há estrutura previsível, mas a hipótese de superioridade funcional proposta não recebeu apoio.

# Dose maior move mais; acertar mais é outra questão

**31 / 31**

direções com maior deslocamento de forma em STRONG que em MEDIUM

| Condição | Acurácia média |
|---|---|
| Baseline | 45,50% |
| MEDIUM | 46,76% |
| STRONG | 44,96% |

> As duas doses oferecem controle de intensidade, sem uma melhora monotônica de competência.

# Validação com direções novas




19.200 gerações. Teste primário por direção nova: 16/16 positivos; p binomial unilateral nominal = 1,53 × $10^{-5}$.

APROFUNDAR [Pares compartilham direções] [O diagnóstico do bootstrap]

# O alcance da generalização

MUDOU

A identidade da direção de intervenção

PERMANECEU FIXO

Modelo · tarefa · painel de problemas

Camada · subespaço · doses · atlas

> As relações generalizaram dentro desse laboratório. Outras dimensões exigem testes próprios.

# Transferência e o comparador textual

ACURÁCIA OBSERVADA

| Coleta | Baseline | Steering fixo | Prompt CAREFUL |
|---|---|---|---|
| Q1 · CRUXEval<br>57 problemas | 43,86% | 50,00% | 73,68% |
| LiveCodeBench<br>130 famílias | 66,92% | 59,62% | 72,88% |

Acurácias descritivas; uso realizado de tokens não pareado. Em LiveCodeBench, o controlador fixo não passou o critério completo de transferência.

> A vantagem sobre prompting continua sendo uma pergunta experimental.

# O subespaço construído é especial?

Um piloto comparou o espaço original com duas orientações aleatórias.

| Espaço | Associação observada |
|---|---|
| Original | 0,418 |
| Aleatório 1 | 0,018 |
| Aleatório 2 | 0,248 |

> O contraste pré-definido ficou inconclusivo. Escala de resposta e repetibilidade diferiram entre os espaços.

19.512 trajetórias registradas no piloto. Duas orientações aleatórias limitam a conclusão populacional.

APROFUNDAR [Que pergunta cada controle responde?]

# Uma explicação concorrente para a geometria

$$q_i(c) \approx q_i(0) + b_i^T c$$

$$D^{shape}(c,d) \approx (c-d)^T \, Cov_i(b_i) \, (c-d)$$

Se a sensibilidade for aproximadamente isotrópica e as normas forem iguais:

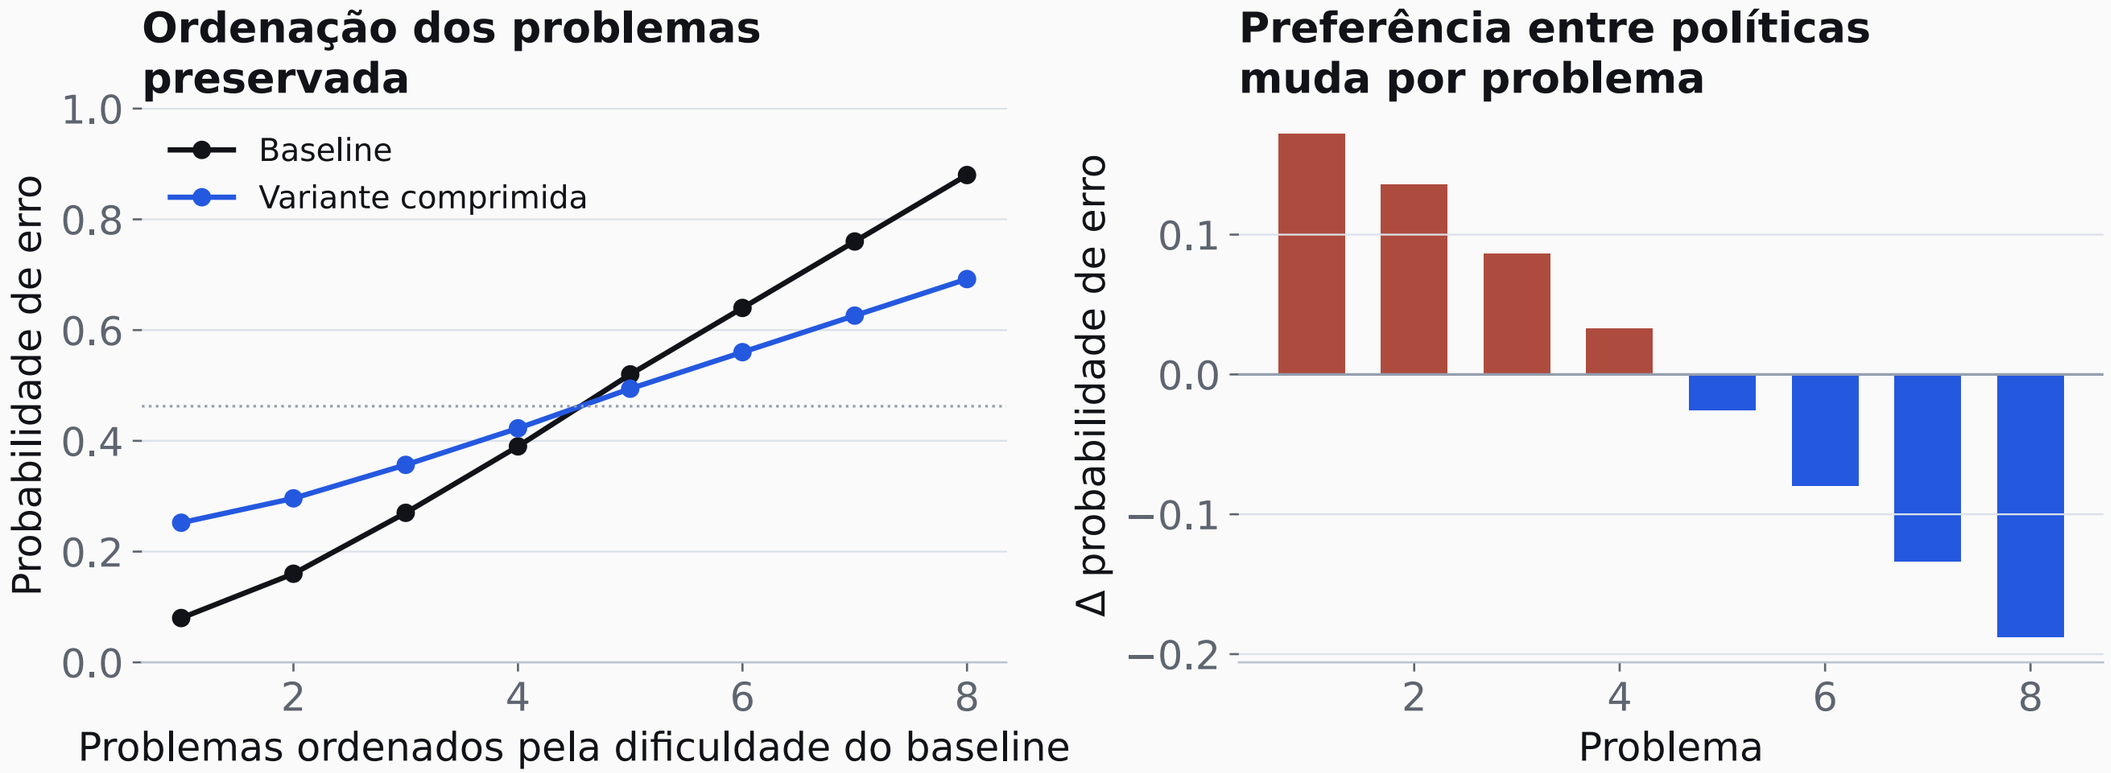
$$D^{shape} \propto 1 - \cos\theta$$

> Uma resposta regular a perturbações já pode gerar associação angular.

Dedução em um modelo reduzido; ainda não validada como explicação dos dados CEG.

APROFUNDAR [Exemplo exato de resposta linear]

# O significado de complementaridade




Exemplo matemático, não dados CEG. C positivo e ganho de oracle podem coexistir com a mesma ordenação de dificuldade dos problemas.

APROFUNDAR [Oracle, competência e complementaridade] [Mesma distância, ganhos de oracle opostos]

# A etapa da utilidade coletiva

## Como escolher ou agregar respostas sem conhecer o gabarito?

Um banco complementar pode oferecer headroom para um oracle.

Seleção realizável exige informação disponível antes da resposta final e avaliação em problemas reservados.

> Os estudos acumulados ainda não demonstram utilidade prospectiva de roteamento.

APROFUNDAR [Mesma distância, ganhos de oracle opostos] [Uma comparação de valor incremental]

# O que as iterações ensinaram

- A definição do instrumento muda o que podemos concluir.
- Direção, dose e duração são escolhas experimentais independentes.
- Relação geométrica, mecanismo e utilidade têm exigências de evidência diferentes.
- A generalização mais forte atual é entre direções dentro do laboratório fixo.

> O programa ganhou um objeto mensurável e limites que orientam as perguntas seguintes.

APROFUNDAR [Quatro mudanças de desenho que custaram trabalho] [Linhas posteriores: resultados e estados]

# Três caminhos para aprofundar

| Caminho | Pergunta que o orienta |
| --- | --- |
| Explicação do mapa de resposta | O que uma aproximação simples prevê e onde ela falha? |
| Generalização do perfil de erro | Quais relações sobrevivem em problemas ou apresentações novos? |
| Valor incremental das variantes | Steering acrescenta utilidade a bons prompts sob o mesmo orçamento? |

Candidatas de pesquisa a qualificar frente aos antecedentes; não são reivindicações de novidade.

APROFUNDAR [Contribuições e possibilidades de publicação]

# Discussão

## Que explicação concorrente vale enfrentar primeiro?

Que resultado mudaria nossa interpretação do mapa entre intervenção e erro?

Qual dimensão nova de generalização acrescentaria mais conhecimento?

Os apêndices permitem aprofundar métodos, estimandos e caminhos de pesquisa.

# Oracle, competência e complementaridade

Usando q para probabilidade de erro e μ para sua média:

$$G = E[q_o^2 - q_o q_j]$$

$$C = Var(q_o) - Cov(q_o, q_j)$$

$$G = C + \mu_o(\mu_o - \mu_j)$$

> Se as médias de erro forem iguais, G = C.

# Distância total e mudança de forma

$q_j = 0{,}5 + m + a(q_0 - 0{,}5)$, com $m = 0{,}00$ e $a = 0{,}00$.

## Perfis de erro

| Perfil | 1 | 2 | 3 | 4 |
|---|---|---|---|---|
| $q_o$ | 0,20 | 0,40 | 0,60 | 0,80 |
| $q_j$ | 0,50 | 0,50 | 0,50 | 0,50 |

## Após subtrair cada média

| Perfil | 1 | 2 | 3 | 4 |
|---|---|---|---|---|
| $q_o - \mu_o$ | -0,30 | -0,10 | 0,10 | 0,30 |
| $q_j - \mu_j$ | 0,00 | 0,00 | 0,00 | 0,00 |

$$D_{total} = (1/n)\ \Sigma_i\ [q_j(i) - q_0(i)]^2$$

$$D_{shape} = (1/n)\ \Sigma_i\ [(q_j(i) - \mu_j) - (q_0(i) - \mu_0)]^2, n = 4$$

$$D_{total} = D_{shape} + (\mu_j - \mu_0)^2 = 0{,}0500 + 0{,}0000 = 0{,}0500$$

$\mu_o = 0{,}50$; $\mu_j = 0{,}50$. VarPOP($q_o$) = 0,0500; VarPOP($q_j$) = 0,0000. Centrar preserva escala e sinal.

Exemplo construído com quatro itens equiprováveis. q é probabilidade de erro. VarPOP: divisor 4. Definições de distância

# Por que duas repetições entram no estimador

Para cada problema, $\delta_{ir} = e_{ijr} - e_{ikr}$, com r = 1,2.

$$E[\delta_{i1}\,\delta_{i2} \mid i] = (q_j(i) - q_k(i))^2$$

O produto de blocos independentes estima a diferença quadrática das propensões.

> Uma estimativa não viesada não garante ranks precisos ou intervalos calibrados.

# Pares compartilham direções

## 31 direções → 465 pares

Os pares (1,2), (1,3) e (1,4) compartilham a direção 1.

$$D \rightarrow P_{\pi} D P_{\pi}^{T}$$

> QAP permuta identidades inteiras; não embaralha cada par como uma observação independente.

# O diagnóstico do bootstrap

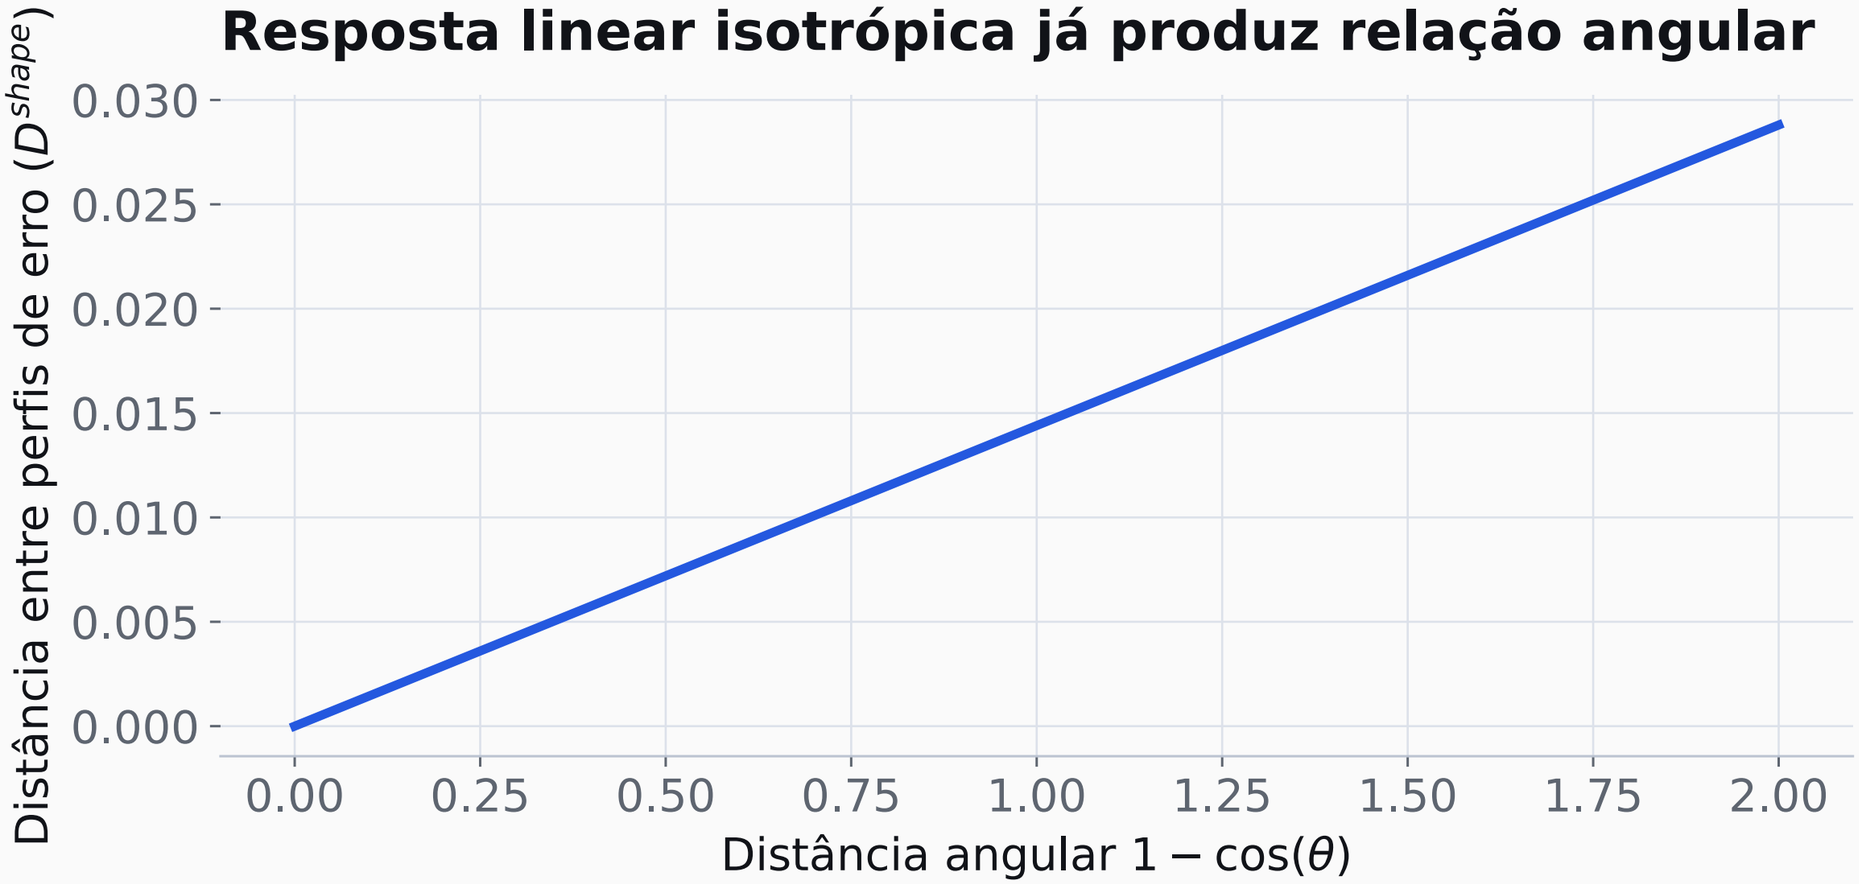
As reamostragens por item reproduziram a implementação histórica.

Os percentis não se mostraram calibrados como um intervalo de confiança convencional para o estimador composto.

> A interpretação atual é sensibilidade à reponderação do painel.

O resultado primário por direção nova permanece separado desse diagnóstico.

# Exemplo exato de resposta linear




Exemplo construído: quatro problemas, duas coordenadas, probabilidades válidas. Não é ajuste aos dados CEG.

# Uma comparação de valor incremental

## Baseline · prompts fortes · steering · prompt + steering · LoRA

- Mesmo modelo e distribuição de problemas
- Orçamento de desenvolvimento e seleção registrado
- Custo de construção e de geração contabilizado
- Avaliação reservada, incluindo repetir o baseline

> Comparar ganho realizável, preservação de competência e custo por decisão.

# Contribuições e possibilidades de publicação

| Possibilidade | O que precisaria sustentar |
|---|---|
| Estudo empírico delimitado | Controle, relação geométrica prospectiva e fronteiras |
| Explicação ou teoria reduzida | Previsões discriminativas além de identidades conhecidas |
| Método para sistemas de agentes | Utilidade incremental realizável frente a comparadores fortes |

> São caminhos a avaliar; aceitação e prioridade não estão estabelecidas.

# Resultados negativos, inconclusivos e não avaliados

| Estado | Significado |
| --- | --- |
| Negativo sob o critério | O teste foi concluído e não satisfez sua regra |
| Inconclusivo | A resolução ou a evidência não discrimina a hipótese |
| Não avaliado | A comparação científica pretendida não foi completada |

> Uma falha operacional não prova ausência do fenômeno.

# D75: o que foi selecionado, e por quê

$$\delta = \eta_{D75} \cdot \sigma_{ref} \cdot v \qquad \eta_{D75} = 0{,}75\ \eta_{full}$$

| Critério de desenvolvimento | Regra |
|---|---|
| Canal e competência | Guardas de validade, avaliabilidade e acurácia |
| Mudança semântica | Acima de patamar e controles aleatórios |
| Regime de tokens | Recuperar parte do efeito textual CAREFUL |
| Escolha | Primeira elegível: D25 → D50 → D75 |

D75 significa 75% de uma dose histórica. Os alvos 0,25/0,50 do Q2 têm outra definição.

# Que pergunta cada controle responde?

| Comparador | Dúvida que enfrenta |
|---|---|
| Repetir o baseline | A diferença excede a estocasticidade da geração? |
| Texto CAREFUL | A instrução de origem tem efeito e benefício? |
| Quatro nulls de Q1 | A direção construída excede perturbações pareadas? |
| Orientações de subespaço | A relação geométrica é especial ao espaço construído? |

> Especificidade do controlador Q1 e especificidade geométrica do Q2 são afirmações distintas.

# A1 e A2: construções operacionais

**A1:** ângulo após whitening regularizado de ativações ordinárias.

**A2:** ângulo de deslocamentos de distribuições em relação ao baseline.

$$r_j^2 = \text{média}\, JS(P_j, Po) \qquad d_{jk}^2 = \text{média}\, JS(P_j, P_k)$$

$$A2(j,k) = 1 - (r_j^2 + r_k^2 - d_{jk}^2) / (2 r_j r_k)$$

JS com pesos iguais, log natural e vocabulário completo; probes sem rótulos de correção.

# Quatro mudanças de desenho que custaram trabalho

| Antes | O que o teste exigiu mudar |
|---|---|
| Readout e formato de resposta | Geração completa e avaliação semântica |
| L17, um token, dose inicial | Fonte, camada, duração e dose separadas |
| Poucas famílias nomeadas | Muitas identidades no span; inferência relacional |
| Resultado no banco conhecido | Predições congeladas para direções novas |

> O progresso foi transformar dificuldades em perguntas que o próximo teste podia resolver.

# Linhas posteriores: resultados e estados

| Linha | Estado científico |
|---|---|
| Reorganização entre doses | Diagnóstico retrospectivo; inversões ordinais não demonstradas |
| Budget em modo thinking | Interação inconclusiva pela decisão fixa |
| Momento da finalização | Plano e implementação; sem resultado estabelecido |

> Essas linhas podem gerar perguntas novas; não ampliam retroativamente o claim Q2.

EXEMPLO CONSTRUÍDO COM PROBABILIDADES DE ERRO

# Mesma distância, ganhos de oracle opostos

Dois itens equiprováveis; s = 0,20. Todas as médias de erro são 0,50.

| Política | Perfil de erro | $D_{shape}$ ao baseline | C | Acerto oracle |
|---|---|---|---|---|
| **Baseline** | (0,20; 0,80) | — | — | 66% |
| **A** | (0,40; 0,60) | 0,0400 | +0,0600 | 72% |
| **B** | (0,00; 1,00) | 0,0400 | -0,0600 | 60% |

$$C_{0j} = ½ [D_{shape}(0,j) + VarPOP(q_0) - VarPOP(q_j)]$$

A mesma $D_{shape}$ permite C de sinais opostos. Com médias iguais, o ganho do oracle sobre repetir o baseline é C. A linha baseline usa duas chamadas baseline; A/B usam uma chamada baseline e uma da variante.

O oracle conhece a correção e aceita uma resposta correta quando ao menos uma tentativa acerta. Isso não é uma regra realizável de roteamento.

Exemplo construído. Duas chamadas independentes condicionalmente ao item. Oracle com gabarito, não roteador. Exemplo exato e identidade