CAUSAL EPISTEMIC GEOMETRY · ACS-USP

Intervenções internas e os erros de um LLM

O que construímos, o que encontramos e o que ainda precisamos entender

Gabriel · Entropic Session · 16 de outubro de 2026

Steering: alterar estados durante a execução

Ativações são os números produzidos pela rede ao processar a entrada. Steering altera esses números durante a execução.

1. Escolhemos o alvo

Por exemplo, o tom de um texto.

2. Alteramos um estado

Somamos, substituímos ou transformamos suas ativações.

3. O modelo continua

Medimos como a saída muda.

> Os parâmetros aprendidos, os pesos, podem ficar fixos. Construir e calibrar a intervenção ainda tem custo.

Turner et al. · ActAdd · Rimsky et al. · CAA

APROFUNDAR Controle de ativações em outros modelos

Uma história anterior aos chatbots atuais

2017

Sentimento em uma rede recorrente

Fixar uma unidade interna muda o sentimento das avaliações geradas.

Radford, Jozefowicz e Sutskever

2019

Objetos em geradores de imagens

Ativar ou suprimir grupos de unidades altera objetos em cenas.

Bau et al. · GAN Dissection · ICLR

2020

Texto guiado por um avaliador

PPLM usa um avaliador de tema ou sentimento para orientar mudanças nos estados.

Dathathri et al. · Plug and Play Language Models · ICLR

Marcos selecionados. Há várias linhagens de controle de representações, sem uma origem única.

Vetores, características e geometrias

2023

ActAdd: contraste entre prompts

A diferença entre ativações oferece um vetor que podemos somar durante a geração.

Turner et al. · Activation Addition

2024

CAA e Golden Gate Claude

CAA combina diferenças de ativações. A demonstração Golden Gate Claude amplifica uma característica interna.

Rimsky et al. · CAA • Anthropic · Golden Gate Claude

2025–26

Além de escolher um vetor

Aprender direções supervisionadas, aproximar aprendizado e respeitar trajetos curvos.

Beaglehole · COLD-Steer · Manifold Steering

O que muda no caso dos modelos de linguagem

O alvo	Pode ser tom, tema, recusa ou uma distribuição de respostas.
A sequência	Token é uma unidade de texto. Cada unidade gerada entra no contexto das próximas.
A intervenção	Camada, posição do texto, intensidade e duração fazem parte do método.
A avaliação	Mudar o comportamento e preservar a qualidade são perguntas separadas.

> Um prompt também muda estados internos. Steering oferece outro ponto de controle, com benefício a comparar.

CAA · método e avaliação · AxBench · comparadores

Beaglehole: extrair, combinar e testar direções

Toward universal steering and monitoring of AI models · 2025

1. Exemplos rotulados

Textos com e sem o conceito de interesse.

2. Encontrar uma direção

Um preditor identifica orientações relevantes nos estados internos.

3. Intervir ou monitorar

Somar direções para mudar respostas; combinar sinais para reconhecer conceitos.

O estudo inclui um banco de **512 conceitos em três modelos Llama**, além de outras demonstrações.

> Influência no projeto: construir intervenções explícitas e investigar seus efeitos.

Beaglehole, Radhakrishnan, Boix-Adserà e Belkin · arXiv v2

APROFUNDAR Como o RFM encontra uma direção

Wurgaft: o trajeto da intervenção importa

Manifold Steering · 2026

Manifold: uma curva ou superfície ajustada à organização dos estados que o modelo normalmente produz.

Reta entre estados

Pode atravessar regiões pouco visitadas pelo modelo.

Trajeto pela curva ajustada

Nos testes com dias e meses, preserva transições de saída mais naturais.

“Natural” significa próximo às distribuições observadas sem intervenção. Isso não equivale a estar correto.

> Influência no projeto: perguntar como a geometria da intervenção se relaciona com seu efeito.

Wurgaft et al. · arXiv v1 · §§2–3 e 8

APROFUNDAR Três trajetos no Manifold Steering

COLD-Steer: aproximar um passo de aprendizado

Sharma e Trivedi · ICLR 2026

1. Mostrar exemplos

Respostas desejadas ou pares de preferência.

2. Estimar uma mudança

Como um passo de aprendizado mudaria um estado interno?

3. Intervir no estado

Aplicar uma aproximação dessa mudança ao modelo.

O critério de erro dos exemplos orienta a intervenção, em vez de usar apenas uma diferença de ativações.

> Aproximação de aprendizado abre outra família de steering. Preparação e custo continuam relevantes.

COLD-Steer · §§3–4 · publicação ICLR

APROFUNDAR O custo das duas variantes de COLD-Steer

Evidência prática: controle, custo e comparadores

Já há instrumentos	Código aberto, benchmarks e demonstrações públicas de controle.
Prompts continuam fortes	AxBench favorece prompting no seu teste de steering. A vantagem depende da tarefa e da avaliação.
O efeito tem outras dimensões	SteerScope compara eficácia e efeitos colaterais. Resultados em dois modelos Gemma; preprint de outubro.

> Para nós: além de alterar a resposta, conseguimos mudar e antecipar quais problemas o modelo erra?

As fontes mostram uso experimental e ferramentas disponíveis. Não fornecem uma taxa de adoção em produção.

Implementação Beaglehole · AxBench · ICML 2025 · SteerScope · preprint · 6/out/2026

Quais problemas o modelo erra?

Conseguimos mudar quais problemas um modelo acerta e erra, mantendo seus pesos fixos?

E antecipar essa mudança a partir da intervenção que fazemos?

A mesma acurácia pode esconder erros diferentes

Duas variantes acertam 3 de 6 problemas.

Problema	1	2	3	4	5	6
Variante A	**Acerta**	**Acerta**	**Acerta**	Erra	Erra	Erra
Variante B	**Acerta**	Erra	Erra	**Acerta**	**Acerta**	Erra

Exemplo construído para ilustrar a pergunta

> B resolve alguns erros de A, mas também perde acertos.

Como aproveitar isso sem conhecer o gabarito?

O que queremos descobrir

Mudar os erros	Uma intervenção oferece algo além de repetir o modelo?
Prever a mudança	Intervenções parecidas produzem perfis de erro parecidos?
Usar a diferença	Conseguimos escolher melhor sem consultar o gabarito?

Nos registros do projeto: Q1, Q2 e Q3, respectivamente.

A ESCOLHA EXPERIMENTAL

O que mudamos em cada abordagem

Abordagem	O que alteramos diretamente
Prompt	O texto de entrada. Os pesos ficam fixos.
Steering	O estado interno, somando um vetor: uma lista de ajustes numéricos. Texto da tarefa e pesos ficam fixos.
Ajuste de pesos	Os parâmetros do modelo, por treinamento adicional. LoRA aprende ajustes compartilhando o modelo base.

A adição interna oferece um controle explícito. A vantagem prática sobre bons prompts ainda precisa ser medida.

LoRA é uma comparação proposta, ainda não executada. Prompt e steering podem ser combinados. Como comparar benefício e custo ↗

O código e a entrada eram mostrados

CRUXEval · problema real sample_298

```
def f(text):
    new_text = list(text)
    for i in range(len(new_text)):
        character = new_text[i]
        new_character = character.swapcase()
        new_text[i] = new_character
    return ''.join(new_text)
```

Entrada

```
'dst vavf n dmv dfvm gamcu dgcvb.'
```

Saída correta

```
'DST VAVF N DMV DFVM GAMCU DGCVB.'
```

O programa troca maiúsculas e minúsculas; preserva espaços e ponto.

> A tarefa era escrever o resultado. A função estava visível; não era preciso descobri-la nem escrevê-la.

A resposta era comparada com o gabarito

Modelo

Lê código e entrada.
Gera uma resposta.

Avaliador, depois

Extrai o valor final.
Compara com o gabarito.

Valor extraído no caso real	Decisão
`'DST VAVF N DMV DFVM GAMCU DGCVB.'`	Correto
`'DST VAVF N DVM DFVM GAMCU DGCVB.'`	Errado: DMV virou DVM
Sem um valor final interpretável	Resposta inutilizável

Na avaliação de Q2, respostas erradas, inválidas e interrompidas contam como falhas. Registros ausentes bloqueiam a análise.

Em que regime o modelo respondia

Modelo	Qwen3-8B, com os pesos fixos durante a avaliação.
Ferramentas	Sem acesso a um interpretador Python.
Thinking desativado	Não usamos o modo especial de pensamento. O modelo ainda podia escrever passos intermediários.

> No teste Q1, o original acertou 43,86% das respostas. Conhecer o código não tornou a tarefa trivial nesse regime.

Esses resultados não estabelecem o desempenho com thinking habilitado nem representam a melhor configuração possível do modelo.

APROFUNDAR [O que pode mudar com os pesos fixos?]

O que somamos ao estado interno

No modelo usado, cada posição do texto tem um estado com **4.096 números**.
Somamos outro vetor, também com 4.096 componentes.

Estado

$$h = (h_1, h_2, \ldots, h_{4096})$$

$+$

Adição

$$\delta = \alpha \cdot (v_1, v_2, \ldots, v_{4096})$$

$\longrightarrow$ $h + \delta$

v: direção, com comprimento 1

α: intensidade da adição

> A direção define a orientação. A intensidade define quanto adicionamos nessa orientação.

Onde fica a adição: depois do 28º bloco

Usamos a **saída do 28º bloco** do Qwen3-8B. O código começa a contar em zero: esse é o **índice 27**.



L27 nos registros = bloco de índice 27 = 28º bloco na contagem humana

Um **token** é uma unidade de texto. Lemos ou alteramos o estado associado a uma posição, nessa saída.

Escolha de desenvolvimento: o protocolo fixou o índice 27 como candidato de camada única, sujeito aos testes da fonte. Os 57 problemas confirmatórios não escolheram o bloco.

APROFUNDAR Como chegamos ao controlador final

Como a adição acompanha a geração

Somamos δ na saída do 28º bloco. Os escores após os blocos seguintes dão as chances do próximo token.

Chamada	Entrada	Posição com +δ	Próximo token amostrado
Prompt inteiro	Prompt inteiro x_1 … xP	xP, último token da entrada	g_1
Próximo passo	g_1	Corrente, em g_1	g_2
Passo seguinte	g_2	Corrente, em g_2	g_3

$$h \leftarrow h + \delta \quad \cdot \quad \delta = \alpha v$$

Se a geração continuar, cada token sorteado entra na próxima chamada. A memória de passos anteriores não é reescrita; nova memória pode mudar.

Mesma adição nominal em cada passo. BF16 é a precisão numérica usada; o arredondamento pode mudar o incremento realizado. Adição, linhas 28–109 · Intensidade da primeira intervenção

Uma direção nasce de duas instruções

Nos mesmos **104 problemas**, processamos uma instrução cuidadosa e uma direta.

Cuidadosa · CAREFUL

Rastrear operações e valores.
Conferir o resultado.

Direta · DIRECT

Responder imediatamente.
Sem rastrear ou verificar.

estado cuidadoso – estado direto → média → normalização

Lemos 4.096 números na última posição do prompt, na saída do 28º bloco, antes de gerar livremente a resposta.

104 problemas de desenvolvimento; 32 separados para validar a fonte. Os 57 da confirmação não constroem o vetor.

APROFUNDAR Como chegamos ao controlador final

O que D75 significa na primeira etapa?

D75 é um tamanho de adição: 75% do tamanho histórico, calibrado no desenvolvimento.

$$\text{adição} = 0{,}75 \times \text{tamanho histórico} \times \text{direção unitária}$$

A intensidade histórica usa a dispersão das projeções dos estados na direção escolhida, além de um multiplicador já calibrado.

> O tamanho fica fixo na confirmação. D75 não significa 75% de mudança na resposta ou de acerto.

A coleção Q2 usa outra referência para intensidade. Seus valores 0,25 e 0,50 não são frações dessa mesma escala.

Por que D75 passou e D50 não?

Um critério exigia recuperar parte do aumento de comprimento produzido pelo prompt cuidadoso.

> Exemplo construído
>
> Original: 10 tokens. Cuidadoso: 110.
> Adição: 35 → recupera 25 dos 100 tokens extras = **25%**.

Calibração real · 50 problemas	Recuperação	Faixa exigida: 25%–125%
D50	2,8%	Não passou
D75	34,6%	Passou

D75 foi a menor intensidade elegível no conjunto de critérios, que também exigia respostas utilizáveis, competência e mudança acima dos controles.

APROFUNDAR [Como chegamos ao controlador final]

Duas instruções não são duas repetições

Condição = uma configuração fixa para gerar respostas.

Construir a direção	Testar a direção fixa
104 problemas: instrução cuidadosa e instrução direta.	57 problemas reservados: duas respostas em **cada condição**.

As sete condições: original, steering fixo, prompt cuidadoso e quatro direções de controle.

$$57 \text{ problemas} \times 7 \text{ condições} \times 2 \text{ respostas} = 798 \text{ gerações}$$

> Duas repetições usam a mesma instrução, direção e intensidade. As respostas podem coincidir.

APROFUNDAR [Os quatro cruzamentos reutilizam as mesmas respostas]

Um perfil reúne chances de erro

A geração é aleatória: o mesmo problema pode ser acertado ou errado em tentativas diferentes.

Duas tentativas	Proporção observada de erros
0 erros	0%
1 erro	50%
2 erros	100%

> Essas proporções não são probabilidades conhecidas. Duas tentativas dão baixa resolução; as medidas usam repetições e vários problemas.

Como as repetições entram

APROFUNDAR Quanto valeria saber qual tentativa acertou? O que muda ao retirar a média? Como medir distância com poucas tentativas?

De duas respostas à falha conjunta

Registramos **erro = 1** e **acerto = 0**. O produto vale 1 só quando as duas tentativas falham.

Resposta 1	Resposta 2	Produto
0	0	0
0	1	0
1	0	0
1	1	**1**

Exemplo construído: chance de erro $q_0 = 0{,}60$ no original; $q_v = 0{,}40$ com steering.

Par	Ambas falham	Ao menos um acerto
Original + original	0,60 × 0,60 = 0,36	0,64
Original + steering	0,60 × 0,40 = 0,24	0,76

> $G = 0{,}76 - 0{,}64 = 0{,}12$: ganho de 12 pontos percentuais, com duas tentativas de cada lado.

Tentativas independentes dado o problema; seleção com gabarito.

APROFUNDAR [Os quatro cruzamentos reutilizam as mesmas respostas]

C: comparar os perfis de erro

q_0: chance de erro do original em cada problema. **q_v**: com steering.

$$C = \mathrm{Var}(q_0) - \mathrm{Cov}(q_0, q_v)$$

$\mathrm{Var}(q_0)$	Quanto a chance de erro do original varia entre problemas.
$\mathrm{Cov}(q_0, q_v)$	Quanto os dois perfis de erro variam juntos entre problemas.

Mesma medida: $C = G - \mu_0(\mu_0 - \mu_v)$.

μ_0 e μ_v são os erros médios do original e do steering.

As chances q são desconhecidas. Estimamos os termos com respostas repetidas.

> A referência é o perfil original comparado consigo mesmo. C positivo não identifica uma habilidade.

APROFUNDAR [Os quatro cruzamentos reutilizam as mesmas respostas] [A mesma distância garante o mesmo ganho?]

Três comparadores, três perguntas

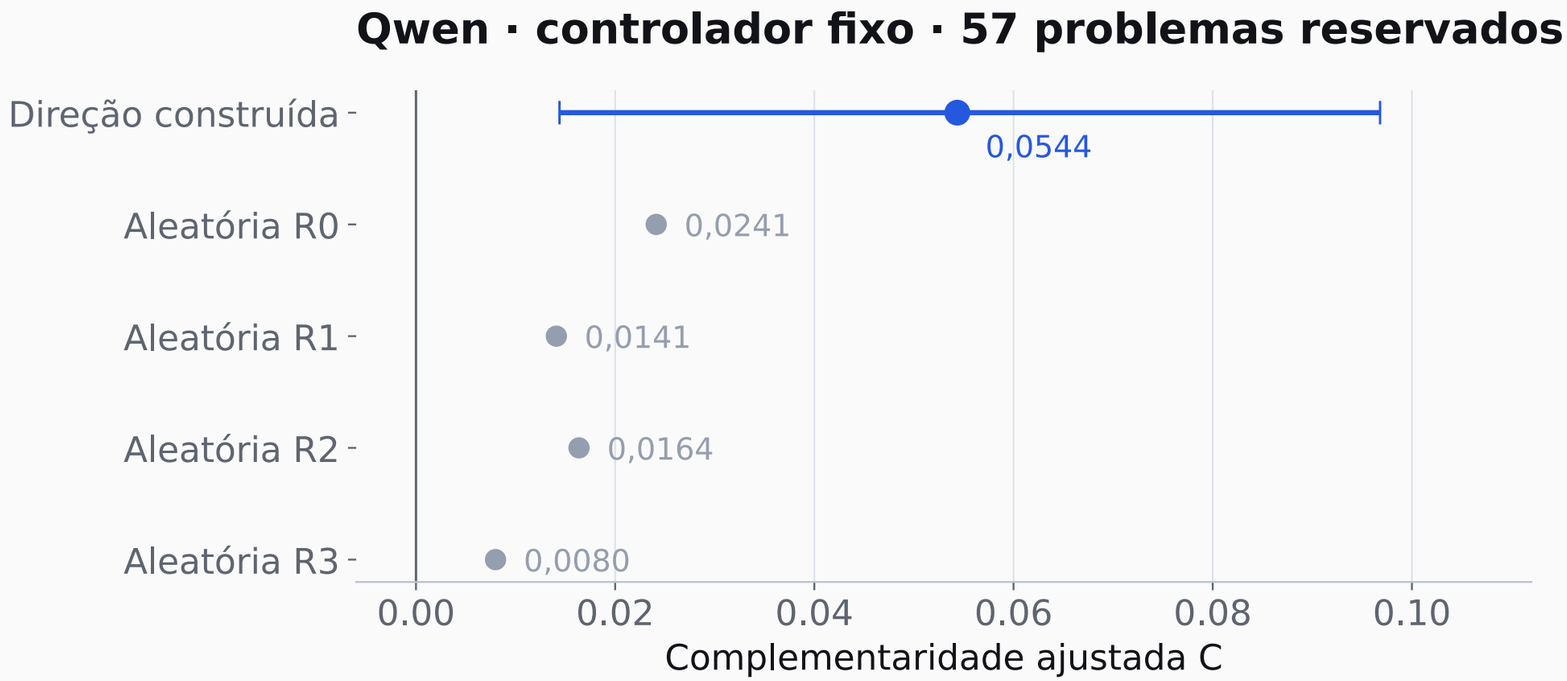
Comparador	Pergunta
Repetir o original	Quanto já ganhamos com outra amostra?
Quatro direções aleatórias	Outras direções, aplicadas do mesmo modo, também funcionam?
Prompt CAREFUL	O pedido textual já oferece benefício?

CAREFUL não integra os quatro controles aleatórios.

> Calculamos C frente ao original; depois verificamos C acima de zero e C acima da média dos quatro controles.

Complementaridade no Qwen

Controlador fixo = direção construída. R0–R3 = vetores aleatórios. Barra azul = intervalo de 95%.



57 problemas reservados; duas gerações por condição. C = 0,05435; C – média dos controles = 0,03871.

> A direção passou no Qwen. O segundo modelo, Ministral, falhou no critério de respostas utilizáveis.

APROFUNDAR Casos observados Por que estes controles?

Qual trecho será executado?

Q2 constrói outras fontes; a direção de Q1 fica fora.

```
def f(x):
    if x > 0:
        return x + 1
    else:
        return -x
```

Instrução A

Liste quais trechos podem executar; acompanhe cada um até o retorno.

Instrução B

Siga o trecho que parecer mais imediato, sem listar outros. **“Mais imediato” não foi definido.**

Entrada: `-3`.
`x > 0` é falso: seguimos o `else` e retornamos **3**.

Exemplo construído. A/B resumem instruções reais; não são respostas coletadas nem prova de habilidade isolada.

Dois nomes, uma única lista

```
def f(x):
    a = [x]
    b = a
    b.append(2)
    return a
```

Entrada: `1`. Resultado: **`[1, 2]`**.
`b = a` não copia a lista.

Instrução A

Registre que `a` e `b` apontam para a mesma lista; aplique as mudanças em ordem.

Instrução B

Faça as atualizações sem manter esse registro de objetos compartilhados. **Isso não manda criar duas listas.**

Exemplo construído. A/B resumem instruções reais; não são respostas coletadas nem prova de habilidade isolada.

Qual é a última repetição?

```
def f():
    total = 0
    for i in range(1, 4):
        total += i
    return total
```

Chamada `f()`: resultado **6**.
Somamos `1 + 2 + 3`; o `4` fica fora.

Instrução A

Confira começo, primeiro e último `i`, ordem das somas e parada.

Instrução B

Resolva o que a repetição faz, sem conferir esses limites separadamente. **O texto não define outro cálculo.**

Exemplo construído. A/B resumem instruções reais; não são respostas coletadas nem prova de habilidade isolada.

Qual saída resiste às operações?

```
def f(x):
    y = x + 2
    return y * 3
```

Entrada: `1` → `y = 3` → retorno **9**.
Entre `3` e `9`, a última operação exclui `3`.

Instrução A

Teste saídas possíveis contra as operações; descarte as incompatíveis.

Instrução B

Assuma a primeira saída plausível, sem manter ou eliminar alternativas.

> Quatro pares A/B × duas posições de leitura = oito vetores-fonte. Q1 usa outra direção.

Exemplo construído. A/B resumem instruções reais; não são respostas coletadas nem prova de habilidade isolada.

De onde lemos os estados

No mesmo problema, lemos o estado após cada instrução A/B, na saída do 28º bloco. Os prompts podem ter comprimentos diferentes.

Posição	O que lemos em A	O que lemos em B
Fim do prompt	h^A no último token da entrada	h^B no último token da entrada
Fim da frase fornecida	h^A após a frase fixa	h^B após a mesma frase

Frase fornecida · não é uma resposta livre

I will now apply the requested reasoning policy to the program before committing to one answer.

Uma passagem completa sem cache por instrução. h é o estado com 4096 números nessa posição.

Quatro receitas × duas posições = oito vetores-fonte. Aqui lemos estados; na avaliação somamos vetores. Esquema de posições, sem tokens reais. Captura, linhas 259–302

Dos oito vetores a uma base comum

Para cada receita e posição: média das diferenças em 24 problemas, depois normalização para comprimento 1.

$$d_i = h_i^{A} - h_i^{B} \quad \rightarrow \quad \bar{d} = \text{média}(d_i) \quad \rightarrow \quad u = \bar{d} / \|\bar{d}\|$$

8 vetores-fonte: colunas de U

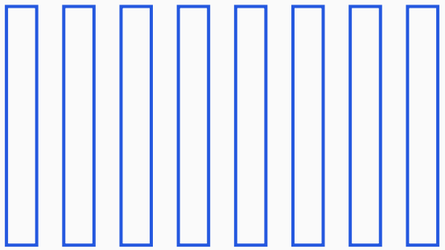


4 receitas × 2 posições

SVD

Decomposição em valores singulares

8 colunas de Q



4096 linhas; 8 colunas

> O posto observado foi 8. Q tem colunas de comprimento 1, perpendiculares entre si: uma base do mesmo espaço.

Como produzimos novas direções nesse espaço

Uma nova direção combina as oito colunas de Q, com pesos positivos ou negativos.

8 pesos: $c_1 \ldots c_8$ — Base já construída — Direção no modelo

$$c \longrightarrow Q \times c \longrightarrow v = Qc$$

c tem 8 números

v tem 4096 números

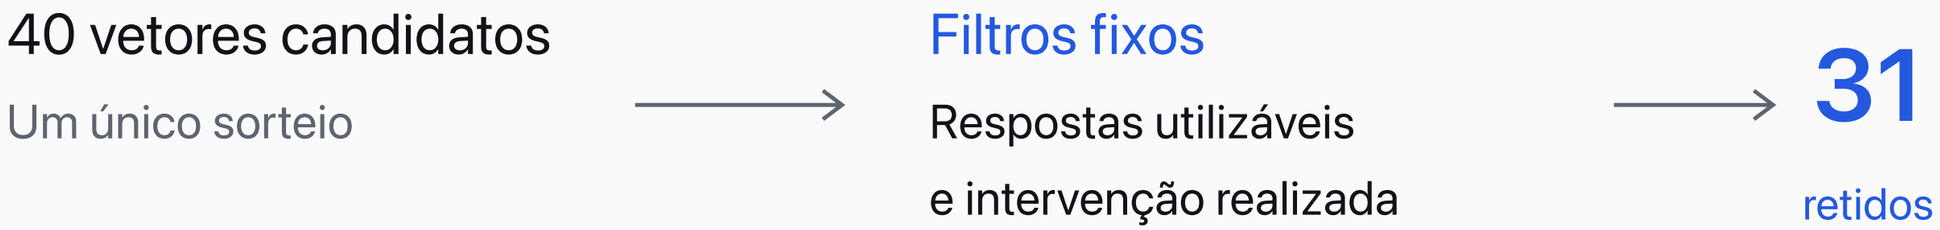
Para obter c, sorteamos oito números independentes da normal padrão e normalizamos o conjunto:

$$g \sim N(0, I_8) \rightarrow c = g / \|g\| \rightarrow v = Qc$$

Orientações distribuídas uniformemente dentro desse espaço, antes dos filtros. Coordenadas não nomeiam conceitos.

Como fechamos a coleção de direções

Chamamos de **banco** a coleção de vetores disponíveis para adicionar ao mesmo modelo.



Os filtros verificam formato, interpretação da saída, interrupção, mudança textual e tamanho, sem consultar acertos. **Uma resposta utilizável ainda pode estar errada.**

> Não substituímos os rejeitados. Estudamos as 31 direções que qualificaram, não todas as orientações possíveis.

APROFUNDAR [Usar sem gabarito ainda é usar o problema]

Mesma direção, duas intensidades

Calibramos dois tamanhos de adição contra uma referência fixa do estado sem intervenção.

Alvo Q2	Norma do vetor adicionado ÷ referência
0,25 · menor	0,25
0,50 · maior	0,50

Referência = raiz da média de $||h||^2$, congelada em 12 prompts de calibração. h é o estado sem adição.

> 31 direções × 2 intensidades + modelo original = 63 condições.

α é calibrado por direção e alvo; fica fixo na geração. D75 usa outra escala. O arredondamento numérico pode mudar o incremento efetivo.

Como comparar dois perfis de erro?

Perfil: chance de errar cada problema.

Condição	Problema 1	Problema 2	Erro médio
Referência	20%	80%	50%
Variante	40%	60%	50%

Exemplo construído

A média é igual, mas a distribuição entre problemas mudou.

> Chamamos de D^{shape} a distância de forma, que retira a diferença média.

No estudo: duas gerações por condição; estimativas com baixa resolução.

Três maneiras de comparar as intervenções

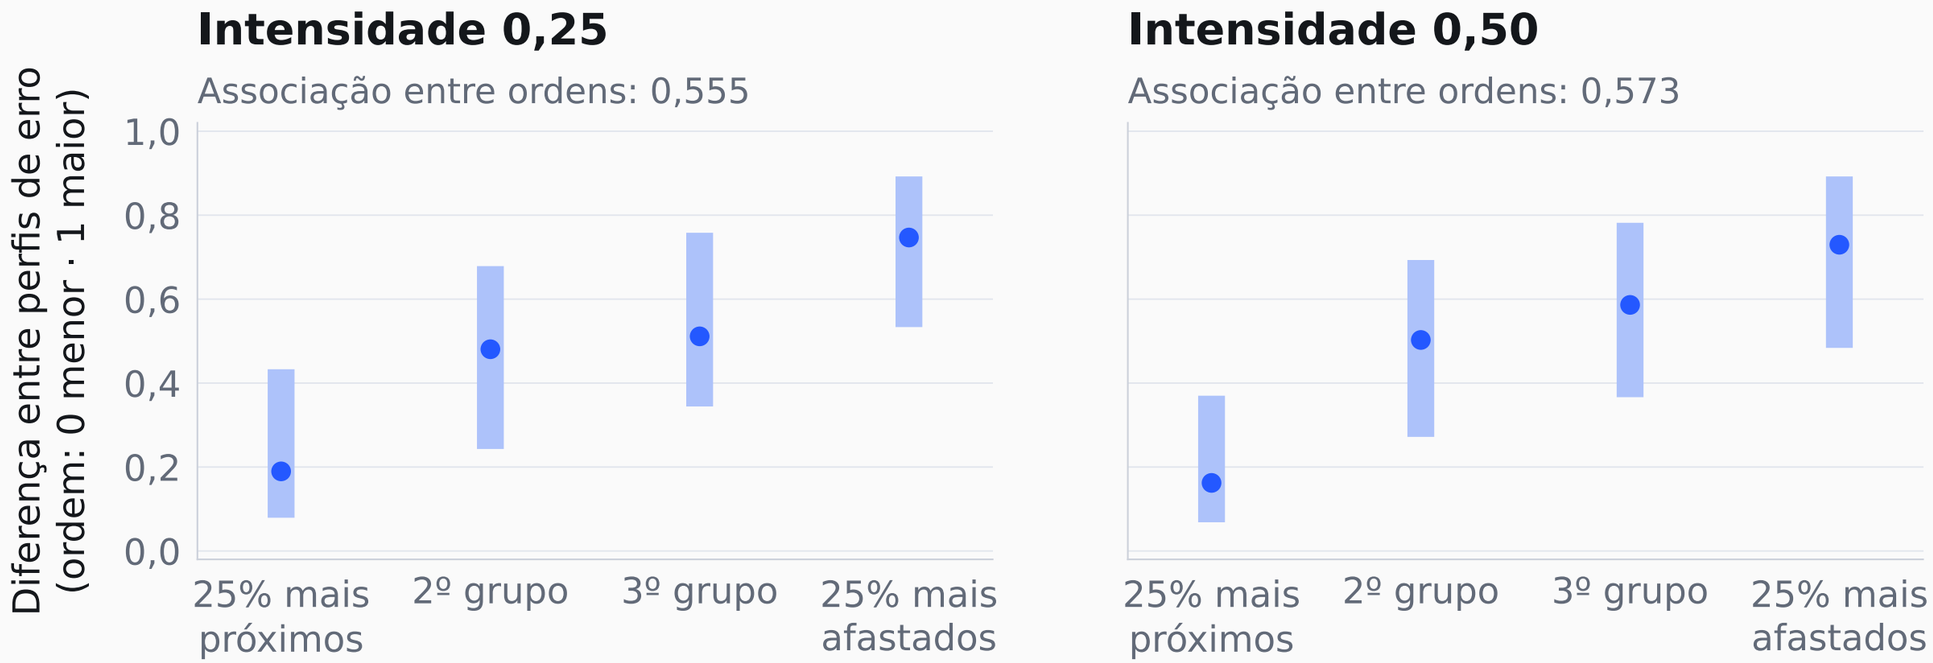
Medida	Como comparamos
A0 · vetores	Ângulo entre as direções adicionadas.
A1 · estados internos	Ângulo com coordenadas ajustadas à variação habitual dos estados internos.
A2 · respostas probabilísticas	Ângulo entre mudanças nas probabilidades do próximo token.

> Foram fixadas antes de analisar os erros do painel. A2 exige executar intervenções, mas não consulta o gabarito.

APROFUNDAR [O que A1 e A2 acrescentam ao ângulo comum?]

Ângulo dos vetores e diferenças nos erros

Quatro grupos, dos menores aos maiores ângulos: 116 ou 117 pares de direções por grupo.



Pontos: medianas. Faixas: os 50% centrais dos valores, não intervalos de confiança.

> Os 465 pares compartilham 31 direções: não são observações independentes.

APROFUNDAR [Por que 465 pares não são casos independentes?]

O teste com direções novas

Mantemos o espaço de oito dimensões e as duas intensidades. Trocamos os vetores.

Para cada direção nova	Procedimento
Comparar com as 31 originais	31 distâncias entre vetores versus 31 distâncias entre perfis de erro.
Obter um resultado	Calcular a associação em cada intensidade e fazer a média.

> O gráfico seguinte mostra um resultado por direção nova.

34 candidatas em um único fluxo, 26 qualificadas, primeiras 16 retidas. Seleção sem consultar acertos.

O padrão se repetiu em direções novas

Uma barra por nova direção. Atlas = 31 referências. A altura, r_i, é a associação média nas duas intensidades.



16/16 associações positivas. Teste de sinais: p unilateral nominal = $1{,}53 \times 10^{-5}$.

> Unidade do teste: direção qualificada. As referências e os problemas são compartilhados; 19.200 gerações não são unidades independentes.

APROFUNDAR [Por que 465 pares não são casos independentes?] [Reamostrar problemas cria novas respostas?]

O alcance do teste com novas direções

Variou	Permaneceu igual
As direções adicionadas	Modelo, tarefa e 300 problemas
Novas identidades	Bloco de aplicação, espaço de misturas, duas intensidades e 31 referências

> O resultado generaliza para direções novas nesse laboratório. Não testa tarefas novas nem garante prever cada resposta.

Estratégia semântica específica e resposta genérica às perturbações continuam explicações a distinguir.

O texto também é um comparador forte

Acurácia observada em duas coletas distintas:

Coleta	Sem adição	Adição fixa	Instrução detalhada
CRUXEval 57 problemas	43,86%	50,00%	73,68%
LiveCodeBench 130 grupos de casos	66,92%	59,62%	72,88%

A adição fixa não passou os critérios completos na tarefa nova.

> A instrução teve maior acurácia observada. Custos não foram igualados; isso não é um teste de superioridade.

O espaço construído teve uma vantagem especial?

Um piloto manteve a estrutura das direções e comparou três orientações do espaço interno.

Orientação	Associação entre distâncias
Construída das instruções	0,418
Aleatória 1	0,018
Aleatória 2	0,248

> O critério pré-definido ficou inconclusivo. O tamanho da mudança de erros e sua repetibilidade diferiram; só duas orientações aleatórias foram comparadas.

APROFUNDAR [Por que estes controles?]

Escolher a configuração trouxe ganhos em desenvolvimento

Seletor: escolhe a configuração antes da resposta, sem gabarito. Dados já expostos.

Desenho	Ganho em pontos percentuais
Escolha por problema	+5,33
Seletor em um conjunto de 8 variantes	+4

Comparador de cada estudo: sua melhor configuração fixa, escolhida na parte de treino de cada divisão dos dados.

> No primeiro estudo, informar também a geometria ao seletor acrescentou 0,33 ponto. O mínimo exigido era 1 ponto.

APROFUNDAR [A mesma distância garante o mesmo ganho?] [Como comparar steering, prompts e ajuste de pesos?]

A confirmação em problemas novos não foi aberta

Primeiro, o instrumento precisava passar critérios obrigatórios.

Critério	Observado	Exigido
Acerto da configuração fixa	13,33%	≥25%
Oportunidade observada com gabarito	1,5 ponto percentual	≥5 pontos percentuais

São dois exemplos de quatro critérios que falharam.

> Instrumento não qualificado; confirmação não realizada. Isso não demonstra ausência de benefício.

Por que o desenho precisou mudar

Dificuldade encontrada	O que mudamos
O formato escrito confundia a correção.	Passamos a comparar o valor final interpretado.
Separar instruções não garantia um efeito útil.	Testamos também onde, quanto e por quanto tempo adicionar o vetor.
Poucas intervenções limitavam a comparação.	Construímos uma coleção e fixamos regras antes dos acertos.
A relação podia depender das direções já vistas.	Reservamos novas direções para testar a previsão.

Os apoios documentam as mudanças de desenho, os resultados que limitaram a hipótese e a sistemática de registro.

APROFUNDAR [O trabalho mudou o que precisava ser testado]

O que vale testar a seguir?

Que observação distinguiria uma estrutura especial dos erros de uma resposta genérica à perturbação?

E que ganho justificaria usar steering junto de bons prompts?

Dois casos observados: acertos ganhos e perdidos

Problema	Modelo original	Adição interna	Instrução cuidadosa
Operadores and/or sample_82	0 / 2	2 / 2	2 / 2
Troca de maiúsculas e minúsculas sample_298	2 / 2	0 / 2	1 / 2

Acertos em duas tentativas por condição

> A intervenção pode recuperar respostas e perder outras.

Casos escolhidos depois de observar os resultados. Duas tentativas não estimam com precisão a chance de acerto de cada problema.

A medida mais elaborada não superou as simples

Associação entre a ordem das distâncias internas e das distâncias de erro:

Medida	Associação média
A0 · ângulo dos vetores	0,564
A1 · ângulo ajustado	0,556
A2 · resposta probabilística	0,441

Todas passaram os critérios de associação.

> A2 não passou a exigência adicional de superioridade. Observar uma associação não basta para demonstrar vantagem incremental.

Mais mudança de perfil não significou mais acertos

Nas 31 direções, a intensidade maior produziu maior distância de forma frente à referência.

Configuração	Acurácia média
Sem adição	45,50%
Intensidade menor · 0,25	46,76%
Intensidade maior · 0,50	44,96%

> A intensidade controla o tamanho da adição; não garante melhora de acurácia. Dois níveis não estabelecem uma curva geral.

Uma resposta simples já pode criar geometria?

Imagine que pequenas mudanças na intervenção alterem quase linearmente a chance de erro de cada problema.

$$q_i(c) \approx q_i(0) + b_i^T c$$

q_i: chance de erro; **0**: sem adição; **c**: coordenadas da intervenção; **b_i**: sensibilidade daquele problema.

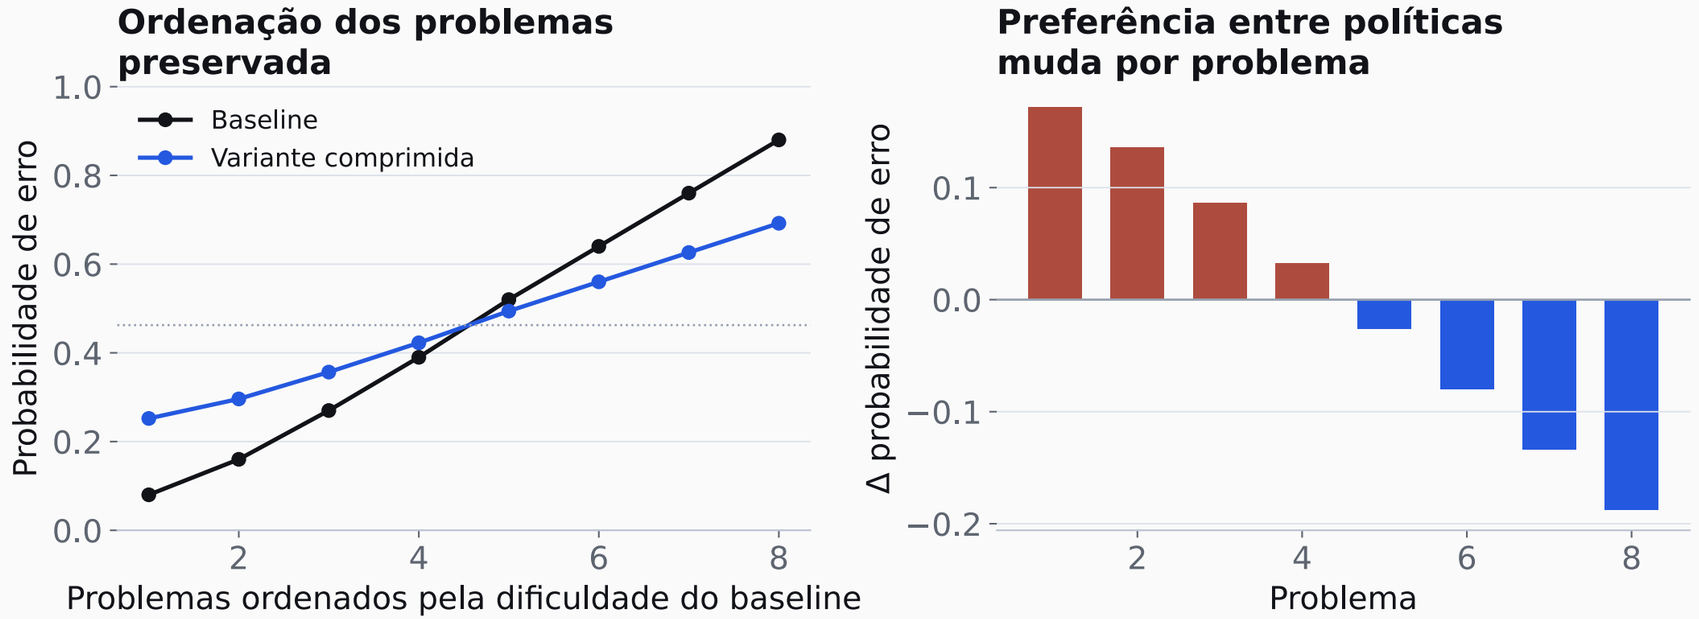
> Com sensibilidades igualmente distribuídas nas orientações, o ângulo já prevê a distância de forma.

Modelo reduzido; ainda não validado como explicação dos resultados.

APROFUNDAR [Um exemplo em que o ângulo funciona exatamente]

Complementaridade exige inverter a dificuldade?

Neste exemplo construído, a variante aproxima as chances de erro de sua média, sem mudar essa média nem a ordem de dificuldade.



q é a chance de erro. A variante piora os problemas fáceis e melhora os difíceis. Duas tentativas independentes dado o problema.

> Aqui, com médias iguais, C positivo é ganho da seleção com gabarito; não identifica habilidade específica.

APROFUNDAR [Quanto valeria saber qual tentativa acertou?] [A mesma distância garante o mesmo ganho?]

O que o trabalho já tornou mais preciso?

O que conta como resposta	Comparar o valor final, além do formato escrito.
Como intervir	Separar orientação, tamanho da adição e duração.
O que prever	Relações entre perfis de erro, além da acurácia média.
Até onde foi testado	Novas direções no mesmo modelo, tarefa e painel.

> Segue aberto por que o padrão aparece, se passa para outros contextos e como aproveitar a diferença sem gabarito.

APROFUNDAR [O trabalho mudou o que precisava ser testado] [O que as linhas posteriores ainda não resolveram]

Qual pergunta merece a próxima etapa?

Três caminhos, com requisitos diferentes:

Caminho	Pergunta
Explicar o padrão	Uma resposta simples à perturbação prevê o que observamos?
Testar o alcance	As relações persistem ao mudar problemas, tarefa ou modelo?
Usar as diferenças	Escolher uma variante antes de gerar melhora decisões sob um orçamento definido?

> São perguntas para discussão, sem prioridade ou novidade estabelecida.

APROFUNDAR [O que poderia virar uma contribuição?]

Quanto valeria saber qual tentativa acertou?

Com gabarito, aceite um acerto entre duas tentativas. Compare repetir o original com original + variante.

$$G = C + \mu_0(\mu_0 - \mu_j)$$

G: ganho de acerto; μ_0, μ_j: médias de erro; **C**: parcela do ganho além do termo das médias.

> Médias iguais: G = C. É uma oportunidade retrospectiva, sem regra de escolha utilizável.

Suposição: tentativas independentes dado o problema.

O que muda ao retirar a média?

Original: q_0. Variante: $q_j = 0{,}5 + m + a(q_0 - 0{,}5)$. m muda a média; a muda escala e sinal. Aqui, m = 0,00 e a = 0,00.

Perfis de erro

Versão	1	2	3	4
Original	0,20	0,40	0,60	0,80
Variante	0,50	0,50	0,50	0,50

Após subtrair cada média

Versão	1	2	3	4
Original – sua média	-0,30	-0,10	0,10	0,30
Variante – sua média	0,00	0,00	0,00	0,00

$$D_{total} = (1/n)\ \Sigma_i\ [q_j(i) - q_0(i)]^2$$

$D_{shape} = (1/n)\ \Sigma_i\ [(q_j(i) - \mu_j) - (q_0(i) - \mu_0)]^2$; i é o problema; n = 4

$$D_{total} = D_{shape} + (\mu_j - \mu_0)^2 = 0{,}0500 + 0{,}0000 = 0{,}0500$$

Erro médio original (μ_o): 0,50; variante (μ_j): 0,50. Dispersão original: 0,0500; variante: 0,0000. Dispersão é a média dos desvios ao quadrado; aqui, usamos divisor 4. Retirar a média preserva escala e sinal.

Quatro problemas com pesos iguais. μ é a média. D_{total} compara perfis; D_{shape} compara perfis centrados. Centrar mantém escala e sinal. Dispersão é a média dos desvios ao quadrado, com divisor 4. Definições de distância

Como medir distância com poucas tentativas?

Em cada problema, cada condição produz erro **1** ou acerto **0**. Repetimos a geração em dois blocos independentes.

$$\mathrm{E}[\delta_1\delta_2 \mid \text{problema}] = (q_j - q_k)^2$$

δ é a diferença entre os erros observados das condições em um bloco; **q** é sua chance de erro.

> O produto retira o viés do quadrado de uma só observação. Duas tentativas ainda deixam muita incerteza.

Por que 465 pares não são casos independentes?

31 direções → 465 pares

Os pares (1,2), (1,3) e (1,4) compartilham a direção 1.

Para testar a relação entre dois mapas de distâncias, trocamos as identidades das direções em um deles. Todas as relações de uma direção se movem juntas.

> Esse teste é a permutação relacional, chamada QAP. Não transforma pares em réplicas independentes nem demonstra generalização externa.

Reamostrar problemas cria novas respostas?

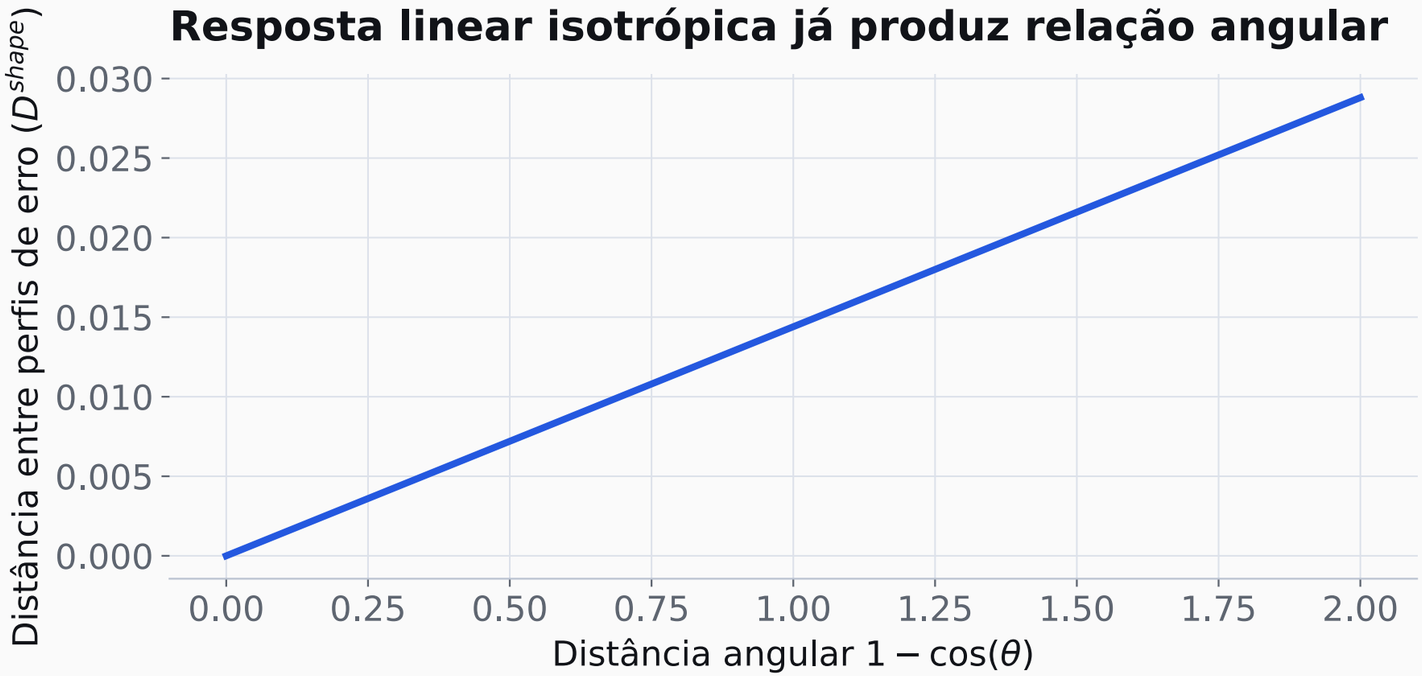
Não. Com duas tentativas por condição e problema, repetir um item na reamostragem reutiliza suas mesmas respostas.

O bootstrap muda o peso dos problemas e recalcula a relação. Nos diagnósticos deste estimador relacional, seus percentis não sustentaram a interpretação como intervalo de confiança convencional.

> Ficou como análise de sensibilidade à composição do painel. O teste principal das 16 direções novas é separado.

Um exemplo em que o ângulo funciona exatamente

Quatro problemas construídos têm chances de erro que variam linearmente em duas coordenadas de intervenção.



O eixo horizontal compara ângulos; o vertical, perfis depois de retirar suas médias.

> A relação vem da construção matemática. Não é ajuste aos dados CEG nem explicação validada do modelo real.

Como comparar steering, prompts e ajuste de pesos?

Proposta ainda não executada: original, bons prompts, steering, ambos e LoRA.

- Mesma distribuição de problemas e avaliação reservada.
- Contar desenvolvimento, seleção e geração no orçamento relevante.
- Medir uma decisão utilizável, sem consultar o gabarito.

> LoRA aprende pequenos ajustes nos pesos. Nenhuma abordagem é presumida mais barata ou superior; repetir o original também entra na comparação.

O que poderia virar uma contribuição?

São possibilidades diferentes para o mesmo programa:

Possibilidade	O que precisaria sustentar
Evidência empírica	Uma relação delimitada, testada em novas direções.
Explicação	Previsões que diferenciem mecanismos, além da forma quadrática conhecida.
Utilidade	Uma escolha realizável que acrescente ganho frente a bons comparadores.

> Precisam ser confrontadas com a literatura e os limites dos testes. Não estabelecem novidade, prioridade ou aceitação.

Três estados que não podemos misturar

Estado	Significado
Negativo sob a regra	O teste terminou e não atendeu seu critério.
Inconclusivo	A evidência não separa as explicações.
Não avaliado	A comparação pretendida não foi completada.

A mesma intervenção na tarefa nova falhou o critério. A especificidade geométrica ficou inconclusiva. Na etapa de uso, a avaliação não passou as condições mínimas e a confirmação não começou.

> Falha operacional não prova ausência do fenômeno.

Cada controle enfrenta uma dúvida diferente

Comparador	Dúvida
Repetir o original	Quanto muda só por sortear outra resposta?
Prompt cuidadoso	O texto de origem já oferece benefício?
Quatro direções controle	Outras direções, com o mesmo tamanho e local, também funcionam?
Espaços alternativos	A relação Q2 depende do espaço construído?

> Q1 compara um controlador fixo com direções aleatórias; o piloto posterior troca o espaço inteiro. São objetos e limites diferentes.

O que A1 e A2 acrescentam ao ângulo comum?

Comparamos intervenções antes de consultar os acertos.

A1: ângulo reponderado	64 estados internos sem adição dão pesos às coordenadas conforme suas variações e correlações.
A2: efeito nos próximos tokens	12 textos, cada um em 4 posições fixas, comparam as mudanças nas distribuições sobre o próximo token.

Em A2, o ângulo relaciona deslocamentos em relação ao original. As probabilidades usam o vocabulário completo, antes dos filtros de amostragem.

> Isso não mede a geometria de toda a geração nem garante acerto final.

O trabalho mudou o que precisava ser testado

Dificuldade	Mudança de desenho
Distinguir formatos	Comparar o valor final da resposta.
Encontrar um efeito	Separar posição, tamanho e duração da adição.
Comparar poucas estratégias	Criar muitas direções num espaço definido.
Explicar um conjunto já visto	Congelar previsões e avaliar novas direções.

> Foram testes e dificuldades sucessivas. Há sucessos delimitados, resultados negativos e instrumentos que não qualificaram; os registros completos ficam nas notas e no guia.

O que as linhas posteriores ainda não resolveram

Pergunta	Estado
Maior intensidade só amplia o efeito?	Uma única escala de resposta não captura tudo; inversões na ordem dos problemas não demonstradas.
Limitar a geração explica o ganho?	Estudo posterior com raciocínio habilitado: inconclusivo.
Quando aparece a resposta final?	Plano e implementação, sem resultado estabelecido.

> São regimes e perguntas diferentes. Não ampliam retroativamente o resultado entre direções nem mostram por que ele ocorre ou se o comprimento gerado explica o ganho.

A mesma distância garante o mesmo ganho?

Dois problemas com pesos iguais; s = 0,20. Todas as médias de erro são 0,50.

Versão	Chances de erro	D_{shape} ao original	C	Acerto com gabarito
Original	(0,20; 0,80)	—	—	66%
A	(0,40; 0,60)	0,0400	+0,0600	72%
B	(0,00; 1,00)	0,0400	-0,0600	60%

$$C = \tfrac{1}{2}\,[D_{shape} + \text{dispersão do original} - \text{dispersão da variante}]$$

Dispersão: média dos desvios ao quadrado, com divisor 2. Com médias iguais, C é o ganho da seleção com gabarito. Original usa duas chamadas; A/B usam original + variante.

A seleção com gabarito aceita qualquer tentativa correta. Precisamos de outra regra para escolher sem o gabarito.

D_{shape}: distância após retirar as médias. C: complementaridade relativa ao original. Seleção com gabarito após gerar. Duas chamadas independentes dado o problema. Exemplo exato e identidade

Como chegamos ao controlador final

Decisão no desenvolvimento	O que foi feito
Camada	Exploramos seis blocos fixados previamente. Um protocolo posterior fixou o índice 27 como candidato de camada única e exigiu testes da fonte.
Duração	Comparamos adição única e sustentada em etapas anteriores, com outro controlador. O teste final usou a sustentada.
Intensidade	D75 passou a calibração de desenvolvimento antes de abrir os 57 problemas confirmatórios.

> O teste final avalia esse conjunto de escolhas. Não isola o mérito de cada escolha nem prova que a camada seja ótima.

Os quatro cruzamentos reutilizam as mesmas respostas

A, B: registros de erro nas duas respostas do original. **V, W:** nas duas com steering. **1 = erro; 0 = acerto.**

Original × steering	V	W
A	A × V	A × W
B	B × V	B × W

Repetir o original usa A × B. O par misto usa a média dos quatro produtos.

> Não são quatro amostras independentes. Para C, usamos ainda produtos entre problemas diferentes, detalhados nas notas.

Usar sem gabarito ainda é usar o problema

Função na campanha Q2	Problemas	Finalidade
Construção	24	Calcular diferenças de ativação.
Validação da fonte	24	Verificar contraste e canal de resposta.
Calibração	12	Fixar tamanho e qualificar intervenções.
Variação ordinária · A1	64	Estimar como as ativações variam.
Sondagens de saída · A2	12	Comparar probabilidades de próximos tokens.
Avaliação principal	300	Medir acertos e erros; painel histórico.

Os conjuntos têm funções separadas e são disjuntos entre si nessa campanha. “Sem gabarito” não significa “nunca utilizado na história do projeto”.

O que pode mudar com os pesos fixos?

Mesmos pesos

As regras aprendidas de transformação permanecem.

Estado alterado

Somamos um vetor a uma representação intermediária.

Continuação diferente

As próximas probabilidades e a resposta podem mudar.

Isso permite mudar como a computação usa a informação disponível. O vetor também depende da informação usada para construí-lo.

> Não demonstramos conhecimento novo, uma habilidade isolada ou um comportamento impossível de obter com qualquer prompt.

Controle de ativações em outros modelos

Modelo	O que foi manipulado	Exemplo de efeito
Rede recorrente de texto	Uma unidade interna.	Sentimento das avaliações geradas.
Gerador adversário de imagens	Grupos de unidades.	Inserir ou remover objetos em cenas.
Modelo de difusão de imagens	Transformações das ativações.	Estilo e presença de elementos.
Modelo de vídeo	Trajetos entre estados internos.	Posição física em Mountain Car.

> A ideia é ampla. A representação, a intervenção e a medida precisam acompanhar cada arquitetura.

Radford et al. · 2017 · GAN Dissection · 2019 · Activation Transport · ICLR 2025 · Manifold Steering · 2026

Como o RFM encontra uma direção

RFM, Recursive Feature Machine: aprende características úteis a um preditor.

1. Guardar estados internos de exemplos com rótulos.
2. Treinar um preditor para distinguir os rótulos em cada bloco.
3. Medir em quais orientações o preditor é mais sensível.
4. Extrair uma direção dominante e testar a adição no modelo.

> Aprender a reconhecer um conceito e conseguir controlá-lo exigem avaliações diferentes.

Beaglehole et al. · método e apêndice A

Três trajetos no Manifold Steering

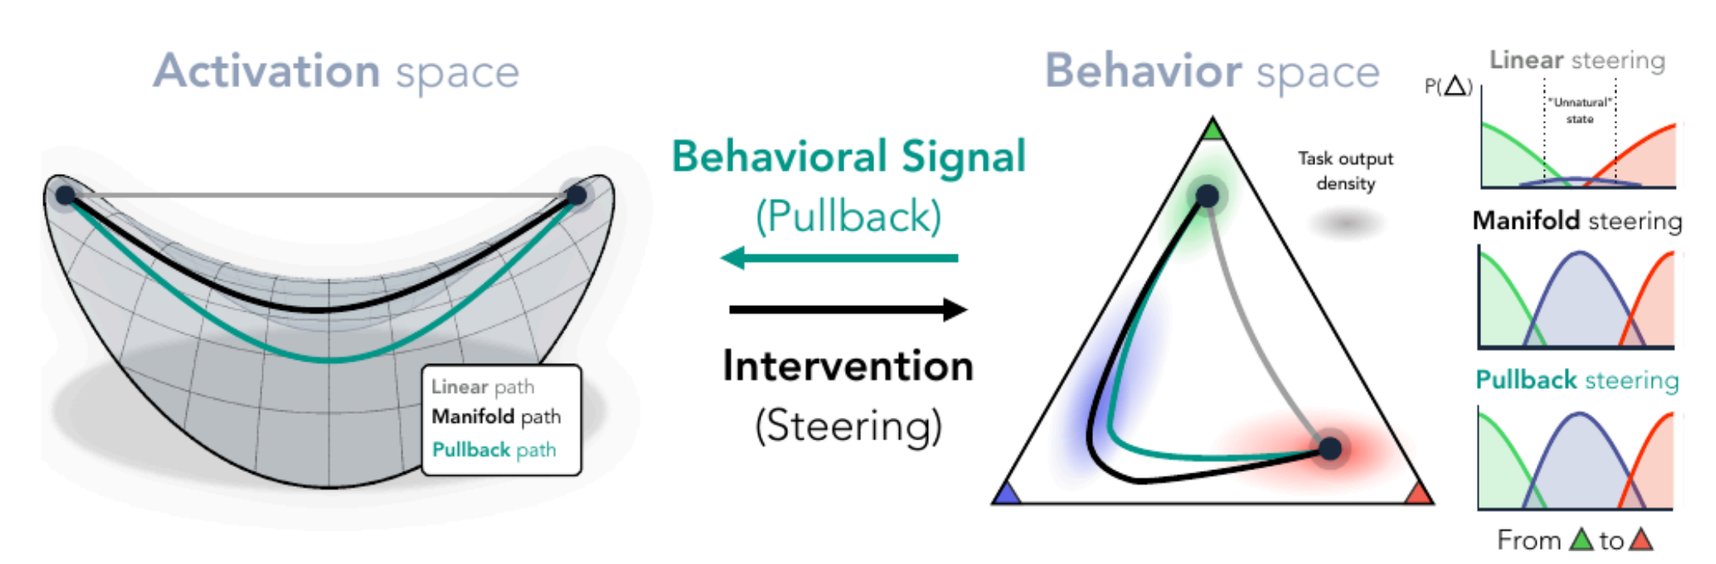


Figura 1 do artigo, esquema. Esquerda: estados internos. Direita: distribuições das saídas.

Cinza: reta entre estados. **Preto:** curva ajustada aos estados naturais. **Verde:** trajeto interno ajustado a partir das saídas, chamado *pullback*.

Manifold é a curva ou superfície ajustada. Os gráficos pequenos mostram como a probabilidade passa entre três respostas.

Wurgaft et al. · Figura 1 e §3 · fonte original

O custo das duas variantes de COLD-Steer

Gradiente: sensibilidade de um critério de erro a pequenas mudanças.

Variante	Preparação nos exemplos	Para uma entrada nova
Kernel	Gradientes dos estados.	Uma passagem e combinação dos sinais dos exemplos.
FD · diferenças finitas	Gradientes de parâmetros; guardar sua soma.	Duas avaliações auxiliares: parâmetros originais e levemente perturbados.

> “Duas passagens” não inclui toda a preparação. O método aproxima um passo de aprendizado.

Sharma e Trivedi · §§3.1–3.3 · Tabela 1