CAUSAL EPISTEMIC GEOMETRY · ACS-USP

Intervenções internas e a estrutura dos erros de um LLM

Resultados, limites e perguntas para continuar investigando

Gabriel · Entropic Session · 16 de outubro de 2026

Controle dos perfis de erro

Até que ponto conseguimos controlar e prever quais problemas um modelo congelado acerta e erra?

O objeto é um perfil de desempenho por problema, sob uma política de geração definida.

> A mesma acurácia média pode acompanhar perfis de erro diferentes.

Três perguntas do programa

Controle	Uma intervenção muda quais problemas falham, além de repetir o baseline?
Geometria	Relações entre intervenções antecipam relações entre perfis de erro?
Utilidade	Um mecanismo realizável consegue aproveitar essa complementaridade?

Cada pergunta tem uma unidade de análise e um teste próprio.

O que a evidência atual sustenta

16 / 16

direções novas com associação geométrica positiva frente ao atlas histórico

Há controle de perfil no teste confirmatório do Qwen.

Há estrutura relacional no banco e em direções novas.

> Generalidade entre tarefas, especificidade do espaço e ganho coletivo permanecem delimitados ou abertos.

Steering, prompting e adaptação dos pesos

Intervenção	O que muda diretamente	Pesos e escopo
Prompt	Instrução e contexto na sequência de entrada; também alteram ativações	Pesos fixos. Pode ser combinado com steering.
Steering	Adição nominal na saída do bloco 27; direção, dose, site e duração controlados	Pesos fixos. Vetor de contrastes de prompts; texto baseline fixo na avaliação.
LoRA	Adaptação aprendida $\Delta W = BA$, escala absorvida; efeito BAx depende da representação x	Base compartilhada e fixa; peso efetivo $W_0 + BA$. Comparador proposto, não executado aqui.

Os métodos podem ser combinados; políticas de prompts também admitem famílias contínuas. Compare baseline repetido, prompts fortes, steering e adaptações, contando construção, seleção, treinamento e inferência.

Steering permite controlar uma adição interna, mantendo o prompt de avaliação fixo. Superioridade prática exige comparação.

Comparação conceitual; LoRA não foi executado neste projeto. O benefício incremental exige comparar prompts fortes, steering e adaptações sob orçamento definido.
Apoio: experimento justo ↗

Como o desenho foi ficando mais preciso

Problema encontrado	Resposta experimental
Artefatos da superfície de resposta	Revisão do instrumento e avaliação semântica
Origem, aplicação e persistência do vetor	Testes de source, camada, dose e duração
Intensidade podia explicar a associação	Doses calibradas e pergunta angular
Poucas unidades do lado das intervenções	Subespaço e banco de direções amostradas
Relação restrita às identidades conhecidas	Validação prospectiva com direções novas

APROFUNDAR [Quatro mudanças de desenho que custaram trabalho]

O laboratório experimental

Qwen3-8B congelado

Predição de saídas de programas Python no CRUXEval

Correção objetiva após avaliação semântica do valor final

Q2: painel fixo de 300 problemas

Mesma camada, prompt de tarefa, avaliação e política de geração entre condições

> O Q2 final usa `enable_thinking=false`.

Respostas observadas no mesmo problema

```
def f(a, b, c, d):
    return a and b or c and d
```

Input: `'CJU', 'BFS', 'WBYDZPVES', 'Y'`

Referência: `'BFS'`

Condição	Tentativa 1	Tentativa 2
Baseline	`Y`	`CJU`
Steering D75	`BFS`	`'BFS'`
Prompt CAREFUL	`BFS`	`'BFS'`

> O prompt também acertou este caso. Há casos observados no sentido inverso.

Qwen, Q1 · sample_82 · seleção pós-hoc · duas gerações por condição.

Uma resposta precisa passar por três perguntas

Compromisso	O modelo entregou um valor final identificável?
Avaliabilidade	Esse valor pode ser interpretado pelo contrato semântico?
Correção	O valor corresponde à execução de referência?

O Q2 conta respostas erradas, inválidas e truncadas como erro; linhas ausentes bloqueiam a análise.

A direção confirmatória de Q1

$$v = \text{unit}\,[\,\text{média de } 104 \text{ contrastes CAREFUL} - \text{DIRECT}\,]$$

- Mesmos problemas nas duas condições de fonte
- Captura no último token do prompt, saída de L27
- 32 itens separados para validar a fonte
- Sem usar correção ou respostas geradas para estimar v
- D75: 75% da dose histórica, após calibração em desenvolvimento

> Esta direção é anterior e distinta das oito fontes do Q2.

Quatro contrastes de instruções

Família	Política positiva	Política negativa
Fluxo de controle	Enumerar e reconciliar caminhos	Seguir o caminho mais aparente
Mutação e aliasing	Acompanhar alterações e referências	Tratar atualizações localmente
Fronteiras de loops	Auditar iterações e término	Seguir o padrão geral
Hipóteses	Manter e eliminar candidatos	Assumir o primeiro plausível

Paráfrases para leitura. Os prompts completos e seus bytes definem o experimento.

APROFUNDAR [A direção confirmatória de Q1]

Duas posições de captura

As instruções +/− são system prompts para o mesmo problema i e família f. Cada prompt tem comprimento $P_{\pm}$ próprio; a continuação fixa tem T tokens. Capturamos a saída do bloco 27.

Condição	Sequência processada	Prompt boundary	Execution boundary
+	$x_1^+ \dots xP^+ \cdot t_1 \dots tT$	h^+ em xP^+ Índice $P_+ - 1$	h^+ em tT Índice $P_+ + T - 1$
−	$x_1^- \dots xP^- \cdot t_1 \dots tT$	h^- em xP^- Índice $P_- - 1$	h^- em tT Índice $P_- + T - 1$

```
teacher_ids = encode(text, add_special_tokens=False)
full_ids = prompt_ids + teacher_ids
```

Continuação fixa · teacher forcing

I will now apply the requested reasoning policy to the program before committing to one answer.

Índices com base zero. Uma forward completa, sem cache, por condição captura ambas as posições. Não há geração livre nem retokenização de uma string combinada.

Quatro famílias × duas posições = oito fontes. Esquema de posições, sem tokens ou comprimentos medidos. Captura não é fase nem site de aplicação. Captura Q2, linhas 259–302

Das ativações ao subespaço de intervenção

Etapa	Operação	Definição
1 · Pares	Mesmos 24 problemas, para cada família f e posição s	$d_{i,f,s} = h^{+}_{i,f,s} - h^{-}_{i,f,s}$
2 · Fonte unitária	Média das diferenças, depois normalização L2	$\bar{d}_{f,s} = (1/24)\ \Sigma_i\ d_{i,f,s}$ $u_{f,s} = \bar{d}_{f,s} / \lVert \bar{d}_{f,s} \rVert_2$
3 · Base SVD	Oito fontes em $U \in \mathbb{R}^{4096\times 8}$; posto observado 8	$U = L\Sigma R^{T}$; reter $\sigma_k/\sigma_1 \geq 10^{-6}$ $Q = L_{retido} \in \mathbb{R}^{4096\times 8}$; $Q^{T}Q = I_8$
4 · Combinação	Coeficientes unitários; isotropia apenas no subespaço	$g_j \sim N(0, I_8)$ $c_j = g_j/\lVert g_j \rVert_2$; $v_j = Qc_j$

Quatro famílias × duas posições = oito fontes. A média pareada precede a normalização; U não precisa ter colunas ortogonais. Q fornece coordenadas, não significados cognitivos. A lei isotrópica é anterior à qualificação: 40 candidatos sorteados deram 31 direções qualificadas.

31 direções não significam 31 conceitos. 40 candidatos sorteados → 31 qualificados. Esquema de matrizes; sem novo sorteio nem valores medidos. Construção Q2 e fontes imutáveis · Geometrias: A0, A1 e A2

Site, dose e duração

δ é uma adição na saída de L27. Os logits após os blocos seguintes definem a distribuição de amostragem.

Chamada	Entrada	Posição com +δ	Próximo token amostrado
Prefill	Prompt inteiro x_1 … xP	xP, último não-padding	g_1
Decode 1	g_1	Corrente, em g_1	g_2
Decode 2	g_2	Corrente, em g_2	g_3

$$h^{(27)}_p \leftarrow h^{(27)}_p + \alpha_{j,s} v_j$$

As chamadas decode ocorrem se a geração continuar. O hook não reescreve K/V já calculados em L27. Os blocos seguintes podem mudar o cache produzido adiante.

δ nominal fixo por condição. Em BF16, o incremento realizado pode variar com o estado. Q2: alvos 0,25 e 0,50 com RMS baseline congelado. Regime serial, batch 1, com cache qualificado. Hook L27, linhas 28–109 · D75: seleção da dose

A formação do banco de direções

40 → 31

Uma amostra de candidatos; 31 passaram os critérios de integridade nas duas doses.

O banco foi fixado antes da avaliação semântica do painel.

> A análise é condicional às direções qualificadas nesse subespaço.

31 direções × 2 doses + baseline = 63 condições

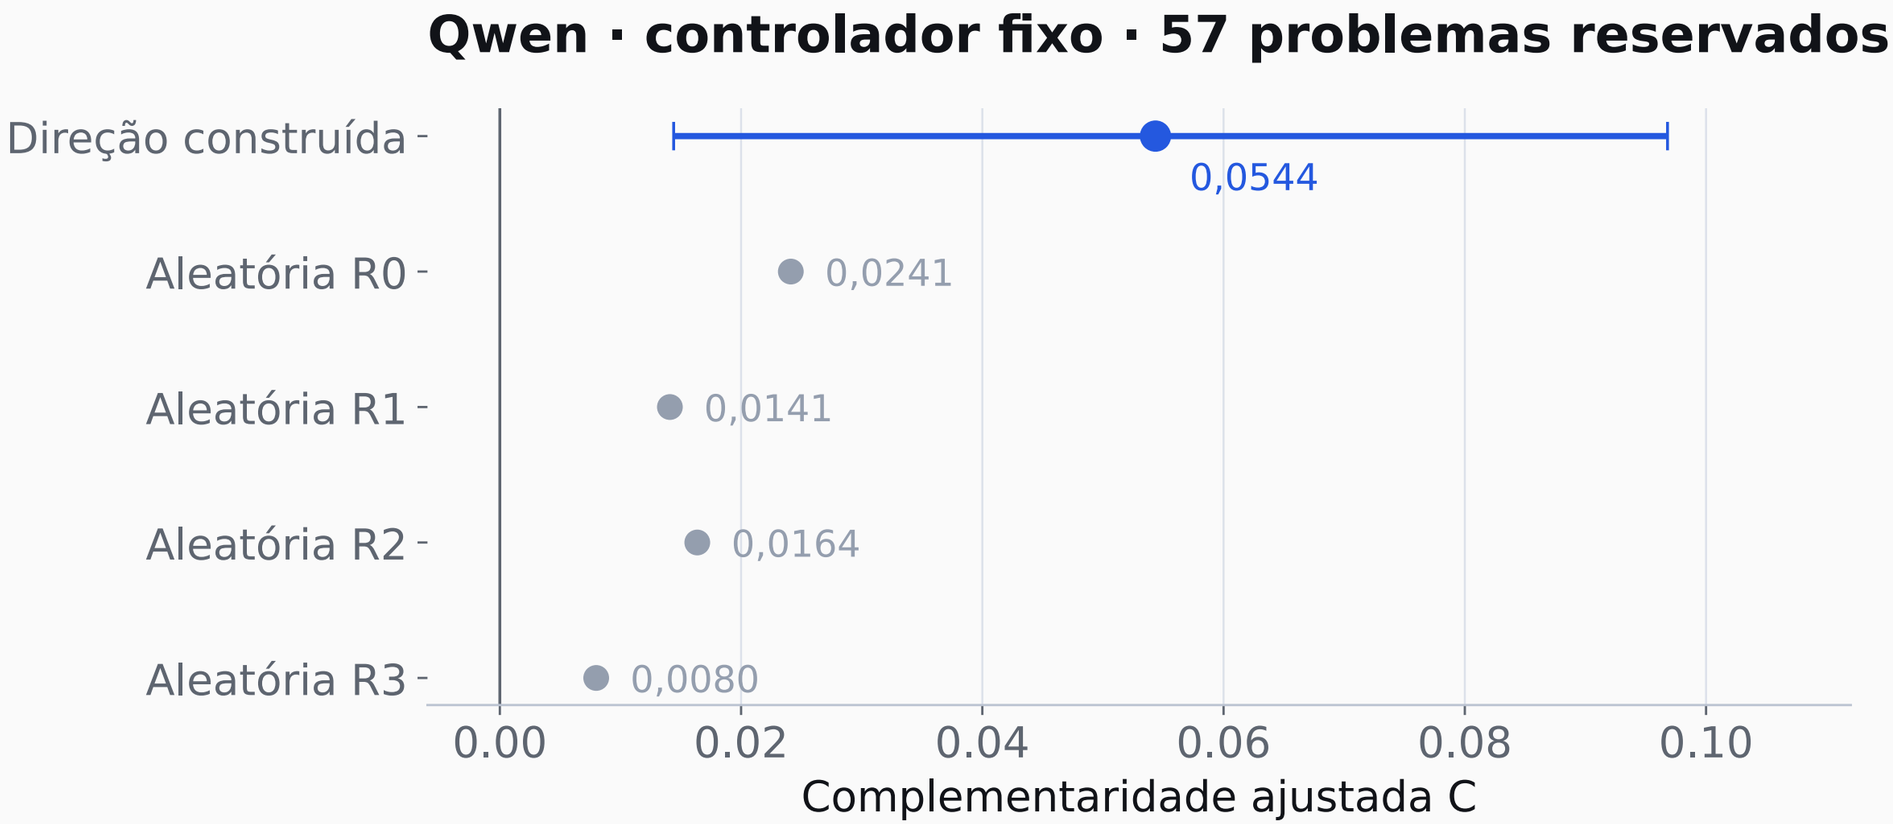
O que medimos em cada problema

$q_j(i)$: probabilidade de erro da condição j no problema i

Quantidade	Pergunta
Acurácia média	A condição acerta mais no painel?
Rescue / damage	Que acertos ganhamos e perdemos frente ao baseline?
Complementaridade C	Qual componente da mudança excede a diferença média de competência?
D^{shape}	Quanto a forma do perfil muda, removendo seu deslocamento médio?

APROFUNDAR Oracle, competência e complementaridade · Distância total e mudança de forma · Por que duas repetições entram no estimador

Q1 · complementaridade no controlador fixo



Qwen, 57 problemas reservados. Acurácia: 43,86% → 50,00%. Contraste C – média dos controles: 0,03871.

APROFUNDAR [Respostas observadas no mesmo problema] [A direção confirmatória de Q1] [D75: o que foi selecionado, e por quê] [Que pergunta cada controle responde?]

Geometrias definidas antes dos acertos

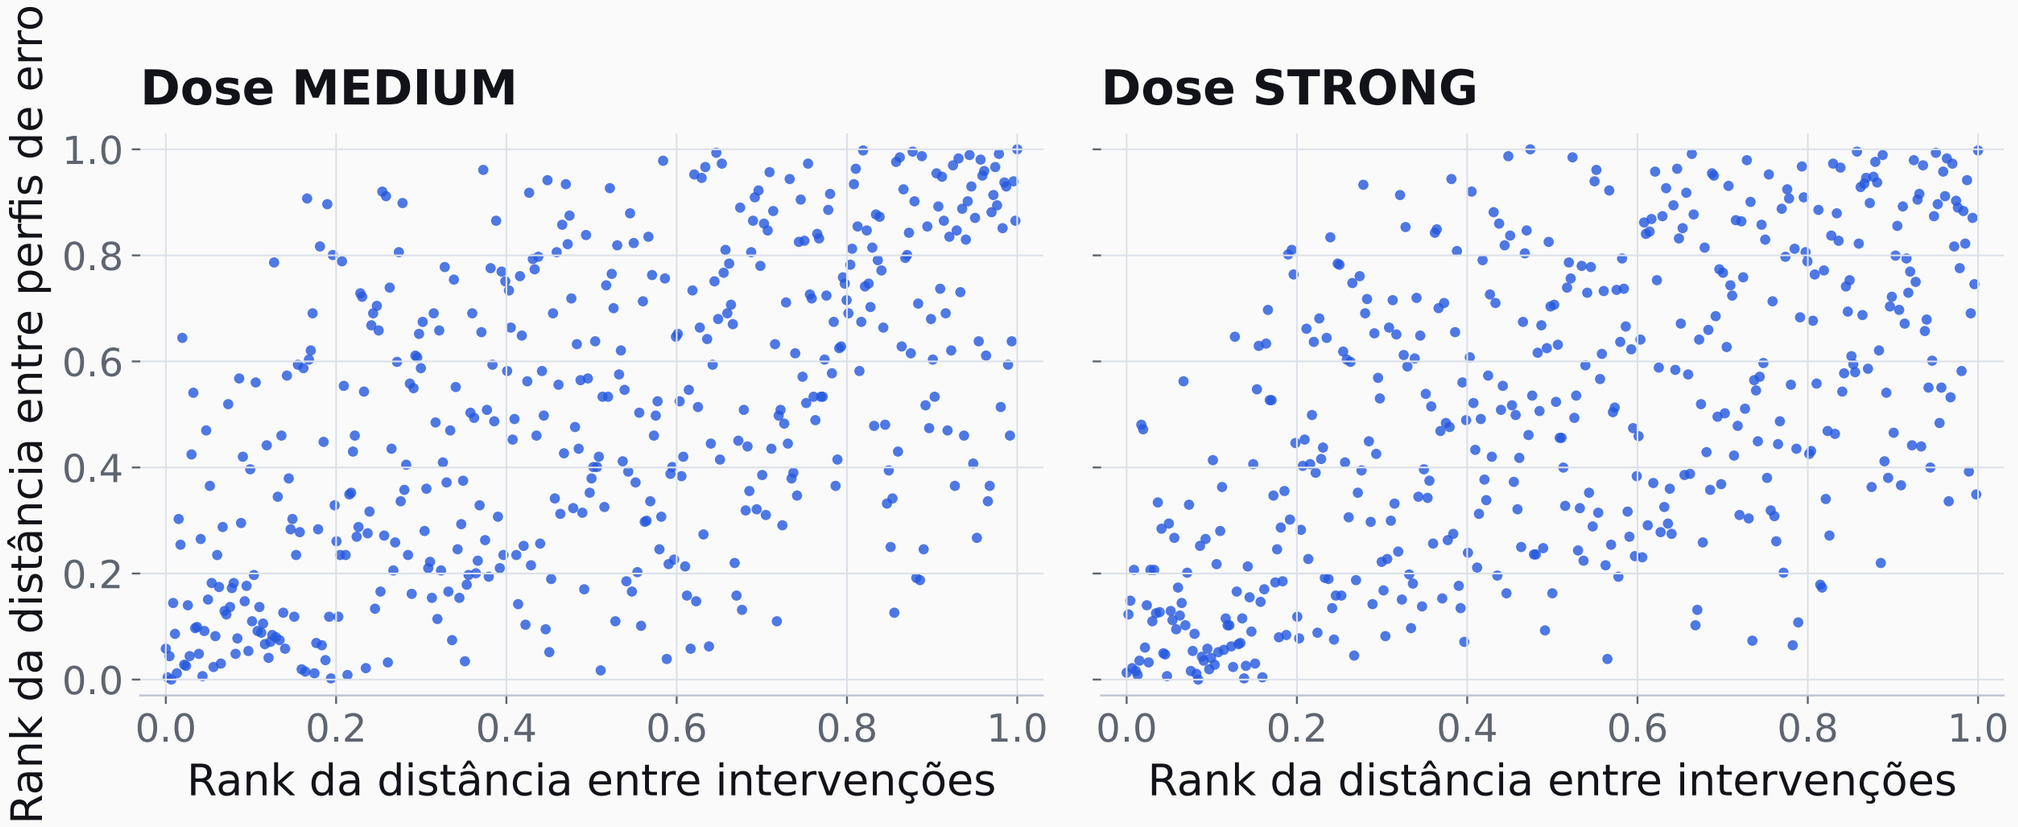
Preditor	Informação utilizada
A0 · coordenadas	Ângulo entre direções de intervenção
A1 · ativações	Geometria ponderada por estatísticas de ativação
A2 · resposta	Relações entre mudanças nas distribuições de saída

> Pré-outcome semântico não significa pré-intervenção.

A2 utiliza resposta label-free a intervenções; não é uma Fisher estimada por derivada infinitesimal.

APROFUNDAR [A1 e A2: construções operacionais]

Q2 · associação no banco histórico



31 direções, 300 problemas, duas repetições por condição. 37.800 gerações. A0 agregado: ρ ≈ 0,564.

APROFUNDAR [Pares compartilham direções]

A geometria mais elaborada não foi a melhor

Geometria	ρ agregado	Resultado
A0 · coordenadas	0,564	Associação qualificada
A1 · ativações	0,556	Associação qualificada
A2 · resposta	0,441	Associação qualificada; sem superioridade

> Há estrutura previsível, mas a hipótese de superioridade funcional proposta não recebeu apoio.

Dose maior move mais; acertar mais é outra questão

31 / 31

direções com maior deslocamento de forma em STRONG que em MEDIUM

Condição	Acurácia média
Baseline	45,50%
MEDIUM	46,76%
STRONG	44,96%

> As duas doses oferecem controle de intensidade, sem uma melhora monotônica de competência.

Validação com direções novas



19.200 gerações. Teste primário por direção nova: 16/16 positivos; p binomial unilateral nominal = 1,53 × 10^{-5}.

APROFUNDAR [Pares compartilham direções] [O diagnóstico do bootstrap]

O alcance da generalização

MUDOU

A identidade da direção de intervenção

PERMANECEU FIXO

Modelo · tarefa · painel de problemas

Camada · subespaço · doses · atlas

> As relações generalizaram dentro desse laboratório. Outras dimensões exigem testes próprios.

Transferência e o comparador textual

ACURÁCIA OBSERVADA

Coleta	Baseline	Steering fixo	Prompt CAREFUL
Q1 · CRUXEval 57 problemas	43,86%	50,00%	73,68%
LiveCodeBench 130 famílias	66,92%	59,62%	72,88%

Acurácias descritivas; uso realizado de tokens não pareado. Em LiveCodeBench, o controlador fixo não passou o critério completo de transferência.

> A vantagem sobre prompting continua sendo uma pergunta experimental.

O subespaço construído é especial?

Um piloto comparou o espaço original com duas orientações aleatórias.

Espaço	Associação observada
Original	0,418
Aleatório 1	0,018
Aleatório 2	0,248

> O contraste pré-definido ficou inconclusivo. Escala de resposta e repetibilidade diferiram entre os espaços.

19.512 trajetórias registradas no piloto. Duas orientações aleatórias limitam a conclusão populacional.

APROFUNDAR [Que pergunta cada controle responde?]

Uma explicação concorrente para a geometria

$$q_i(c) \approx q_i(0) + b_i^T c$$

$$D^{shape}(c,d) \approx (c-d)^T \, Cov_i(b_i) \, (c-d)$$

Se a sensibilidade for aproximadamente isotrópica e as normas forem iguais:

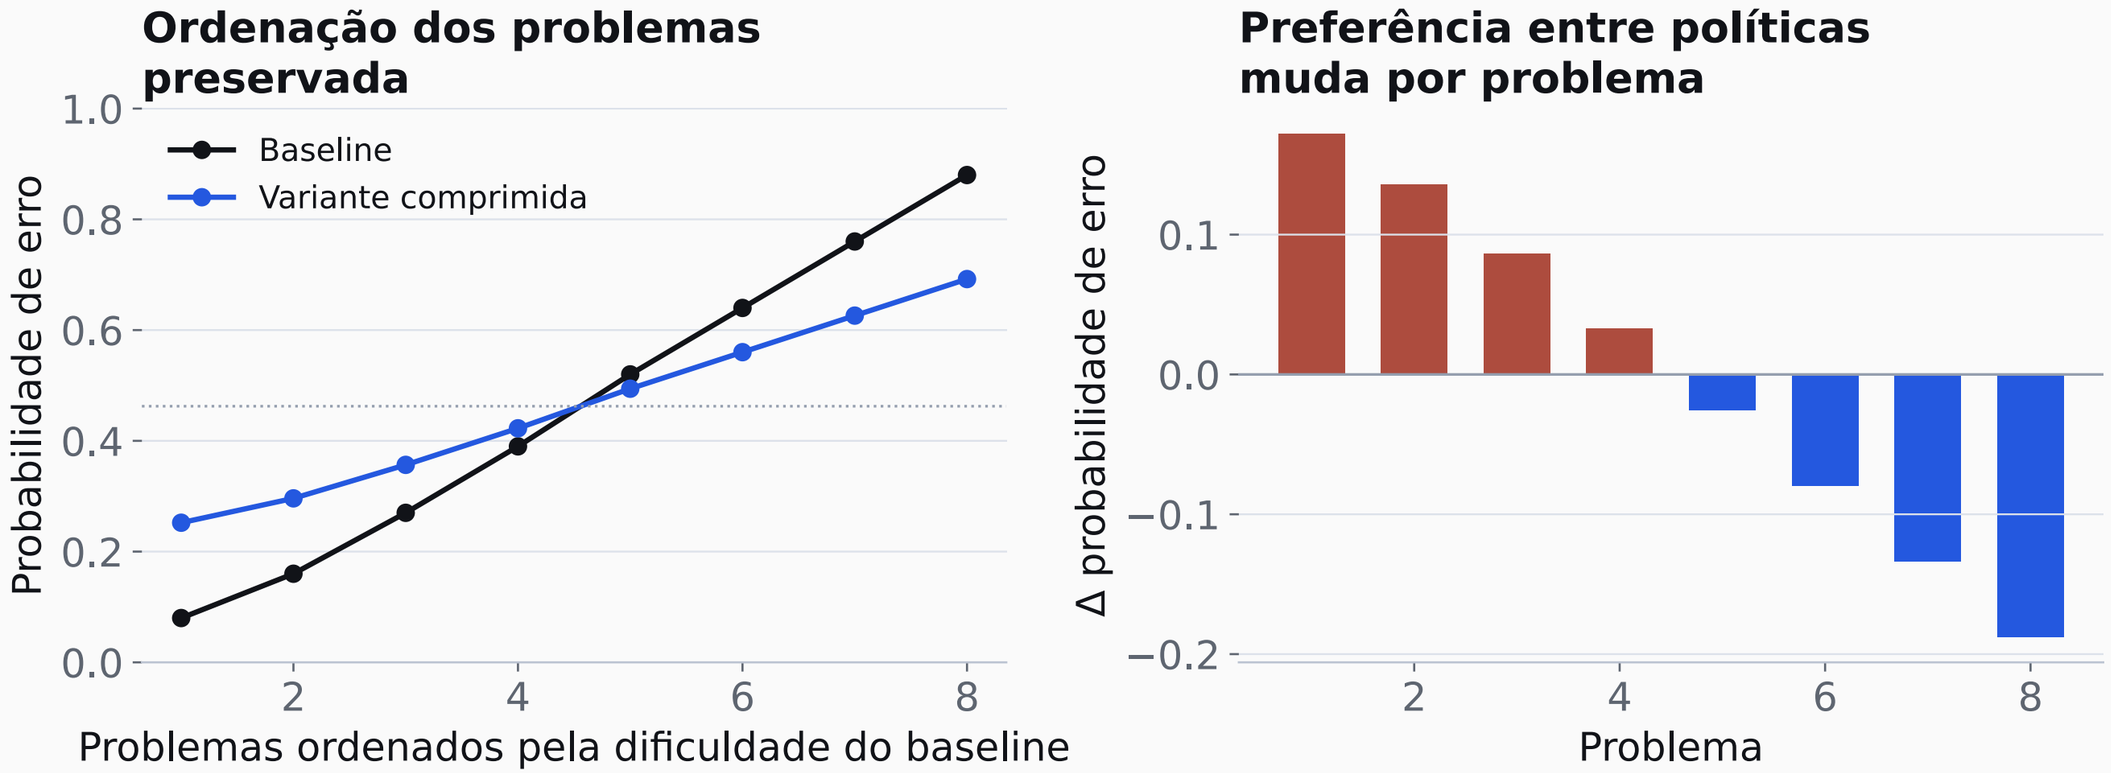
$$D^{shape} \propto 1 - \cos\theta$$

> Uma resposta regular a perturbações já pode gerar associação angular.

Dedução em um modelo reduzido; ainda não validada como explicação dos dados CEG.

APROFUNDAR [Exemplo exato de resposta linear]

O significado de complementaridade



Exemplo matemático, não dados CEG. C positivo e ganho de oracle podem coexistir com a mesma ordenação de dificuldade dos problemas.

APROFUNDAR [Oracle, competência e complementaridade] [Mesma distância, ganhos de oracle opostos]

A etapa da utilidade coletiva

Como escolher ou agregar respostas sem conhecer o gabarito?

Um banco complementar pode oferecer headroom para um oracle.

Seleção realizável exige informação disponível antes da resposta final e avaliação em problemas reservados.

> Os estudos acumulados ainda não demonstram utilidade prospectiva de roteamento.

APROFUNDAR [Mesma distância, ganhos de oracle opostos] [Uma comparação de valor incremental]

O que as iterações ensinaram

- A definição do instrumento muda o que podemos concluir.
- Direção, dose e duração são escolhas experimentais independentes.
- Relação geométrica, mecanismo e utilidade têm exigências de evidência diferentes.
- A generalização mais forte atual é entre direções dentro do laboratório fixo.

> O programa ganhou um objeto mensurável e limites que orientam as perguntas seguintes.

APROFUNDAR [Quatro mudanças de desenho que custaram trabalho] [Linhas posteriores: resultados e estados]

Três caminhos para aprofundar

Caminho	Pergunta que o orienta
Explicação do mapa de resposta	O que uma aproximação simples prevê e onde ela falha?
Generalização do perfil de erro	Quais relações sobrevivem em problemas ou apresentações novos?
Valor incremental das variantes	Steering acrescenta utilidade a bons prompts sob o mesmo orçamento?

Candidatas de pesquisa a qualificar frente aos antecedentes; não são reivindicações de novidade.

APROFUNDAR [Contribuições e possibilidades de publicação]

Discussão

Que explicação concorrente vale enfrentar primeiro?

Que resultado mudaria nossa interpretação do mapa entre intervenção e erro?

Qual dimensão nova de generalização acrescentaria mais conhecimento?

Os apêndices permitem aprofundar métodos, estimandos e caminhos de pesquisa.

Oracle, competência e complementaridade

Usando q para probabilidade de erro e μ para sua média:

$$G = E[q_o^2 - q_o q_j]$$

$$C = Var(q_o) - Cov(q_o, q_j)$$

$$G = C + \mu_o(\mu_o - \mu_j)$$

> Se as médias de erro forem iguais, G = C.

Distância total e mudança de forma

$q_j = 0{,}5 + m + a(q_0 - 0{,}5)$, com $m = 0{,}00$ e $a = 0{,}00$.

Perfis de erro

Perfil	1	2	3	4
q_o	0,20	0,40	0,60	0,80
q_j	0,50	0,50	0,50	0,50

Após subtrair cada média

Perfil	1	2	3	4
$q_o - \mu_o$	-0,30	-0,10	0,10	0,30
$q_j - \mu_j$	0,00	0,00	0,00	0,00

$$D_{total} = (1/n)\ \Sigma_i\ [q_j(i) - q_0(i)]^2$$

$$D_{shape} = (1/n)\ \Sigma_i\ [(q_j(i) - \mu_j) - (q_0(i) - \mu_0)]^2, n = 4$$

$$D_{total} = D_{shape} + (\mu_j - \mu_0)^2 = 0{,}0500 + 0{,}0000 = 0{,}0500$$

$\mu_o = 0{,}50$; $\mu_j = 0{,}50$. VarPOP(q_o) = 0,0500; VarPOP(q_j) = 0,0000. Centrar preserva escala e sinal.

Exemplo construído com quatro itens equiprováveis. q é probabilidade de erro. VarPOP: divisor 4. Definições de distância

Por que duas repetições entram no estimador

Para cada problema, $\delta_{ir} = e_{ijr} - e_{ikr}$, com r = 1,2.

$$E[\delta_{i1}\,\delta_{i2} \mid i] = (q_j(i) - q_k(i))^2$$

O produto de blocos independentes estima a diferença quadrática das propensões.

> Uma estimativa não viesada não garante ranks precisos ou intervalos calibrados.

Pares compartilham direções

31 direções → 465 pares

Os pares (1,2), (1,3) e (1,4) compartilham a direção 1.

$$D \rightarrow P_{\pi} D P_{\pi}^{T}$$

> QAP permuta identidades inteiras; não embaralha cada par como uma observação independente.

O diagnóstico do bootstrap

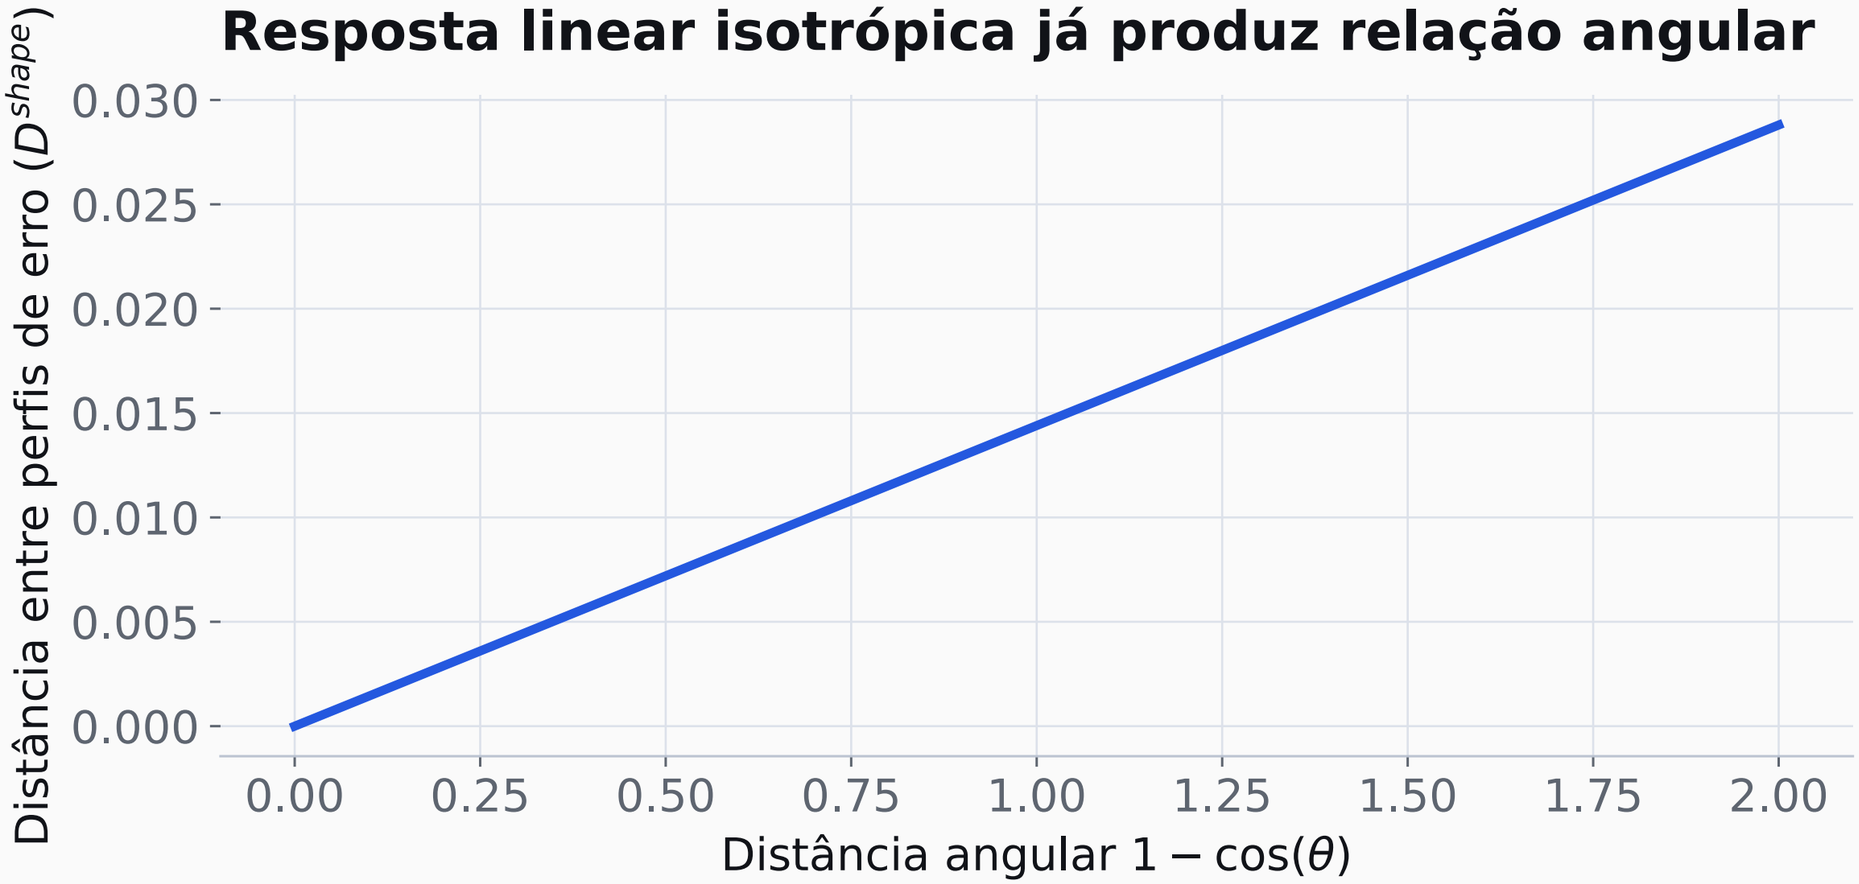
As reamostragens por item reproduziram a implementação histórica.

Os percentis não se mostraram calibrados como um intervalo de confiança convencional para o estimador composto.

> A interpretação atual é sensibilidade à reponderação do painel.

O resultado primário por direção nova permanece separado desse diagnóstico.

Exemplo exato de resposta linear



Exemplo construído: quatro problemas, duas coordenadas, probabilidades válidas. Não é ajuste aos dados CEG.

Uma comparação de valor incremental

Baseline · prompts fortes · steering · prompt + steering · LoRA

- Mesmo modelo e distribuição de problemas
- Orçamento de desenvolvimento e seleção registrado
- Custo de construção e de geração contabilizado
- Avaliação reservada, incluindo repetir o baseline

> Comparar ganho realizável, preservação de competência e custo por decisão.

Contribuições e possibilidades de publicação

Possibilidade	O que precisaria sustentar
Estudo empírico delimitado	Controle, relação geométrica prospectiva e fronteiras
Explicação ou teoria reduzida	Previsões discriminativas além de identidades conhecidas
Método para sistemas de agentes	Utilidade incremental realizável frente a comparadores fortes

> São caminhos a avaliar; aceitação e prioridade não estão estabelecidas.

Resultados negativos, inconclusivos e não avaliados

Estado	Significado
Negativo sob o critério	O teste foi concluído e não satisfez sua regra
Inconclusivo	A resolução ou a evidência não discrimina a hipótese
Não avaliado	A comparação científica pretendida não foi completada

> Uma falha operacional não prova ausência do fenômeno.

D75: o que foi selecionado, e por quê

$$\delta = \eta_{D75} \cdot \sigma_{ref} \cdot v \qquad \eta_{D75} = 0{,}75\ \eta_{full}$$

Critério de desenvolvimento	Regra
Canal e competência	Guardas de validade, avaliabilidade e acurácia
Mudança semântica	Acima de patamar e controles aleatórios
Regime de tokens	Recuperar parte do efeito textual CAREFUL
Escolha	Primeira elegível: D25 → D50 → D75

D75 significa 75% de uma dose histórica. Os alvos 0,25/0,50 do Q2 têm outra definição.

Que pergunta cada controle responde?

Comparador	Dúvida que enfrenta
Repetir o baseline	A diferença excede a estocasticidade da geração?
Texto CAREFUL	A instrução de origem tem efeito e benefício?
Quatro nulls de Q1	A direção construída excede perturbações pareadas?
Orientações de subespaço	A relação geométrica é especial ao espaço construído?

> Especificidade do controlador Q1 e especificidade geométrica do Q2 são afirmações distintas.

A1 e A2: construções operacionais

A1: ângulo após whitening regularizado de ativações ordinárias.

A2: ângulo de deslocamentos de distribuições em relação ao baseline.

$$r_j^2 = \text{média}\, JS(P_j, Po) \qquad d_{jk}^2 = \text{média}\, JS(P_j, P_k)$$

$$A2(j,k) = 1 - (r_j^2 + r_k^2 - d_{jk}^2) / (2 r_j r_k)$$

JS com pesos iguais, log natural e vocabulário completo; probes sem rótulos de correção.

Quatro mudanças de desenho que custaram trabalho

Antes	O que o teste exigiu mudar
Readout e formato de resposta	Geração completa e avaliação semântica
L17, um token, dose inicial	Fonte, camada, duração e dose separadas
Poucas famílias nomeadas	Muitas identidades no span; inferência relacional
Resultado no banco conhecido	Predições congeladas para direções novas

> O progresso foi transformar dificuldades em perguntas que o próximo teste podia resolver.

Linhas posteriores: resultados e estados

Linha	Estado científico
Reorganização entre doses	Diagnóstico retrospectivo; inversões ordinais não demonstradas
Budget em modo thinking	Interação inconclusiva pela decisão fixa
Momento da finalização	Plano e implementação; sem resultado estabelecido

> Essas linhas podem gerar perguntas novas; não ampliam retroativamente o claim Q2.

EXEMPLO CONSTRUÍDO COM PROBABILIDADES DE ERRO

Mesma distância, ganhos de oracle opostos

Dois itens equiprováveis; s = 0,20. Todas as médias de erro são 0,50.

Política	Perfil de erro	D_{shape} ao baseline	C	Acerto oracle
Baseline	(0,20; 0,80)	—	—	66%
A	(0,40; 0,60)	0,0400	+0,0600	72%
B	(0,00; 1,00)	0,0400	-0,0600	60%

$$C_{0j} = ½ [D_{shape}(0,j) + VarPOP(q_0) - VarPOP(q_j)]$$

A mesma D_{shape} permite C de sinais opostos. Com médias iguais, o ganho do oracle sobre repetir o baseline é C. A linha baseline usa duas chamadas baseline; A/B usam uma chamada baseline e uma da variante.

O oracle conhece a correção e aceita uma resposta correta quando ao menos uma tentativa acerta. Isso não é uma regra realizável de roteamento.

Exemplo construído. Duas chamadas independentes condicionalmente ao item. Oracle com gabarito, não roteador. Exemplo exato e identidade